Pontificia Universidad Católica de Chile

Predicción de fuga y tiempos de permanencia para la fidelización de clientes rentables del Plan Complementario de salud en una EPS colombiana

EPS ABC

Grupo 11:

Joan Martinez

Sebastián Cornejo

Andrés Ospina

Katherin Molina

Fecha de entrega: 2 de febrero 2026

Tabla de Contenidos

Tabla de Contenidos 2
1. Resumen Ejecutivo 6
2. Contexto Organizacional 7
2.1. Descripción de la Organización 7
2.2. Ecosistema y Entorno 10
2.2.1 Ecosistema 10
2.2.2 Entorno 15
3. Definición de la Problemática de Negocio 19
3.1. Descripción del Problema 19
3.2. Clientes e Involucrados 20
3.2.1 Clientes 20
3.2.2 Involucrados 21
3.3. Antecedentes 22
4. Propuesta de Valor 24
4.1. Motivación 24
4.2. Contribución 24
4.3. Beneficios 25
4.3.1 Beneficios Financieros (derivados de comprensión y simulación) 26
4.3.2 Beneficios Comerciales (no promesa de resultado) 26
4.3.3 Beneficios Analíticos y Operativos (activos entregables) 27
4.4. Costos 28
4.4.1 Costos de Implementación Inicial (*One-shot*) 28
4.4.2. Costos Operativos Variables 29
4.4.3 Costos de Herramientas y Tecnología (Mixto) 30
4.4.4 Costos de Personal Interno (Tiempo y Esfuerzo) 30
4.4.5 Resumen Financiero 31
5. Objetivos 32
5.1. Descripción 32
5.2. Objetivos específicos 32

5.2 Indicadores de Éxito 32
6. Análisis de Datos 34
6.1. Identificación de Fuentes 34
6.2. Depuración 38
6.2.1. Limpieza y Corrección de Tipos 38
6.2.2. Integración de Datos y Tratamiento de Nulos 39
6.2.3. Ingeniería de Características 40
6.3. Descripción 45
6.3.1 Base de Permanencia (df_permanencia) 45
6.3.2 Base de CRM/PQRS (df_CRM) 51
6.3.3 Base de Consumos Médicos (df_consumos) 53
6.3.4 Análisis Exploratorio de Datos (EDA) y Hallazgos Clave 56
6.4. Consideraciones 63
6.4.1 Consideraciones Éticas 64
6.4.2 Consideraciones Legales y de Privacidad 64
6.4.3 Consideraciones de Seguridad de la Información 64
7. Técnicas Analíticas 65
7.1. Técnicas Alternativas 65
7.1.1. Datos Requeridos 66
7.1.2. Métodos y Técnicas 67
7.2. Herramientas 71
7.3. Selección 72
7.4. Aplicación 74
7.4.1 Aplicación de Técnicas de Segmentación 74
7.4.2 Aplicación de Modelos de Regresión y XGBoost 81
7.4.3 Aplicación Modelo de Supervivencia 86
8. Resultados 89
8.1. Presentación de Resultados 89
8.1.1 Presentación de Resultados de Segmentación 89
8.1.2 Modelos de Regresión y XGBoost 99
8.1.3 Resultados Modelo de Supervivencia 108
8.2 Relación con los objetivos del proyecto 114

8.2.1 Relación de Segmentación con los objetivos del proyecto....114
8.2.2 Relación XGBoost/Regresión Logística con los objetivos del proyecto....115
8.2.3 Relación Modelo de Supervivencia con los objetivos del proyecto....117
8.3 Análisis e interpretación de Resultados....118
8.3.1 Evaluación Económica y Simulación de Escenarios....125
8.3.2 Discusión y Enfoque Propuesto para la Gestión de la Retención....129
9. Conclusiones y Recomendaciones....135
9.1 Conclusiones....135
9.1.1. Hallazgos Estructurales y Resultados....135
9.1.2 Logros y Contribuciones Alineados con los Objetivos....136
9.1.3. Lecciones Aprendidas y Desafíos Superados....137
9.1.4. Valor del Análisis de Datos para la Toma de Decisiones....137
9.1.5. Impacto y Relevancia para la Organización....138
9.2. Recomendaciones....139
9.2.1 Fundamentos Conceptuales de las Recomendaciones....139
9.2.2 Estrategias de Intervención Diferenciadas por Arquetipo de Cliente....140
9.2.3 Tácticas Operativas de Implementación Prioritaria....143
9.2.4 Habilitadores Tecnológicos y de Infraestructura Analítica....146
9.2.5 Fronteras de Innovación Analítica y Mejora Continua....147
9.2.6 Marco de Evaluación de Impacto y Sistema de Indicadores Clave de Desempeño....150
9.2.7 Consideraciones Críticas para la Implementación....152
9.2.8 Síntesis y Llamado a la Acción....154
10. Bibliografía....156
11. Anexos....161
A.1. Cronograma y Matriz Raci....161
A.2 Documentos....161
A.3 Merge_Completo_vigencia_total.parquet....161
A.4. Modelo de Segmentación Kmeans....161
A.5. Modelo de Segmentación UMAP + HDBSCAN....161
A.6. Modelo de Regresión y XGBoost....161
A.7. Pregúntale al Modelo para validación....161

A.8. Modelo de Regresión y XGBoost 162
A.9. Prototipo funcional de despliegue (valor agregado) 162

1. Resumen Ejecutivo

El presente proyecto aborda la problemática crítica de la fuga de clientes rentables en los Planes de Atención Complementaria (PAC) de la EPS ABC, donde la tasa de cancelación anual del 2,8 % se quintuplica en los segmentos de mayor valor y baja siniestralidad. Dado que las estrategias actuales de retención operan de manera reactiva, activándose únicamente cuando la decisión de retiro ya ha sido tomada, se planteó como objetivo el desarrollo de un sistema analítico integral. Este sistema busca identificar arquetipos de usuarios, estimar la probabilidad individual de deserción a un año y predecir los tiempos de permanencia, con el fin de optimizar la asignación de recursos de retención bajo un enfoque estricto de rentabilidad financiera.

Metodológicamente, la investigación se fundamentó en el marco de trabajo CRISP-DM, integrando y depurando tres fuentes de datos internas: Permanencia, PQRS y Consumos Médicos. El enfoque técnico combinó técnicas de segmentación topológica no supervisada mediante UMAP y HDBSCAN para revelar estructuras de comportamiento latentes, con modelos de predicción supervisada donde se contrastó el desempeño de la Regresión Logística frente a XGBoost. De manera complementaria, se implementaron modelos de análisis de supervivencia, incluyendo Kaplan-Meier, Cox y Random Survival Forest (RSF), para capturar la dinámica temporal y las ventanas críticas de la permanencia del afiliado.

Los resultados obtenidos demostraron la superioridad del modelo XGBoost, optimizado bajo una configuración estratégica, alcanzando un desempeño discriminante sobresaliente con un AUC de 0.86 y un indicador Lift de 3.29 en el primer decil. En términos operativos, esto permite capturar el 32 % de la fuga total gestionando únicamente al 10 % de la población de mayor riesgo. La triangulación de los hallazgos reveló fenómenos estructurales como la "Paradoja de la Salud", donde los clientes jóvenes y sanos presentan la mayor volatilidad, y el "Efecto Fortaleza", evidenciando que el uso de la infraestructura propia (IPS Exclusiva) reduce el riesgo relativo de fuga en un 40 %. En conclusión, se realiza una simulación financiera donde se estima que si se implementa el sistema propuesto, este proyecta una utilidad neta estimada de 5,732 millones de COP anuales y un retorno sobre la inversión (ROI) del 302 %, validando la necesidad de transitar de campañas masivas hacia una gestión de retención proactiva y con gestión de información anticipada.

2. Contexto Organizacional

2.1. Descripción de la Organización

Identidad y alcance

Ítem	Dato
Nombre (alias)	EPS ABC
País	Colombia
Rubro	Aseguramiento en salud (PAC, pólizas, vida/generales vía filiales)
Domicilio	Medellín, Colombia
Cobertura	Nacional
Segmentos objetivo	Afiliados régimen contributivo; colectivos/empresariales

Tabla 2.1 *- Datos EPS ABC*

Magnitudes

Ítem	Dato	Año/Fuente breve
Clientes totales (CO)	**13.788.448**	2024 público
Empleados (CO)	**16.661**	2024 público
Afiliados PAC – ABC EPS	**~298.000**	2023 público
Churn rentables PAC (dolor)	**2,8 % anual**	Dato del proyecto

Facturación PAC (ABC EPS)	**Reservado**	—
Siniestralidad PAC (ABC EPS)	**Reservado**	—

Tabla 2.2 *– Datos cuantitativos EPS ABC*

Canales y operación (resumen)

Ítem	**Dato**
Canales principales	Ejecutivo/call, brokers, digital (Web/App/WhatsApp)
Estado comercialización PAC	Sin venta nueva desde **2024**; mantenimiento cartera
Entornos clave	Inflación, empleo, regulación Supersalud/MinSalud

Tabla 2.3 *- Datos de canales y operación EPS ABC*

Organigrama (foco proyecto)

Área	**Rol en proyecto**
Dirección PAC (Sponsor)	Gobierno del caso de uso
Comercial & Retención	Ejecución Top-N / contactos
Servicio al Cliente & PQRS	SLA, causas de fuga
Actuaría & Riesgos	Siniestralidad, valor retenible
Inteligencia de Negocio / BA	Modelado churn / métricas
Tecnología & Datos	DWH/ETL/CRM; calidad de datos

Cumplimiento & Habeas Data	Privacidad (Ley 1581) Colombia

Tabla 2.4 *- Organigrama EPS ABC*

En Colombia, el sistema general de seguridad social en salud está diseñado para garantizar el acceso a los servicios médicos de toda la población, independientemente de su capacidad de pago. Este sistema combina financiamiento público y privado y se organiza en dos grandes regímenes que coexisten y que cubren a diferentes segmentos de la población: el Régimen Contributivo y el Régimen Subsidiado.

El Régimen Contributivo está conformado por las personas que tienen una vinculación laboral o ingresos suficientes para realizar aportes al sistema, como trabajadores dependientes (empleados de empresas), trabajadores independientes (profesionales o emprendedores), pensionados y sus familias. En este régimen, tanto el empleador como el trabajador realizan contribuciones económicas para financiar el acceso a los servicios de salud.

El Régimen Subsidiado, en cambio, está destinado a la población más vulnerable, que carece de capacidad de pago. En este caso, el Estado asume el costo de la cobertura mediante subsidios, financiados con recursos públicos, para que estas personas puedan acceder a los servicios médicos y hospitalarios que garantiza el sistema.

La entidad responsable de formular las políticas, regular el sistema y supervisar su funcionamiento es el Ministerio de Salud y Protección Social. Bajo la dirección del ministerio operan las Entidades Promotoras de Salud (EPS), que pueden ser públicas o privadas. Las EPS actúan como aseguradoras de salud: afilian a la población, recaudan las contribuciones (en el caso del Régimen Contributivo) o reciben subsidios (en el caso del Régimen Subsidiado) y garantizan el acceso a una red de prestadores de servicios de salud (hospitales, clínicas, médicos, laboratorios) para atender las necesidades de sus afiliados.

Dentro del sistema existe un plan básico obligatorio para todos los afiliados, denominado Plan de Beneficios en Salud (PBS). Este plan cubre una amplia gama de servicios médicos, hospitalarios, medicamentos y procedimientos, pero con ciertas limitaciones y exclusiones definidas por el Estado.

Es precisamente en este punto donde surgen los Planes de Atención Complementaria (PAC). Estos son productos de aseguramiento voluntario, ofrecidos por algunas EPS exclusivamente a sus propios afiliados del Régimen Contributivo, que buscan ampliar la cobertura y mejorar la calidad y oportunidad en

la atención médica más allá de lo que garantiza el PBS. El PAC no sustituye la cobertura básica, sino que la complementa con beneficios adicionales.

Entre los beneficios típicos de un PAC se incluyen:

- Acceso más rápido a especialistas sin necesidad de remisión previa.
- No pago de cuota moderadoras y copagos.
- Ampliación del número de procedimientos y tecnologías cubiertas.
- Red de atención preferencial con clínicas y hospitales de mayor capacidad y especialización.
- Habitaciones individuales en hospitalización.
- Mayor cobertura en medicamentos de alto costo no incluidos en el PBS.
- Servicios de salud en el hogar y telemedicina con menor tiempo de espera.

El mercado de seguros voluntarios de salud en Colombia, en el que se ubican los PAC, ha mostrado un crecimiento anual promedio del 12 % anual (Guerrero, 2025), impulsado por el aumento en la demanda de servicios médicos diferenciales y la búsqueda de mayor rapidez en la atención.

Es importante diferenciar el PAC de otros productos como la medicina prepagada o las pólizas de salud. Aunque estos también son seguros voluntarios, tienen un alcance y estructura distinta. El PAC está siempre ligado a la EPS y al PBS, es decir, solo puede ser adquirido por quienes ya están afiliados a esa EPS en el Régimen Contributivo. En cambio, la medicina prepagada y las pólizas privadas son independientes del PBS y tienen sus propios requisitos y redes de atención.

La organización objeto de este estudio es una EPS con presencia nacional que ofrece, entre otros productos, un PAC dirigido al segmento B2C (clientes individuales). La relación con el cliente se gestiona a través de asesores y ejecutivos comerciales que venden el producto y brindan acompañamiento durante su permanencia.

Sin embargo, el PAC enfrenta actualmente un desafío importante y es la pérdida progresiva de clientes (fuga o “churn”), lo que afecta tanto los ingresos como la proyección de crecimiento del portafolio.

2.2. Ecosistema y Entorno

2.2.1 Ecosistema

El sistema de salud colombiano se basa en el **Sistema General de Seguridad Social en Salud (SGSSS)**, establecido por la **Ley 100 de 1993** (Congreso de la República de Colombia, 1993). Tal como se mencionó en el punto anterior, este

modelo combina financiamiento público y privado y se organiza en dos regímenes: el **Contributivo**, para quienes tienen capacidad de pago (trabajadores formales, independientes y pensionados), y el **Subsidiado**, dirigido a personas en situación de vulnerabilidad económica, identificadas mediante el sistema Sisbén (Infopalante, 2024).

El SGSSS opera a través de un esquema de actores con funciones claramente definidas:

- **Ministerio de Salud y Protección Social (MSPS):** Es el ente rector y regulador, encargado de la formulación de políticas y la supervisión del sector.
- **Administradora de los Recursos del Sistema de Salud (ADRES):** Creada en 2017, es un pilar central en la cadena de pagos. Su rol incluye el reconocimiento y pago de la **Unidad de Pago por Capitación (UPC)** a las EPS, asegurando la liquidez del sistema. Las recientes propuestas de reforma buscan centralizar aún más los fondos en esta entidad.
- **Empresas Promotoras de Salud (EPS):** Actúan como intermediarios entre el Estado y los usuarios. Son responsables de administrar el riesgo en salud de sus afiliados a través del **Plan de Beneficios en Salud (PBS)** y de garantizar la prestación de servicios mediante una red de prestadores.
- **Instituciones Prestadoras de Servicios de Salud (IPS):** Son las entidades, tanto públicas como privadas (hospitales, clínicas, laboratorios), que proveen directamente la atención médica.

El sistema permite la movilidad entre regímenes, lo que facilita que una persona pase del régimen contributivo al subsidiado (y viceversa) sin perder continuidad en la atención, siempre que cumpla con los requisitos del Sisbén (Infopalante, 2024).

Papel de las aseguradoras en el sistema de salud colombiano.

En el sistema de salud colombiano, las aseguradoras que ofrecen seguros complementarios voluntarios juegan un papel adicional al de las Entidades Promotoras de Salud (EPS). Estos seguros no reemplazan el Plan Obligatorio de Salud (POS), sino que lo complementan, ofreciendo beneficios adicionales como atención preferencial, acceso directo a especialistas, hospitalización en clínicas privadas y cobertura para enfermedades de alto costo (Bardey, Zapata, Buitrago, & Concha, 2013) (Noticias RCN, 2025).

Dentro de la industria aseguradora de salud, los seguros voluntarios incluyen modalidades como medicina prepagada, planes complementarios (PAC) y pólizas

privadas de salud. Para acceder a ellos, los usuarios deben estar afiliados al sistema general (EPS o régimen de excepción), y en algunos casos cumplir requisitos como exámenes médicos de ingreso, especialmente si tienen más de 60 años (Noticias Caracol, 2023).

La demanda por estos seguros ha crecido significativamente. En 2025, más de 1,2 millones de colombianos optaron por cobertura privada adicional, reflejando preocupaciones sobre la calidad y oportunidad de la atención en el sistema público (Noticias RCN, 2025). Según el DANE, 2,9 millones de personas ya pagan por estos planes, lo que indica una tendencia creciente en todos los estratos socioeconómicos (Noticias Caracol, 2023). En el caso colombiano, Johnattan García Ruiz, investigador de sistemas de salud globales en la Universidad de Harvard en Estados Unidos, estima que al menos un 8 % de la población paga un seguro privado. (Cueto, 2024)

Las aseguradoras están adaptando sus productos para hacerlos más accesibles, ofreciendo planes más simples y económicos, incluso con opciones de congelamiento para quienes se trasladan al exterior. Este dinamismo del mercado responde a la necesidad de los ciudadanos de garantizar una atención más rápida y especializada, ante las limitaciones del sistema público, que actualmente no está siendo capaz de cubrir las necesidades en salud.

El Plan de Atención Complementaria (PAC)

En este contexto de crisis e incertidumbre, los **Planes de Atención Complementaria (PAC)** emergen como una solución para las deficiencias del sistema obligatorio. A diferencia de la medicina prepagada, los PAC son un servicio adicional ofrecido por las mismas EPS a sus afiliados del régimen contributivo. Su propuesta de valor es un complemento al **Plan de Beneficios en Salud (PBS)**, ofreciendo ventajas que el sistema público no puede garantizar con la misma agilidad, como acceso directo y preferencial a especialistas, servicios con mayor confort como habitación individual, y atención a domicilio (Nueva EPS, 2025; Famisanar, 2025).

El PAC es un actor especial porque funciona como un puente entre el sistema público y el privado. Permite a los usuarios tener una atención más ágil sin la necesidad de migrar a la medicina prepagada, que es más costosa y no requiere afiliación a una EPS.

Ítem	Dato	Año/Fuente breve
Valor mercado **PVS** (voluntarios, total)	**COP 12,8 billones**	2024 público
% PAC dentro de PVS	**11,8 % – 16 %**	2023–2024 público
Valor mercado PAC (rango)	**COP 1,5 – 2,1 billones**	2024 (estimación pública)
Afiliados PAC en Colombia	**~1,0 millón**	2024 prensa
Cuota EPS ABC en PAC	**~40 % (2023)**; **~30 % (2024 aprox.)**	Prensa/series públicas
Principales competidores PAC	Compensar, Sanitas, Salud Total, Nueva EPS, Famisanar, SOS	—

Tabla 2.5 *– Datos Mercado PAC*

Desafíos Estructurales y la Crisis del Sistema (Legales, Sociales y Económicos)

Aunque la cobertura del sistema es casi universal, con más del **98.46 %** de la población afiliada, persisten desafíos significativos que afectan su sostenibilidad (Infopalante, 2024). Para febrero de 2024, el régimen contributivo contaba con 23 millones de personas afiliadas, frente a los 26.5 millones del régimen subsidiado (Cueto, 2024).

El sistema enfrenta una profunda crisis financiera que genera incertidumbre en el sector. Una de las principales amenazas es la **crisis de las EPS**, que han reportado pérdidas históricas, con un déficit patrimonial de hasta **$10.2 billones de pesos** y una siniestralidad superior al 103.4 % (Asprilla, 2025). Esta situación ha llevado al cierre de varias IPS y a la suspensión de servicios en hospitales, afectando directamente la calidad del servicio.

Una reforma reciente busca fortalecer la atención primaria y transformar las EPS en **gestoras de salud**, centralizando los pagos en la ADRES para mejorar la eficiencia y evitar deudas acumuladas (Unir Colombia, 2025). Sin embargo, esta reforma ha instalado una gran incertidumbre sobre su viabilidad financiera y operativa, lo que ha llevado a muchos usuarios a buscar alternativas en el sector privado ante el riesgo de que los servicios públicos se deterioren aún más.

Los argumentos en torno a la reforma del sistema de salud tienen como base una preocupación estructural y es que se menciona que los planes voluntarios como la medicina prepagada y los Planes de Atención Complementaria (PAC) terminan trasladando parte del gasto de atención al sistema público, generando una carga adicional. Esto ocurre porque, para acceder a estos planes, es obligatorio estar afiliado a una EPS del régimen contributivo, incluso si el afiliado no utiliza sus servicios básicos. Además, los planes voluntarios tienen coberturas anuales limitadas, que se consumen primero en cualquier atención médica. Cuando el tratamiento supera ese monto, el excedente es cubierto por el Plan Obligatorio de Salud (POS, hoy PBS), lo que significa que, en casos de enfermedades de alto costo, el financiamiento proviene de una combinación entre el plan voluntario y el sistema público, sobrecargando a la ADRES y al sistema general de salud. (Redacción Economía, 2024)

Esta situación no es menor para el Estado. De hecho**,** la ADRES sigue enfrentando desafíos importantes relacionados con los PAC. Por ejemplo, en 2023, los PAC captaron el 6,27 % de los recursos de la Unidad de Pago por Capitación (UPC), a pesar de representar solo el 3,34 % de los afiliados al régimen contributivo. Esta diferencia evidencia una asignación desproporcionada de recursos, que pone en entredicho la sostenibilidad financiera del sistema y refuerza la necesidad de revisar el rol de los planes voluntarios en el modelo de aseguramiento. (ADRES, 2023).

Para organizar de manera óptima los desafíos estructurales del sistema, se ve un diagrama PEST.

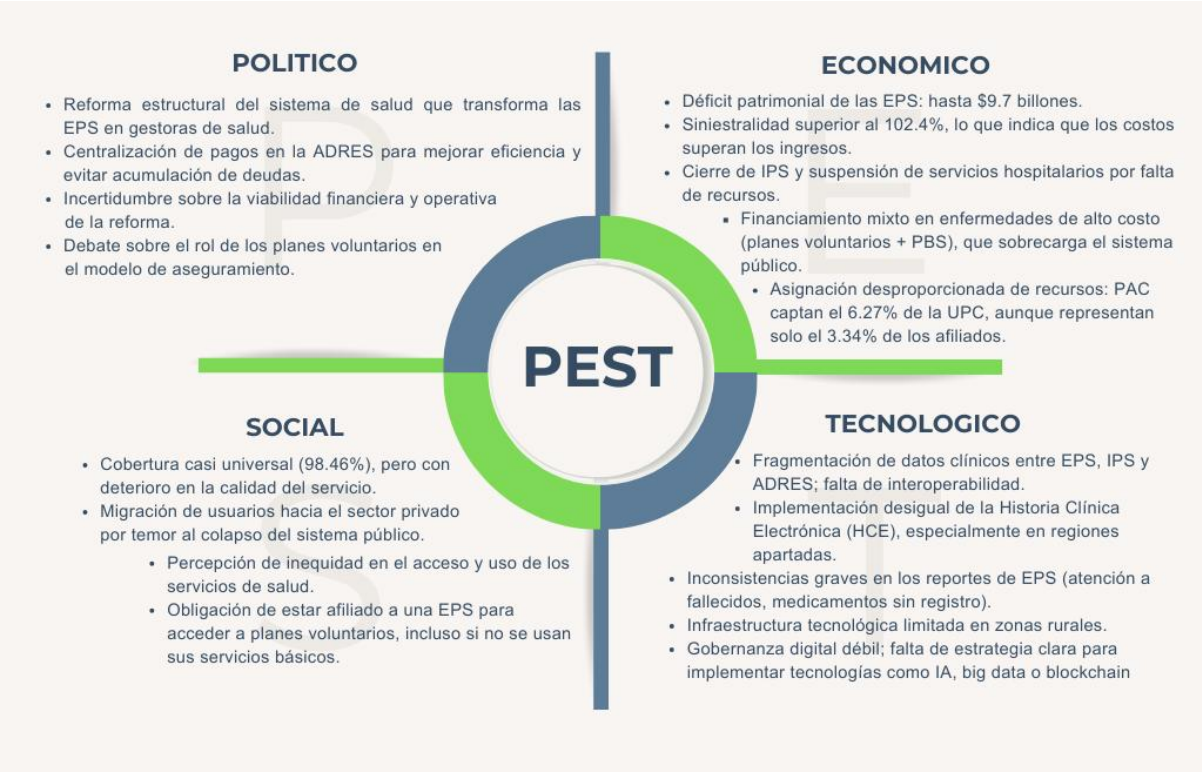

Imagen 2.1 *- Diagrama PEST de desafios para el sistema PAC*

2.2.2 Entorno

Tal como ha sido mencionado previamente en el presente informe, el mercado de los Planes de Atención Complementaria (PAC) en Colombia ha experimentado un crecimiento significativo, impulsado principalmente por la insatisfacción con el sistema de salud público y la creciente demanda de servicios más rápidos y especializados. Estos planes, ofrecidos por las Entidades Promotoras de Salud (EPS), se posicionan como una alternativa accesible frente a la medicina prepagada, atrayendo a un segmento importante de la población que busca mejorar su acceso a la salud.

Cifras y Crecimiento del Mercado

Aunque las cifras exactas del valor monetario del mercado de PAC no son de dominio público, es posible dimensionar su comportamiento a través de su cuota de mercado y el número de afiliados. El tamaño del sector de Planes Voluntarios de Salud (PVS) en el país, según estimaciones de los datos recogidos por Fasecolda y Acemi, asciende a casi 5 millones de personas que tienen alguno de estos servicios. la medicina prepagada el de mayor participación en el mercado con 57 %, las pólizas de salud con un 27 % y por último los planes complementarios y ambulancias prepagadas con 16 % de participación (Salazar Gaitán, 2024) contra

el 6 % en 2012. Con respecto a la **proyección de Afiliados,** se proyecta que el número de afiliados a servicios afiliados exclusivamente al segmento de medicina prepagada de salud alcance los 4.25 millones en 2025, lo que evidencia la gran demanda y la expansión continua de este segmento voluntario (El Colombiano, 2025).

Imagen 2.2 *– Grafico de proporción de tipos de seguros voluntarios en Colombia*

Dado que el régimen contributivo tiene cerca de 24,3 millones de afiliados, y según la ADRES los PAC representaban un 3,34 % de los afiliados a este régimen, podemos estimar que el mercado PAC es de aproximadamente 811.000 usuarios.

Entorno Competitivo y Posicionamiento del PAC

El Plan de Atención Complementaria (PAC) no opera solo en el mercado, sino que se desenvuelve en un **entorno altamente competitivo**, en el que su éxito depende de su capacidad para diferenciarse de otras ofertas de salud privadas. La competencia del PAC no solo proviene de otras EPS que ofrecen productos

similares (competencia directa), sino también de alternativas más robustas como la **medicina prepagada** y las **pólizas de salud** (competencia indirecta).

- **Medicina Prepagada:** A diferencia del PAC, la medicina prepagada es un servicio independiente que no requiere afiliación a una EPS del régimen contributivo para su contratación. Su principal público son personas o familias que buscan una cobertura más amplia y una mayor autonomía en la elección de su red médica y de especialistas, sin las limitaciones de la EPS. Ofrecen una red de clínicas y médicos más extensa, y sus beneficios suelen incluir acceso a tecnología de punta y tratamientos de alto costo con menores trámites administrativos. Su precio es significativamente más elevado, lo que la posiciona como un producto de mayor valor y exclusividad (Colmédica, 2024).

- **Pólizas de Salud:** Son un producto de las compañías de seguros. Su característica principal es que funcionan bajo un modelo de reembolso, donde el usuario paga los servicios médicos y luego la aseguradora le reintegra un porcentaje del valor, según las condiciones de la póliza. A menudo, su público busca una cobertura flexible que le permita elegir libremente a cualquier médico o clínica, incluso aquellos fuera de la red de la aseguradora, lo que la hace atractiva para quienes valoran la libertad de elección por encima de todo (Sura, 2024).

La competencia se basa en la **calidad de la red médica**, el **tiempo de atención**, la **variedad de coberturas adicionales**, el **precio** y el **servicio al cliente**. La facilidad con la que un cliente puede cambiar de aseguradora aumenta la importancia de las estrategias de fidelización del PAC. Dado que su principal ventaja es ser un complemento más accesible y ligado a una EPS, su éxito reside en ofrecer un servicio tan eficiente y de calidad que los usuarios no se vean impulsados a migrar a las alternativas más costosas y menos vinculadas al sistema de seguridad social.

Principales Actores y Oferta Comercial

El mercado de PAC está dominado por las principales EPS del régimen contributivo, que ofrecen estos planes como una extensión de los beneficios del POS. Los precios y la cobertura varían significativamente según la edad del afiliado, la ciudad de residencia y los servicios incluidos.

- **Sanitas (Plan Premium):** Es uno de los actores más fuertes. Sus planes ofrecen acceso directo a especialistas, consultas médicas sin copago y servicios de hospitalización en habitaciones individuales (Sanitas, 2025).

- **Nueva EPS:** Ofrece planes con beneficios adicionales como consultas médicas domiciliarias y acceso a una red de clínicas y especialistas con tarifas preferenciales. Sus tarifas varían por rango de edad (Nueva EPS, 2025).
- **Otros Competidores:** Compañías como Seguros Sura, Seguros Bolívar, Salud Total, SOS, Famisanar, Compensar y Coomeva también tienen una presencia importante en el mercado, ofreciendo planes que se adaptan a distintas necesidades y presupuestos, consolidando un ecosistema competitivo y diverso.

Factores Clave en el Entorno Competitivo

El crecimiento del mercado de PAC no es accidental. Responde a una combinación de factores que reflejan el panorama de la salud y la economía colombiana.

Impulsores del Crecimiento

- **Deterioro del Servicio Público:** La principal fuerza impulsora es la insatisfacción con la calidad y la oportunidad de atención en el sistema de salud público. La Superintendencia Nacional de Salud ha reportado un aumento en el número de quejas, lo que ha llevado a un número considerable de personas a buscar soluciones en el sector privado (El Tiempo, 2024).
- **Gasto de Bolsillo en Salud:** El gasto de los hogares colombianos en salud es considerable, representando entre el 20 % y el 40 % de su ingreso mensual. Esta situación ha incentivado la búsqueda de planes que permitan controlar y reducir estos costos, haciendo que los PAC sean una opción atractiva (El País, 2024).
- **Innovación Digital:** La adopción de tecnologías como la telemedicina y los servicios digitales ha mejorado la eficiencia y la conveniencia, haciendo que los planes privados sean más atractivos para los consumidores.

3. Definición de la Problemática de Negocio

3.1. Descripción del Problema

El mercado de seguros voluntarios de salud en Colombia, en el que se ubican los PAC, ha mostrado un crecimiento anual promedio del 12 % anual (Guerrero, 2025), impulsado por el aumento en la demanda de servicios médicos diferenciales y la búsqueda de mayor rapidez en la atención.

La organización objeto de este estudio es una EPS, La cual para efectos de este proyecto llamaremos “EPS ABC” con presencia nacional que ofrece, entre otros productos, un PAC dirigido al segmento B2C (clientes individuales). La relación con el cliente se gestiona a través de asesores y ejecutivos comerciales que venden el producto y brindan acompañamiento durante su permanencia. Este PAC es estratégico para la compañía porque:

- Genera ingresos adicionales recurrentes sobre la base de afiliados ya captados.
- Incrementa el valor promedio de cada cliente (ticket promedio).
- Diferencia a la EPS ABC frente a sus competidores al ofrecer un servicio de salud más rápido, personalizado y de alta calidad.

Sin embargo, el PAC enfrenta actualmente un desafío importante y es la fuga progresiva de clientes (“*churn*”), lo que afecta tanto los ingresos como la proyección de crecimiento del portafolio.

Sin embargo, el portafolio del Plan de Atención Complementaria (PAC) presenta un desafío estructural importante en la retención de afiliados. En los últimos años la variación anual de activos ha sido positiva, aunque por debajo del esperado, ha tenido un crecimiento acumulado sostenido. El problema subyacente detrás de esto es que el aumento proviene principalmente de la captación de nuevos clientes y no de una retención sólida. La tasa bruta de fuga ha mostrado un incremento progresivo, situándose actualmente en 2.8 % anual total, lo que refleja una pérdida constante de asegurados, incluso dentro de segmentos considerados estratégicos por su alta rentabilidad y baja siniestralidad, los cuales tienen una proporción de fuga 5 veces mayor que el resto de los segmentos de mayor siniestralidad.

Las estrategias de retención implementadas en la actualidad son mayoritariamente reactivas, se activan cuando el cliente ya ha manifestado su intención de cancelar, principalmente mediante llamadas de retención. Este enfoque limita la efectividad

de las acciones, pues en esta etapa la decisión del cliente suele estar consolidada y revertirla resulta difícil.

La pérdida de clientes de alto valor tiene un impacto directo en los ingresos recurrentes y en el margen operativo, ya que estos asegurados generan un balance favorable entre prima pagada y costo de reclamación. Adicionalmente, existe un riesgo reputacional enfocado en la insatisfacción o salida de estos clientes que pueden disminuir la recomendación boca a boca, y que constituye uno de los canales de adquisición más relevantes en este tipo de productos. En consecuencia, el crecimiento observado en la cartera es más aparente que real, dado que se sostiene sobre la adquisición continua de nuevos afiliados sin lograr frenar de manera efectiva la fuga de la base más rentable.

3.2. Clientes e Involucrados

3.2.1 Clientes

Los clientes del Plan de Atención Complementaria (PAC) son personas naturales afiliadas al régimen contributivo del sistema de salud colombiano, principalmente con ingresos medios y altos, que buscan un acceso más rápido, cómodo y de mayor calidad a los servicios médicos que el Plan de Beneficios en Salud estándar. A nivel general también se caracterizan por valorar profundamente la confianza en su aseguradora, buscando experiencias personalizadas, omnicanales y centradas en la calidad de vida. Su comportamiento clínico revela una alta intensidad en el uso del sistema de salud, con un promedio de 11,6 actividades médicas al año y costos per cápita significativamente superiores a los de usuarios no afiliados, especialmente en servicios de alto costo como cuidados intensivos. Este patrón sugiere una mayor conciencia sobre su salud y una disposición a invertir en servicios que ofrezcan prevención, acompañamiento y bienestar integral. (Sura, 2023) (ADRES, 2023)

Desde una perspectiva estratégica, estos usuarios demandan seguros que integren salud, tecnología y propósito social. Valoran la eficiencia digital, la atención remota y las marcas comprometidas con la sostenibilidad. La educación en salud y finanzas personales se vuelve clave para su fidelización. Económicamente, la probabilidad de adquirir un seguro PAC aumenta entre los 30 y 50 años, reflejando una etapa de mayor estabilidad financiera y conciencia sobre riesgos. En este sentido, el PAC no solo representa protección, sino también una expresión de movilidad social positiva. (Morales, Marchi, Spak, Waisser & Craddock, 2025) (Sura, 2023) (Bardey, Zapata, Buitrago, & Concha, 2013).

En resumen, este segmento valora especialmente la oportunidad de acceder a redes de atención diferenciadas, tiempos reducidos de espera, especialistas de libre elección y beneficios adicionales no incluidos en el PBS. Se trata de un grupo altamente sensible a la percepción de servicio y a la relación costo–beneficio donde pequeños deterioros en la experiencia o aumentos de precio sin una mejora percibida pueden motivar su cancelación.

3.2.2 Involucrados

Los actores involucrados en el producto están desglosados en internos y externos.

Internos:

Actor	**Descripción**
EPS ABC	La organización, Administra el PAC.
Área Comercial	Responsable de la captación de nuevos afiliados y del mantenimiento de la relación con los clientes existentes, asegurando el cumplimiento de metas de crecimiento y retención.
Servicio al Cliente	Principal canal de interacción postventa, encargado de gestionar solicitudes, quejas y reclamos; su gestión impacta directamente en la satisfacción y permanencia.
Dirección de Producto	Define la propuesta de valor, estructura de beneficios, cobertura y estrategias diferenciales frente a la competencia.
Inteligencia de Negocios	Realiza la caracterización y segmentación de clientes, identifica patrones de fuga, genera reportes estratégicos y apoya la toma de decisiones basada en datos.
Actuaria	Establece las tarifas del producto considerando siniestralidad y riesgos, analiza tendencias de uso y su impacto en la rentabilidad.
Clientes Actuales	Aunque son receptores del servicio, también actúan como promotores o detractores a través del boca a boca, lo que puede impulsar o frenar la adquisición de nuevos afiliados.

Tabla 3.1 *– Actores Internos*

Externos:

Actor	**Descripción**
Ministerio de Salud	**Regula el sistema de salud y todos los actores**
Superintendencia de Salud	**Vigila y controla el sistema de salud**
Competencia	**Otras EPS, aseguradoras de otros productos voluntarios como medicina prepagada o pólizas de salud**
Afiliados PBS	**Clientes del régimen contributivo (prospectos)**
IPS	**Red de atención que presta los servicios como clínicas, hospitales, centros de salud**

Tabla 3.2 *– Actores Externos*

3.3. Antecedentes

En Colombia, los Planes de Atención Complementaria (PAC) son productos ofrecidos exclusivamente por las EPS como una extensión voluntaria del Plan de Beneficios en Salud (PBS). Su objetivo es mejorar la oportunidad, comodidad y cobertura de los servicios médicos, sin que estén financiados por el sistema obligatorio, sino por el usuario directamente (Canal Institucional, 2022; SGSSS, 2016)

Desde su creación, el PAC ha ganado relevancia como alternativa accesible frente a otros productos como la medicina prepagada o las pólizas de salud. A diferencia de estos, el PAC sí cubre preexistencias, tiene periodos de carencia más cortos y se contrata directamente con la EPS donde el usuario ya está afiliado al PBS.

Entre 2018 y 2023, el PAC fue el tipo de plan voluntario con mayor crecimiento en Colombia, pasando de 295.691 afiliados a 925.521, lo que representa un aumento del 213%. Este crecimiento ha sido acompañado por una concentración creciente de recursos, ya que en 2023 el PAC captó el 6,27% de los recursos de la UPC, a pesar de representar solo el 3,34% de los afiliados al régimen contributivo (ADRES, 2024)

En el caso de la EPS ABC, el PAC es un producto relativamente nuevo en su portafolio. La estrategia comercial se ha centrado en captar afiliados del PBS

mediante campañas internas, lo que ha permitido aumentar el volumen de ventas. Sin embargo, esta táctica no ha garantizado la atracción del cliente más rentable, sino de un espectro amplio de usuarios con perfiles diversos en uso y permanencia.

Aunque algunos de estos afiliados presentan baja siniestralidad, lo que podría favorecer la rentabilidad, la EPS aún no ha logrado una segmentación precisa que identifique el perfil ideal de cliente para el PAC. Este desafío se agrava por el uso de modelos internos basados en variables desactualizadas, en un contexto donde los patrones de comportamiento en salud han cambiado significativamente.

En términos operativos, la retención sigue siendo reactiva. La principal acción consiste en contactar al afiliado cuando manifiesta intención de cancelar, para recordarle los beneficios y persuadirlo de continuar. Esta táctica enfrenta dos tipos de cancelaciones:

Voluntarias, asociadas a percepciones de precio alto o beneficios insuficientes.

Por mora, vinculadas a barreras financieras, sin causas adicionales claramente identificadas.

Actualmente, la EPS define métricas como:

- Tasa de fuga por periodo
- Ventas vs. presupuesto
- Variación en ingresos por primas
- Costo de adquisición de clientes
- Comisiones por retención

No obstante, estas métricas son descriptivas y no permiten anticipar la fuga. ***El reto central de este proyecto es evolucionar hacia un enfoque predictivo***, capaz de identificar con antelación a los clientes en riesgo, segmentarlos según su valor potencial y diseñar estrategias personalizadas que maximicen la retención, priorizando aquellos segmentos con mayor aporte a la rentabilidad y al margen operativo de la compañía.

4. Propuesta de Valor

4.1. Motivación

Este proyecto responde a tres necesidades estratégicas críticas para la sostenibilidad del Plan de Atención Complementaria (PAC):

- **Transición de la Reactividad a la Proactividad-**
  Actualmente, la organización detecta la fuga cuando el cliente ya ha cancelado o está en proceso de hacerlo (con la decisión ya tomada), lo que reduce la efectividad de cualquier intervención. Anticipar el riesgo mediante un puntaje mensual y estimaciones de permanencia abre una ventana de semanas para intervenir a tiempo, aumentando la probabilidad de retención.

- **Eficiencia en la Asignación de Recursos.**
  Sin una medida confiable de riesgo individual, los esfuerzos de retención se distribuyen de forma uniforme, contactando a clientes que no pensaban irse y dejando fuera a afiliados rentables en riesgo silencioso. Priorizando por propensión a la fuga, el presupuesto se concentra donde genera más retorno, reduciendo el costo por caso efectivamente retenido.

- **Protección de la Sostenibilidad Técnica del Portafolio.**
  La fuga no aleatoria de clientes con baja siniestralidad deteriora la mezcla del portafolio, presiona los márgenes y dificulta la planificación operativa y comercial. Retener a los rentables estabiliza la base, mejora la previsibilidad y fortalece la posición competitiva del PAC.

4.2. Contribución

Este proyecto entrega tres contribuciones clave que transforman el análisis en acción concreta:

- **Score Individual Calibrado y Estimaciones de Permanencia**
  Cada afiliado contará con un puntaje mensual que estima su probabilidad de fuga a 1 año, calibrado para reflejar frecuencias reales. Además, se entregan estimaciones de tiempo de permanencia que definen ventanas de contacto, orientando cuándo actuar y por cuánto tiempo sostener la intervención.

- **Segmentación Estratégica de Doble Eje (Valor-Riesgo)**

Se construyen segmentaciones accionables a partir de las bases de Permanencia, PQRS y Usos, diferenciando perfiles y comportamientos. Esto permite diseñar estrategias específicas por subpoblación en cuanto a mensaje, canal e incentivo, con foco explícito en los clientes rentables.

- **Inteligencia Accionable y Protocolos de Gestión**
  Se identifican los impulsores del riesgo y se traducen en umbrales simples para la acción, junto con tablas e indicadores que conectan la analítica con decisiones concretas de priorización y fidelización. Esto dota a la organización de un “manual de alertas tempranas” para la retención.

4.3. Beneficios

La implementación de un modelo predictivo calibrado para estimar la probabilidad de fuga en clientes rentables del PAC permite a la aseguradora transformar su gestión comercial, operativa y financiera. Al identificar con antelación a los afiliados con alta probabilidad de salida y priorizarlos en campañas de retención, se prolonga su permanencia, se incrementa el valor de vida del cliente (CLV) y se estabiliza el flujo de caja. Además, al conservar en la cartera a afiliados con baja siniestralidad, mejora la composición del portafolio y reduce la siniestralidad promedio, lo que se traduce en mayor eficiencia técnica.

Desde una perspectiva reputacional, la intervención temprana sobre factores de fricción, como quejas recientes o caídas inusuales en el uso, reduce la insatisfacción y previene experiencias negativas que suelen amplificarse en canales digitales. Al ofrecer respuestas oportunas y personalizadas a quienes más lo requieren, la aseguradora refuerza la confianza de sus afiliados y diferencia su marca frente a competidores. Un mejor clima de satisfacción también facilita la referenciación positiva, clave en productos de salud donde el boca a boca influye fuertemente en la decisión.

Operativamente, el modelo permite organizar el trabajo diario con criterios claros sobre a quién contactar primero y cuándo hacerlo, pasando de una gestión reactiva a una proactiva con ventanas de intervención definidas. Esto se traduce en uso más eficiente del call center y canales digitales, reducción del costo por caso efectivamente retenido, mayor productividad del equipo y ciclos de seguimiento más disciplinados mediante tableros que conectan riesgo, acciones ejecutadas y resultados. La priorización por riesgo y la planificación por horizonte de permanencia evitan esfuerzos dispersos y focalizan la operación donde el impacto esperado es mayor.

4.3.1 Beneficios Financieros (derivados de comprensión y simulación)

Protección Potencial de Ingresos/Margen (Simulada): A partir del score anual calibrado se simulan escenarios de priorización (Top-N) para estimar cuánto ingreso o margen podría protegerse bajo diferentes supuestos de lift@k, uplift de retención, costo de contacto e incentivos.

Fórmulas de estimación:

- **Churn por cliente (estimación en ingreso):**
$$Protegido \approx N° \, rentables \times \Delta \, churn(pp) \times ingreso_prom_anual$$
- **Churn por margen (recomendado):**
$$Protegido \approx N° \, rentables \times \Delta \, churn \times margen_retenible$$

Ejemplo ilustrativo:

Si el modelo identifica correctamente que el 10 % superior de clientes en riesgo concentra 1.8 veces más fugas (*lift@10% = 1.8*), y se interviene efectivamente sobre este segmento, se pueden simular escenarios de protección de margen bajo diferentes supuestos de efectividad de retención.

Optimización del Presupuesto de Retención (Simulada): Con lift@k y PR-AUC favorables para eventos raros, el riesgo se concentra en pocos deciles, lo que implica:

- Menos contactos improductivos
- Mejor ROI esperado por contacto
- Dimensionamiento informado según cobertura (*Top-5 %, Top-10 %, Top-20 %)*

Mejora del Mix/Margen (Análisis de Oportunidad): El análisis identifica subpoblaciones de baja siniestralidad y alto valor.

- Caracterización de segmentos rentables
- Análisis de sensibilidad
- Insumo para decisiones estratégicas

4.3.2 Beneficios Comerciales (no promesa de resultado)

Productividad Comercial (Priorización Informada), con $AUC \geq 0.75$ y $KS \geq 0.30$ se logra:

- Ordenamiento por riesgo
- Definición de umbrales/Top-N

- Ventanas sugeridas de intervención
- Framework replicable de priorización

Personalización de Estrategias

- Mapas de drivers (*coeficientes/SHAP*)
- Segmentación $riesgo \times valor$
- Plantilla de medición
- Hipótesis accionables

Ventaja Informacional

- Gestión proactiva vs. reactiva
- Base para experimentación (pilotos A/B)
- Benchmarking competitivo

4.3.3 Beneficios Analíticos y Operativos (activos entregables)

Capacidad Analítica Institucional

- Score anual calibrado
- Mapa de drivers
- Guía de umbrales
- Pipeline documentado

Optimización Operativa

- Ventanas de intervención
- Criterios de priorización $riesgo \times valor$
- Simulaciones de contacto por *Top-N*

Diseño de Intervención

- Segmentación por perfil
- Hipótesis de contacto
- Framework de medición para pilotos

4.4. Costos

Nota: Los costos se presentan considerando que este es un proyecto desarrollado en marco académico, pero con potencial aplicación real por parte de la aseguradora. Tipo de cambio referencial: $1\ USD\ =\ \$4{,}200\ COP$ *(septiembre 2024).*

4.4.1 Costos de Implementación Inicial (*One-shot*)

- Preparación y Gobierno de Datos

    - Auditoría y depuración de datos:
        - Recurso: Analista de datos senior (40-60 horas)
        - Tarifa estimada: $25,000-30,000 COP/hora ($6-7 USD/hora)
        - Costo: $1,200,000-1,800,000 COP ($285-430 USD)

    - Diccionario de datos y reglas de negocio:
        - Recurso: Analista de negocio + Científico de datos (30-40 horas combinadas)
        - Costo: $900,000-1,400,000 COP ($215-335 USD)

    - Anonimización y seguridad:
        - Recurso: Especialista en seguridad de datos (20-25 horas)
        - Costo: $800,000-1,100,000 COP ($190-260 USD)

    - Subtotal Datos: $2,900,000-4,300,000 COP ($690-1,025 USD)

- Desarrollo y Validación del Modelo

    - Ingeniería de características:
        - Recurso: Científico de datos senior (80-120 horas)
        - Tarifa: $35,000-40,000 COP/hora ($8-10 USD/hora)
        - Costo: $2,800,000-4,800,000 COP ($665-1,145 USD)

    - Entrenamiento y optimización de modelos:
        - Recurso: Científico de datos + Ingeniero ML (60-80 horas combinadas)
        - Costo: $2,100,000-3,200,000 COP ($500-760 USD)

    - Calibración de probabilidades:
        - Recurso: Científico de datos especializado (25-35 horas)
        - Costo: $875,000-1,400,000 COP ($210-335 USD)

- Documentación técnica y validación:
  - Recurso: Científico de datos + Analista técnico (40-50 horas)
  - Costo: $1,400,000-2,000,000 COP ($335-475 USD)
- Subtotal Modelado: $7,175,000-11,400,000 COP ($1,710-2,715 USD)

- Adopción y Capacitación

  - Talleres con equipos de negocio:
    - 4 sesiones de 4 horas cada una (16 horas de facilitación)
    - Participantes: 12-15 personas (equipos comercial y servicio al cliente)
    - Costo facilitador: $640,000-800,000 COP ($150-190 USD)
    - Costo oportunidad participantes: $2,400,000-3,000,000 COP ($570-715 USD)

  - Guías de usuario y protocolos:
    - Recurso: Analista funcional + Diseñador instruccional (25-30 horas)
    - Costo: $750,000-1,050,000 COP ($180-250 USD)
  - Subtotal Adopción: $3,790,000-4,850,000 COP ($900-1,155 USD)

- **Total Costos Iniciales: $13,865,000-20,550,000 COP ($3,300-4,895 USD)**

4.4.2. Costos Operativos Variables

- Campañas de Retención (Mensuales)

  - Costos de contacto:
    - 150-250 contactos mensuales promedio
    - Costo por contacto: $8,400-12,600 COP ($2-3 USD)
    - Total mensual: $1,260,000-3,150,000 COP ($300-750 USD)

  - Incentivos diferenciados:
    - Budget sugerido: 2-4 % de la prima promedio mensual del segmento
    - Estimado: $4,200,000-8,400,000 COP mensuales ($1,000-2,000 USD)

  - Recursos humanos dedicados:
    - 0.5 FTE Ejecutivo de retención especializado

        - Salario promedio: $3,500,000 COP mensuales ($835 USD)
        - Costo mensual: $1,750,000 COP ($415 USD)

4.4.3 Costos de Herramientas y Tecnología (Mixto)

- Infraestructura de Software

    - Licencias open-source: $0 (Python, scikit-learn, XGBoost, pandas)
    - Infraestructura de cómputo:
        - Cloud computing (AWS/Azure/GCP): $420,000-1,260,000 COP mensuales ($100-300 USD)
        - Almacenamiento y procesamiento para scoring mensual

    - Herramientas de visualización:
        - Power BI Pro: $42,000 COP usuario/mes ($10 USD) × 5 usuarios = $210,000 COP mensuales ($50 USD)

- Mantenimiento y Actualización

    - Re-entrenamiento trimestral:
        - Recurso: Científico de datos (20-25 horas por trimestre)
        - Costo: $700,000-1,000,000 COP por actualización ($165-240 USD)
        -
    - Monitoreo de model drift:
        - Automatización + revisión mensual (8-10 horas/mes)
        - Costo mensual: $280,000-400,000 COP ($65-95 USD)

4.4.4 Costos de Personal Interno (Tiempo y Esfuerzo)

- Durante Implementación (3-4 meses)

    - Product Owner/Líder de proyecto:
        - Dedicación: 30 % de tiempo (48-64 horas/mes)
        - Costo oportunidad: $1,800,000-2,400,000 COP mensuales ($430-570 USD)

    - Referente técnico interno:
        - Dedicación: 25 % de tiempo (40 horas/mes)
        - Costo oportunidad: $1,200,000-1,600,000 COP mensuales ($285-380 USD)

    - Usuarios finales (capacitación y pruebas):
        - 15 personas × 8 horas de participación = 120 horas totales
        - Costo oportunidad total: $3,600,000-4,200,000 COP ($855-1,000 USD)

- Durante Operación (Mensual)

    - Analista de negocio:
        - Dedicación: 15 % de tiempo (24 horas/mes)
        - Costo oportunidad: $720,000-960,000 COP mensuales ($170-230 USD)

    - Administrador del modelo:
        - Dedicación: 10 % de tiempo (16 horas/mes)
        - Costo oportunidad: $560,000-720,000 COP mensuales ($135-170 USD)

4.4.5 Resumen Financiero

- Inversión Inicial Total:
    - Costos directos de desarrollo: $13,865,000-20,550,000 COP ($3,300-4,895 USD)
    - Costos de personal interno (4 meses): $24,000,000-32,800,000 COP ($5,715-7,810 USD)
    - Total implementación: $37,865,000-53,350,000 COP ($9,015-12,705 USD)

- Costos Operativos Mensuales:
    - Campañas y retención: $7,210,000-12,700,000 COP($1,715-3,025 USD)
    - Tecnología y mantenimiento: $910,000-1,870,000 COP ($215-445 USD)
    - Personal interno dedicado: $1,280,000-1,680,000 COP ($305-400 USD)
    - Total mensual: $9,400,000-16,250,000 COP ($2,235-3,870 USD)

- **Costo Total Año 1: $150,665,000-248,350,000 COP ($35,875-59,130 USD)**

Nota: Los rangos de costos consideran diferentes niveles de complejidad y alcance de implementación. Para el contexto académico, estamos considerando el extremo inferior del rango.

5. Objetivos

5.1. Descripción

Desarrollar un sistema analítico integral para la EPS ABC que combine la segmentación avanzada de clientes (Clustering) con modelos de predicción de fuga y supervivencia, permitiendo identificar arquetipos de usuarios, estimar su probabilidad de deserción a 1 año y predecir su tiempo de permanencia para optimizar las estrategias de retención con un enfoque financiero.

5.2. Objetivos específicos

1. Definir criterios de rentabilidad y permanencia de los clientes, incorporando reglas del negocio y segmentación de clientes, identificando arquetipos de clientes basados en patrones de consumo asistencial, niveles de fricción operativa (PQRS) y estabilidad contractual, permitiendo una caracterización técnica que sustente las estrategias de retención diferenciadas.
2. Construir un modelo de predicción de fuga individual utilizando técnicas de machine learning.
3. Calibrar el score de fuga mediante técnicas como Platt Scaling o isotonic regression, asegurando que las probabilidades estimadas reflejen adecuadamente el riesgo real de salida.
4. Validar el desempeño del modelo con métricas como AUC-ROC, Brier Score y curvas de calibración, integrando un análisis de valor esperado que cuantifique el ahorro potencial por ingresos protegidos y la optimización del presupuesto de retención bajo diferentes escenarios de intervención.
5. Generar visualizaciones y reportes interpretables para stakeholders, destacando los factores más influyentes en la fuga y proponiendo acciones preventivas basadas en el score.

5.2 Indicadores de Éxito

Indicador	**Qué mide**	**Meta**
AUC	**Poder de ordenar de mayor a menor riesgo**	$\geq \mathbf{0.75}$
lift@10 %	**Concentración de fuga en top-10 %**	$\geq \mathbf{1.8}$
KS	**Separación entre fugan/no fugan**	$\geq \mathbf{0.30}$

PR-AUC	**Precisión–recuperación (evento raro)**	≥ 0.70
Brier	**Calidad de probabilidad (calibración)**	≤ 0.20
Recall@10 %@60d	**Cobertura con ≥ 60 días de antelación**	$\geq 50\,\%$
DQ (PK/comp./consist.)	**Confiabilidad del dataset**	**Cumple**

Tabla 5.1 *– Detalle de indicadores de éxito*

6. Análisis de Datos

6.1. Identificación de Fuentes

El análisis utilizará principalmente fuentes de datos internas de la aseguradora, que concentran la información relevante sobre la permanencia y el comportamiento de los afiliados en el PAC. Estas bases incluyen la duración en el producto, que permite calcular la permanencia de los clientes y detectar patrones de cancelación; la caracterización de los afiliados, que ofrece información demográfica y de segmentación útil para identificar perfiles diferenciales de riesgo; los registros de PQRS, que constituyen un insumo valioso para medir la experiencia y satisfacción percibida por los clientes; los indicadores de siniestralidad, que permiten distinguir la relación entre uso de servicios y cobertura; y finalmente, las bases de consumos médicos, que muestran la frecuencia y el tipo de servicios utilizados por los afiliados. Todos estos datos se encuentran anonimizados y vinculados únicamente a través de un identificador interno modificado, lo que garantiza la protección de la identidad de los usuarios.

De manera complementaria, se recurrirá a fuentes de datos externas que permitan enriquecer la comprensión del fenómeno de fuga en seguros voluntarios. Entre ellas se incluyen informes de la Superintendencia Nacional de Salud sobre evolución de los seguros voluntarios en Colombia, estadísticas de la Federación de Aseguradores Colombianos (Fasecolda) relacionadas con la penetración y desempeño de estos productos en el mercado, y literatura académica y técnica que aborda metodologías para la predicción de cancelaciones y la retención de clientes en el sector salud. Estas fuentes externas no proveen información individualizada, pero ofrecen un marco de referencia para contrastar los resultados internos con las tendencias del sector y con hallazgos previos en la literatura especializada.

Identificación de Fuentes de Datos Externas

Para comprender la dinámica de pérdida de clientes de Planes de Atención Complementaria (PAC), nuestro análisis no puede limitarse a los datos internos de la compañía. Se hace imprescindible cruzar la información con fuentes externas, que nos ofrezcan un panorama completo del entorno demográfico, socioeconómico y de la competencia. El objetivo es responder a la pregunta fundamental: ¿por qué los clientes se van? ¿Es un problema de la EPS, o es un reflejo de factores que escapan a nuestro control?

El Rol del DANE en el Análisis Socioeconómico y Demográfico

El primer pilar de nuestra investigación externa es el Departamento Administrativo Nacional de Estadística (DANE). A través de la Gran Encuesta Integrada de Hogares (GEIH) que nos entrega el DANE (2025), se puede acceder a datos cruciales sobre empleo, desempleo e ingresos de los hogares. Esta información es vital, ya que la pérdida de un empleo o una disminución en los ingresos familiares son los motivos más comunes para que un cliente cancele un plan de salud voluntario. Al cruzar la información de la GEIH con nuestros datos de deserción, podemos validar la hipótesis de que las fluctuaciones en el mercado laboral son un motor clave de la pérdida de clientes.

Supersalud y la Percepción de Calidad

Para evaluar si la pérdida de clientes es un problema de calidad del servicio, recurrimos a la Superintendencia Nacional de Salud (Supersalud). Esta entidad recopila y publica las Peticiones, Quejas, Reclamos o Sugerencias (PQRS) de los usuarios en todo el sistema. Permite comparar las quejas de clientes propios con las de la competencia.

Fasecolda y el Panorama de la Competencia

La Federación de Aseguradores Colombianos (Fasecolda) es la brújula para entender la dinámica del mercado asegurador. Sus informes ofrecen una visión de la siniestralidad y el crecimiento de primas en el sector. Si la siniestralidad es atípica o si los precios de la competencia están subiendo a un ritmo mayor que el propio, se podría identificar presiones de mercado que influyen en la decisión de los clientes de buscar alternativas o cancelar su plan.

Fedesarrollo: El Pulso Económico

Finalmente, Fedesarrollo proporciona una perspectiva macroeconómica a través de sus informes y estudios de Opinión del Consumidor. Estos datos ayudan a entender la confianza y las expectativas de la población sobre la economía. En un escenario de incertidumbre económica, es natural que los consumidores sean más cautelosos con sus gastos. Esto puede ser un factor subyacente que explique la pérdida de clientes.

En conclusión, la integración de estas fuentes de datos externas permite ir más allá de los síntomas internos y diagnosticar las causas subyacentes de la pérdida de clientes. Al cruzar la información demográfica, de calidad de servicio, competitiva y macroeconómica, podemos construir un análisis sólido y tomar decisiones estratégicas basadas en evidencia.

Identificación de Fuentes de Datos Internas

Para el desarrollo de este proyecto, la EPS proporcionó tres bases de datos internas principales: “Permanencia”, “PQRS” y “Consumos”.

Estas fuentes de datos se encuentran normalizadas y se interconectan mediante una llave primaria común, denominada ID_AFILIADO. Este identificador único permite unificar la información y rastrear la actividad de cada paciente a través de los diferentes conjuntos de datos, facilitando así los futuros análisis descriptivos.

Tabla	Grano	Primary Key	Foreign Keys	Notas
Permanencia	1 fila por afiliado/periodo	ID_AFILIADO	—	Vigencia por FECHA INICIO/FECHA FIN; activo si FIN es nulo
PQRS	1 fila por evento	ID_EVENTO (propuesta)	ID_AFILIADO → Permanencia	Tipo de PQR y proceso; con marca de tiempo
Consumos	(ID_AFILIADO, MES, SUB-CATEGORÍA)	Compuesta	ID_AFILIADO → Permanencia	Frecuencia por subcategoría; costo si disponible

Tabla 6.1 *– Tablas Internas de Datos*

Base de Permanencia

Esta base de datos consolida la información descriptiva de los pacientes afiliados al Plan de Atención Complementaria (PAC) de la EPS. Contiene el historial detallado del afiliado, incluyendo:

- Fecha de ingreso y fecha de fin del contrato.
- Información demográfica.
- Estado de salud reportado.
- Porcentaje de siniestralidad.
- Causa de cancelación (en caso de aplicar).

El objetivo de esta fuente es identificar a los pacientes y sus características, buscando variables que permitan definir patrones para la segmentación de la población. Además, esta base permite diferenciar entre usuarios activos e inactivos.

Es fundamental resaltar que toda la información personal sensible ha sido anonimizada por razones de seguridad y ética, eliminando identificadores directos del paciente. En su lugar, se utiliza exclusivamente el identificador ID_AFILIADO.

Campo	Tipo	Descripción	Oblig.	PII/Sens.	Reglas de calidad
ID_AFILIADO	int	Número único interno (no identificación legal)	Sí	No	Único y no nulo
FECHA INICIO	date	Fecha de inicio del plan	Sí	No	<= hoy
FECHA FIN	date	Fecha fin de cobertura del plan (nulo si activo)	No	No	≥ FECHA INICIO; nulo si activo
TIPO AFILIADO	string	Tomador / Asegurado	No	No	Dominio controlado / catálogo
SEDE	string	Norte/Centro/Oriente/Occidente/Sur	No	No	Dominio controlado / catálogo
EDAD	int	Edad a fecha fin o corte si activo	No	Sens.	Dominio controlado / catálogo
CONDICIÓN SALUD	string	Alta/Media/Baja	No	Sens.	Dominio controlado / catálogo
SEXO	string	F/M	No	PII/Sens.	Dominio controlado / catálogo
NIVEL INGRESO	string	Nivel A/B/C (definición Colombia)	No	Sens.	Dominio controlado / catálogo
MEDIO INGRESO	string	Asesor interno o externo	No	No	Dominio controlado / catálogo
PLAN	string	Bronce, plata, oro, diamante	Sí	No	Dominio controlado / catálogo
RAMO	string	Familiar o Colectivo	No	No	Dominio controlado / catálogo
ESTADO CIVIL	string	Divorciado, soltero, casado y viudo	No	Sens.	Dominio controlado / catálogo
TIPO IPS	string	Propia/Externa/Adscrita	No	No	Dominio controlado / catálogo
CAUSA CANCELACIÓN	string	Motivo de cancelación	No	No	Dominio controlado / catálogo
SINIESTRALIDAD	Decimal (16,2)	Relación Costos/Ingresos del periodo	No	No	≥ 0 (ratio)

Tabla 6.2 *– Diccionario de Tabla Permanencia*

Base de PQRS

Esta fuente registra todas las Peticiones, Quejas, Reclamos y Sugerencias (PQRS) presentadas por los pacientes a la entidad. Cada registro está vinculado al ID_AFILIADO e incluye la fecha de la solicitud, la tipificación (tipo de solicitud realizada) y el proceso que originó el contacto.

La relevancia de esta base para el proyecto radica en que permite medir indicadores de satisfacción del paciente respecto a los servicios prestados. Asimismo, ayuda a identificar a los usuarios que presentan interacciones más frecuentes con estos canales de atención.

Campo	Tipo	Descripción	Oblig.
ID_AFILIADO	string	Número único interno de afiliado (no legal)	Sí
FECHA PQR	date	Fecha del registro de la PQR	Sí
TIPO PQR	string	Petición, Queja, Reclamo, Sugerencia	Sí
PROCESO	string	Causa o concepto de la PQR	No

Tabla 6.3 *– Diccionario de Tabla PQRS*

Base de Consumos Médicos

La base de Consumos Médicos tiene como objetivo registrar todos los servicios del PAC que han sido utilizados o prestados a los pacientes. Esta detalla el mes de la consulta, el concepto del servicio, la categoría a la que pertenece y la cantidad de veces que dicho servicio fue requerido.

Esta fuente es crucial para determinar qué pacientes están haciendo uso efectivo del PAC, con qué frecuencia lo utilizan y cuál es su comportamiento general de consumo. Permite, además, identificar a los afiliados que presentan una siniestralidad más alta que otros y facilita la estimación del costo asociado a la atención de cada paciente. Al igual que las demás bases, cada consumo se vincula mediante el ID_AFILIADO.

6.2. Depuración

6.2.1. Limpieza y Corrección de Tipos

Antes de la integración, se realizó un proceso exhaustivo de limpieza para garantizar la calidad y consistencia de los datos provenientes de las 5 fuentes: **Permanencia, CRM (2) y Consumos (2).** Esta etapa fue crítica, dado que los sistemas transaccionales en producción suelen presentar problemas de duplicidad, valores nulos, formatos inconsistentes y variables con baja calidad informativa.

Eliminación de duplicados

En la base de Permanencia, se identificaron **26.154 registros duplicados**, principalmente por filas con el mismo identificador y fecha de inicio o fecha de fin. Para resolverlo, se aplicó una lógica de negocio, conservar la fila con mayor duración del contrato, calculada como la diferencia entre `FECHA_FIN` y `FECHA_INICIO`. Este criterio asegura que la información más representativa del ciclo del cliente permanezca en el dataset.

Tratamiento de valores nulos

En la base CRM, la variable `TIPO_CASO` presentaba valores nulos. Se imputaron con la categoría “sin información”, evitando sesgos en modelos que no manejan bien valores faltantes. El resto de las columnas no presentó nulos significativos. En Permanencia, se detectó la variable `Estado Civil` con un 43 % de datos “sin información”, por lo que se eliminó del dataset por su baja utilidad predictiva.

Corrección de formatos inconsistentes

Las fechas aparecían en tres formatos distintos: `DD/MM/YYYY`, `YYYY-MM-DD` y timestamps Unix. Se normalizaron todas a un formato único (`YYYY-MM-DD`). En variables categóricas, se unificaron valores como `FEMENINO`, `F`, `Femenino` y `female` en una sola categoría estándar. Este proceso se extendió a otras variables textuales para garantizar homogeneidad.

Resultado final

Tras la limpieza, la pérdida de datos fue de **2,75 % en la base Permanencia**, mientras que las demás bases se mantuvieron prácticamente intactas. Este resultado refleja un proceso eficiente que priorizó la calidad sin sacrificar volumen.

6.2.2. Integración de Datos y Tratamiento de Nulos

Con las bases limpias, el siguiente desafío fue la **integración**. Inicialmente se contaba con cinco archivos (PAC y PBS separados en CRM y Consumos), que se consolidaron en **tres bases**: Permanencia, CRM y Consumos. Sin embargo, cada fuente tenía **granularidad distinta**:

- **Consumos**: nivel transacción (un cliente puede tener múltiples filas por tipo de consumo, convenio, mes y producto).
- **CRM**: nivel transacción (múltiples filas por tipo y causa de caso, mes y producto).
- **Permanencia**: nivel cliente (una fila por un ciclo de vida de un cliente FECHA_INICIO y FECHA_FIN).

Dado que el objetivo era predecir la fuga en un horizonte de 12 meses y que, además, los contratos dentro de la aseguradora son con renovación a 12 meses, se definió la **unidad de análisis como vigencia-cliente**. Esto implicó:

1. **Expandir la base de Permanencia** en intervalos de vigencia anual (1 id con varias filas que indican una fecha de vigencia).
2. **Agrupar CRM y Consumos** por cliente y vigencia, aplicando agregaciones (conteos, sumas, promedios) para reducir la granularidad transaccional.

3. **Unificar las tres fuentes** mediante claves comunes (`AFILIADO_ID_EPS`, `FECHA_INICIO`, `FECHA_FIN`), utilizando **Left Join** con Permanencia como base principal.

El resultado de esta integración fue el Dataset final, que consolida toda la información necesaria para el modelado.

Tratamiento de nulos tras la integración

Las métricas agregadas (Ejemplo: Número de quejas, prestaciones) generaron valores nulos para clientes sin actividad en CRM o Consumos. Estos no se consideraron datos faltantes, sino **ausencia de interacción**, por lo que se imputaron con 0, reflejando fielmente el comportamiento del cliente.

6.2.3. Ingeniería de Características

Para capturar la complejidad del fenómeno de fuga, se diseñaron variables derivadas que enriquecen el modelo predictivo.

A. Segmentos de Variables del Set de Datos Final

1. Identificador

- `AFILIADO_ID_EPS` (ID único del afiliado)

2. Variables Temporales

- `FECHA_INICIO (inicio de vigencia)`
- `FECHA_FIN (fin de vigencia)`
- *(De aquí podemos derivar antigüedad, duración en meses, etc.)*

3. Variables Demográficas

- `Sexo_Cd_BIN`
- `SEGMENTO_EDAD_01_DEPENDIENTE`
- `SEGMENTO_EDAD_02_ADULTOJOVEN`
- `SEGMENTO_EDAD_03_PRODUCTIVO`
- `SEGMENTO_EDAD_04_ADULTOMAYOR`
  (Estas son dummies de edad, ya están segmentadas)

4. Variables Económicas

- `NIVEL_INGRESO`
- `PLAN`

5. Variables de Producto / Contrato

- POLIZA_BIN
- RAMO_FAMILIAR
- Compania_DIGITAL
- Compania_PROPIO
- Compania_TERCERO
- TIPO_IPS_ALIADA
- TIPO_IPS_CONVENIO
- TIPO_IPS_EXCLUSIVA
- TIPO_IPS_PROPIA
- TIPO_IPS_SIN INFORMACION

6. Variables de Segmentación Comercial

- Regional_Agrupadora_CENTRO,
- Regional_Agrupadora_NORTE,
- Regional_Agrupadora_OCCIDENTE,
- Regional_Agrupadora_ORIENTE,
- Regional_Agrupadora_SUR
- TIPO_AFILIADO_ASEGURADO COLECTIVO,
- TIPO_AFILIADO_ASEGURADO FAMILIAR,
- TIPO_AFILIADO_TOMADOR FAMILIAR

7. Variables de Riesgo / Salud

- CONDICION_SALUD
- MARCA_CAC_BIN
- FALLA_BIN
- GRUPO_CAUSA_CANCELACION_MORA,
- GRUPO_CAUSA_CANCELACION_NO APLICA,
- GRUPO_CAUSA_CANCELACION_NO PBS,
- GRUPO_CAUSA_CANCELACION_OTRAS CAUSAS,
- GRUPO_CAUSA_CANCELACION_PETICION DEL CLIENTE

8. Variables de Uso y Experiencia

- **Consumo y uso del servicio**:
  - Prestaciones_PAC
  - Prestaciones_PBS
  - Prestaciones_PAC_FIN

    - Prestaciones_PBS_FIN

- **Interacción y Experiencia del cliente**:
    - Felicitaciones_PAC
    - Felicitaciones_PBS
    - Felicitaciones_PAC_FIN
    - Felicitaciones_PBS_FIN
    - Inquietud_PAC
    - Inquietud_PBS
    - Inquietud_PAC_FIN
    - Inquietud_PBS_FIN
    - Peticion_PAC
    - Peticion_PBS
    - Peticion_PAC_FIN
    - Peticion_PBS_FIN
    - Queja_PAC
    - Queja_PBS
    - Queja_PAC_FIN
    - Queja_PBS_FIN
    - Sugerencia_PAC
    - Sugerencia_PBS
    - Sugerencia_PAC_FIN
    - Sugerencia_PBS_FIN
    - friccion

B. Métricas de Comportamiento Agregadas

De las variables anteriores, se ve en las cuales se sintetizó la historia transaccional del cliente en cada vigencia relacionada a las bases de consumos y CRM:

- **Consumos**:
    - Prestaciones_PAC, Prestaciones_PBS (total de prestaciones por producto).
    - Prestaciones_PAC_FIN, Prestaciones_PBS_FIN (prestaciones en el mes de cancelación para cada producto).
- **CRM**:
    - Felicitaciones_PAC, Felicitaciones_PBS, Inquietud_PAC, Inquietud_PBS, Peticion_PAC, Peticion_PBS, Queja_PAC, Queja_PBS, Sugerencia_PAC, Sugerencia_PBS, y sus versiones "**FIN"** para el mes de cancelación.

En total, se generaron **24 variables agregadas** que capturan la intensidad y tipo de interacción del cliente.

C. Discretización y Codificación

- **Edad**: se detectó comportamiento no lineal, por lo que se discretizó en cuatro segmentos:

    - Dependiente (0-20): Riesgo ligado al titular.
    - Joven Riesgo (21-35): Alta movilidad.
    - Productivo (36-59): Estabilidad.
    - Alto Valor (60+): Baja fuga por necesidad de cobertura.

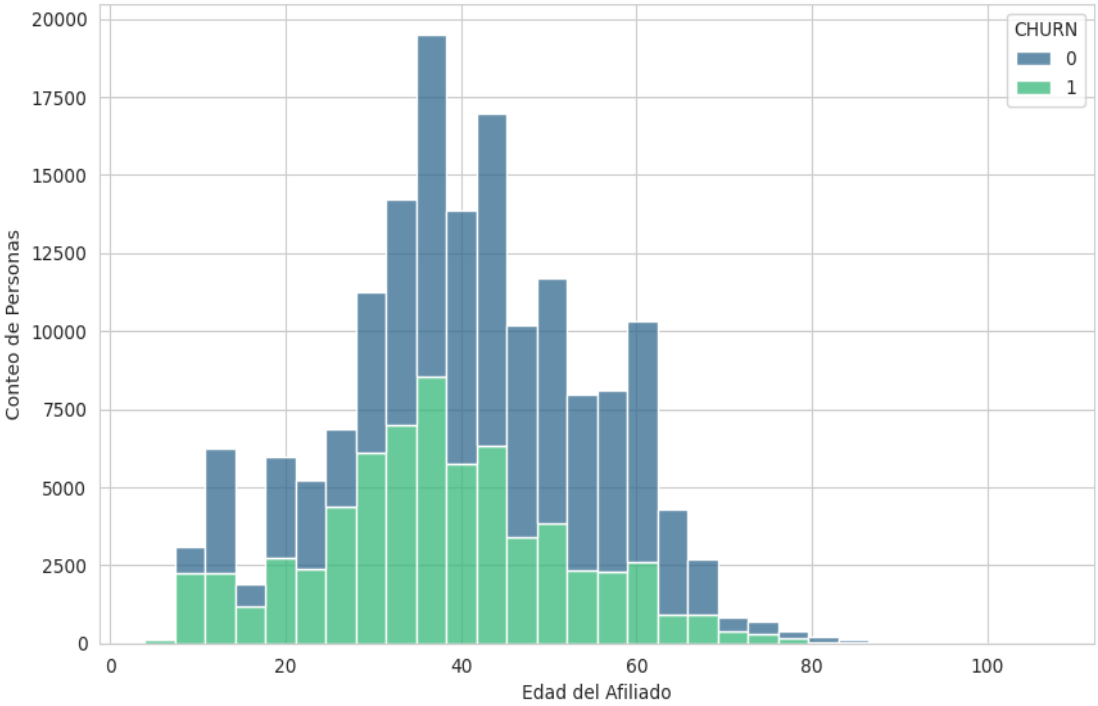

Ilustración 6.2.1 – Distribución de Churn por Edad

Estas categorías se codificaron como variables dummy (`SEGMENTO_EDAD_01_DEPENDIENTE` … `SEGMENTO_EDAD_04_ADULTOMAYOR`).

- **Variables ordinales**:

    - `'NIVEL_INGRESO': {'A': 1, 'B': 2, 'C': 3},`
    - `'CONDICION_SALUD': {'BAJA': 1, 'MEDIA': 2, 'ALTA': 3},`
    - `'PLAN': {'BRONCE': 1, 'PLATA': 2, 'ORO': 3, 'DIAMANTE': 4}`

- **Variables binarias**:
  - `Sexo_Cd_BIN: {'M': 1, 'F': 0}`
  - `POLIZA_BIN: {'SI': 1, 'NO': 0}`
  - `MARCA_CAC_BIN: {'SI': 1, 'NO': 0}`
  - `FALLA_BIN: {'CANCELADOS': 1, 'ACTIVO': 0}`

- **Transformación de variables categóricas:** Para preparar las variables categóricas para el modelado, se aplico **one-hot encoding** a las siguientes columnas.
  - *Tipo de afiliado*
  - *Regional*
  - *Causa de cancelación*
  - *Compañía*
  - *Ramo*
  - *Tipo de IPS*

  En el caso de variables con **alta cardinalidad**, como *Tipo consumo* (20 categorías) y *Causa_caso* (348 categorías), optamos por reducir la dimensionalidad seleccionando únicamente las **10 categorías más relevantes** en cada variable. Para saber una cobertura aproximada de la distribución se calculó cuanto cubre el top 10 de categorías de estas 2 variables:

  Tipo_consumo (20): top 5

  - NIVEL BASICO Y ATENCION DOMICIALIARIA: 1,638,639
  - PROCEDIMIENTOS DIAGNOSTICOS: 1,542,066
  - MEDICAMENTOS POS AMBULATORIOS: 1,517,896
  - CONSULTAS MEDICAS: 1,329,168
  - CONSULTA ACCESO DIRECTO PAC: 653,137

    Total top 5: 6,680,903 (85 %) base de 7 millones 882 mil datos.

  Causa_caso (348): top 5

  - INFORMACION PROCESO DE AUTORIZACIONES DE SALUD: 86,242
  - ATENCION SALUD: 83,026
  - AFILIACIONES: 82,993
  - FALTA DE OPORTUNIDAD Y DISPONIBILIDAD CONSEGUIR CITA: 71,158

- DIGITACION DEL RETIRO OPERAPAC: 65,046

  Total top 5: 388,465 (26 %) base de 1 millón 491 mil datos

6.3. Descripción

En alineación con la segunda fase de la metodología estándar CRISP-DM, esta etapa se centró en la recolección, descripción, exploración y verificación de la calidad de los datos. El objetivo principal fue identificar patrones de comportamiento en la fuga (churn) y validar la viabilidad de las fuentes de información para alimentar los modelos predictivos y de supervivencia.

Para la construcción del dataset analítico, se integraron tres fuentes de información primarias proporcionadas por la EPS ABC, las cuales fueron sometidas a procesos de normalización y anonimización para garantizar la privacidad de los afiliados y el cumplimiento de la normativa de protección de datos:

6.3.1 Base de Permanencia (df_permanencia)

La fuente eje del análisis es la Base de Permanencia, repositorio que consolida la información demográfica, contractual y el estado actual del afiliado, abarcando un total de 474.684 registros. Es sobre esta estructura que se define la variable objetivo; al evaluar la distribución del estado de los afiliados, se observa una proporción equilibrada compuesta por un 53.9 % de pacientes activos frente a un 46.1 % de cancelados. Esta uniformidad en la clase objetivo resulta favorable para el modelado posterior, pues mitiga la necesidad de aplicar técnicas agresivas de re-muestreo para corregir desbalances extremos.

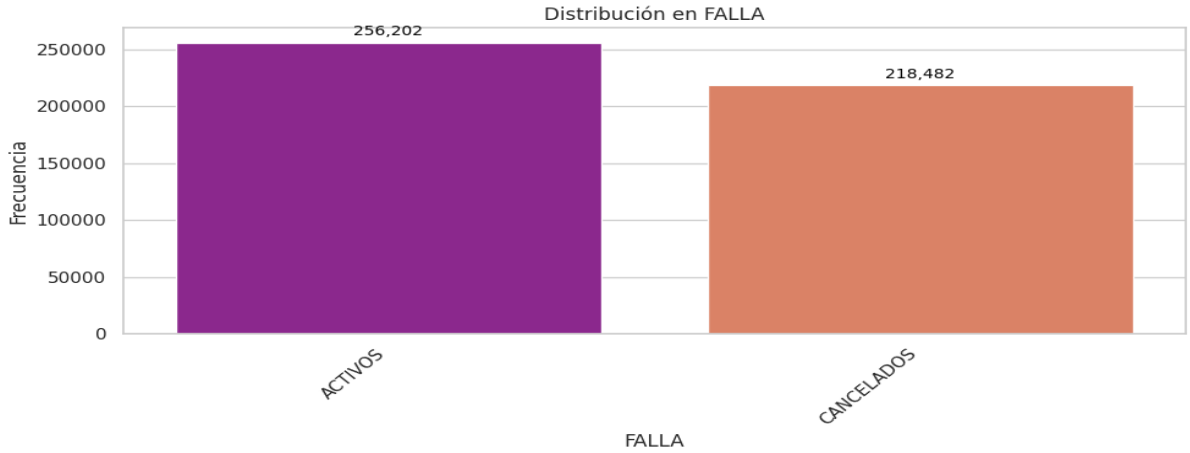

Ilustración 6.3.1 – Grafico Distribución en FALLA

En lo referente a la calidad de los datos, la auditoría inicial reveló una alta integridad en la mayoría de los campos, identificando valores vacíos significativos únicamente en dos variables: Estado Civil y Tipo de IPS, con una ausencia de datos del 43.59 % y 2.16 % respectivamente. Ante este hallazgo, y con el objetivo de preservar la totalidad de la historia transaccional, se optó por una estrategia de imputación explicita mediante la categoría “Sin Información”. Esto permite que los algoritmos de aprendizaje automático evalúen posteriormente si la ausencia del dato constituye en sí misma un patrón de comportamiento o riesgo asociado a la falta de actualización de datos por parte del usuario.

Profundizando en la caracterización de la población, se evidencian patrones estructurales determinantes para la hipótesis de negocio. En primer lugar, la composición de la cartera muestra un predominio de afiliaciones de carácter individual, donde las figuras de "Tomador Familiar" (43 %) y "Asegurado Familiar" (40 %) constituyen el grueso de la población, relegando los planes corporativos a un 17% de la muestra. Este hallazgo es fundamental para entender la dinámica de la fuga: dado que el 83 % de los usuarios asume la carga económica directa (a diferencia de los planes corporativos cofinanciados), se infiere una alta sensibilidad al precio y a la calidad del servicio. En este segmento mayoritario, cualquier fricción operativa o percepción de bajo valor se traduce rápidamente en una decisión de retiro, validando la pertinencia para evaluar en un modelo predictivo.

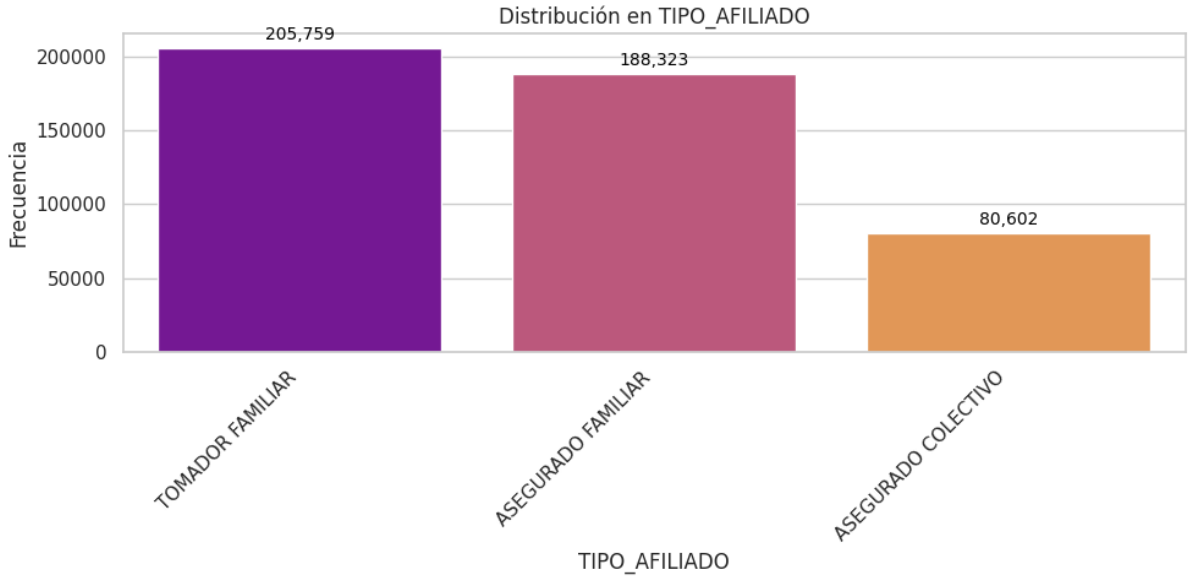

Ilustración 6.3.2 – Grafico Distribución Tipo_Afiliado

Desde una perspectiva operativa y geográfica, la población se concentra mayoritariamente en la Zona Centro (50 %), coincidiendo estratégicamente con la ubicación de la red principal de urgencias y puntos de atención. A su vez, el modelo

de prestación de servicios presenta una estructura mixta, donde la IPS Propia (43 %) y la red en Convenio (34 %) gestionan la mayoría de la demanda. Esta distribución otorga a la EPS un margen de maniobra significativo, ya que casi la mitad de la experiencia del usuario ocurre en infraestructura propia, permitiendo un control directo sobre la calidad asistencial.

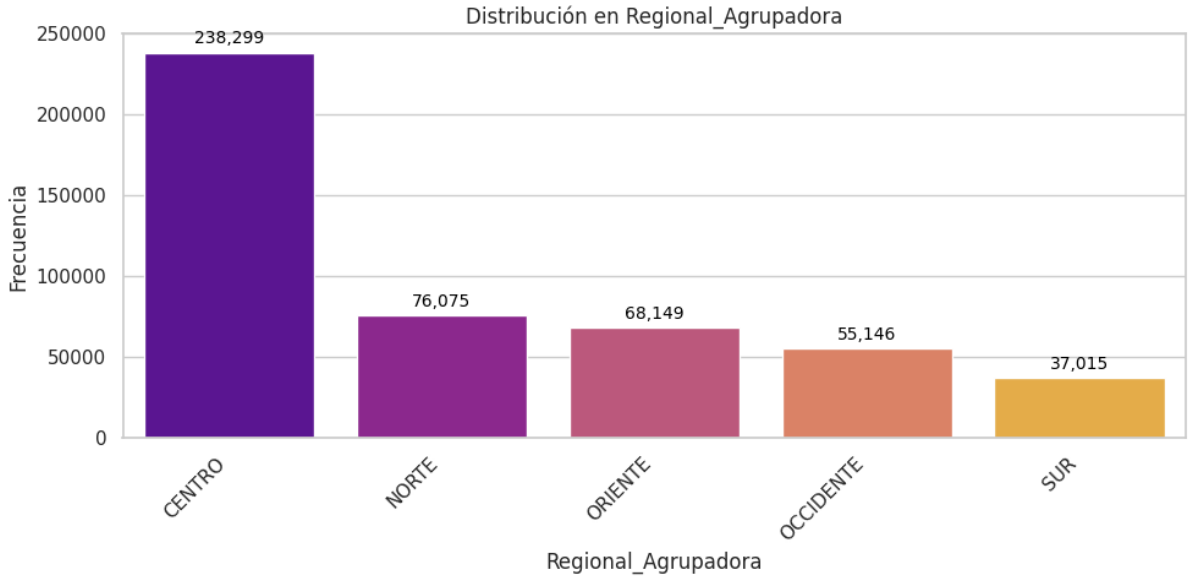

Ilustración 6.3.3 – Grafico Distribución Regional_Agrupadora

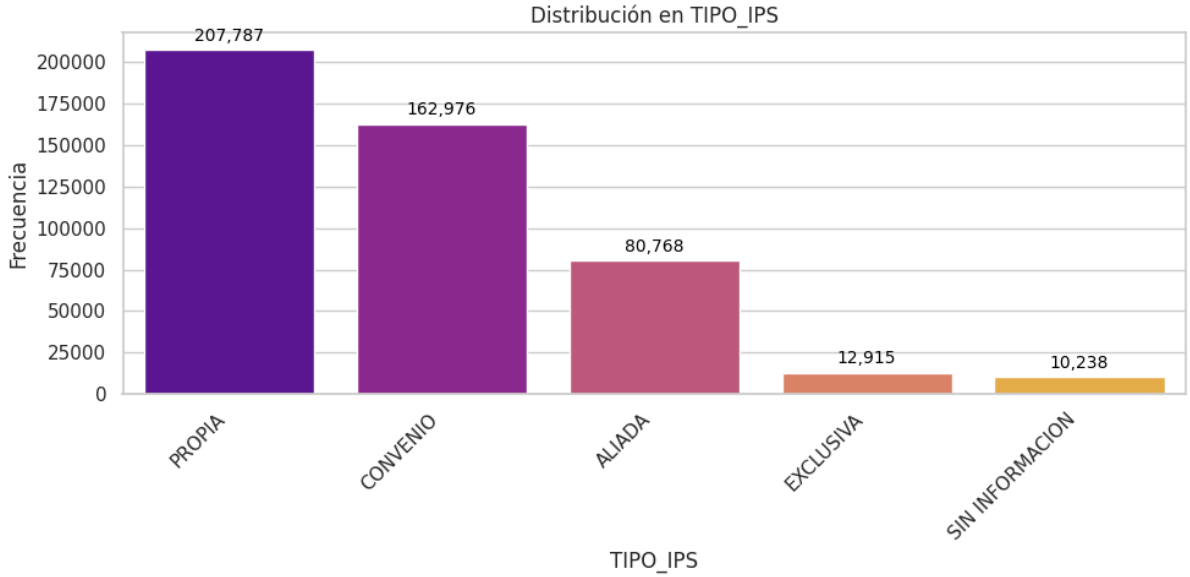

Ilustración 6.3.4 – Grafico Distribución Tipo_Ips

Adicionalmente, al analizar el perfil de riesgo en salud, se identificó que el 47 % de los afiliados se clasifica en condiciones de salud 'Media' y 'Alta'. Este dato confirma que el portafolio se encuentra relativamente balanceado entre la población sana (condición 'Baja') y aquella con mayor carga de morbilidad.

Sin embargo, esta distribución plantea un desafío dual para la sostenibilidad del portafolio: por un lado, la proporción significativa de usuarios con salud 'Media' y 'Alta' podría impactar el equilibrio económico debido a la siniestralidad y el alto costo asociado. Por otro lado, es crucial monitorear al segmento restante (Salud 'Baja'), cuyo riesgo principal no es el gasto médico, sino la probabilidad de deserción, dado que, al no percibir una necesidad inmediata del servicio, son más propensos a cancelar el producto.

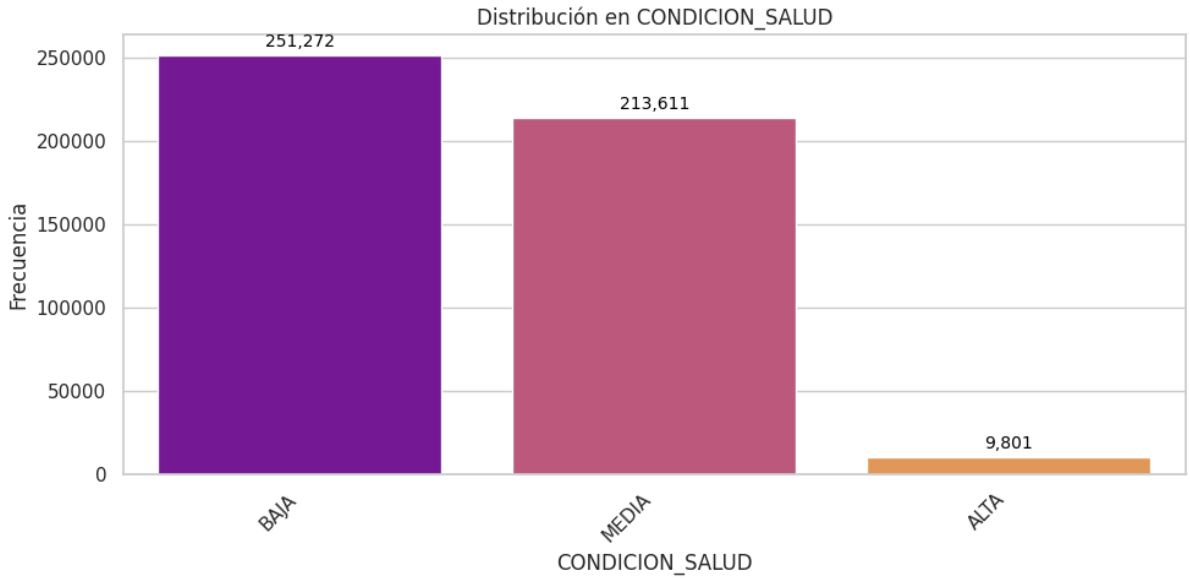

Ilustración 6.3.4 – Grafico Distribución Condicion_Salud

Socioeconómicamente, la base presenta un perfil equilibrado, con una ligera preponderancia del género femenino (59 %) y una distribución homogénea entre los niveles de ingreso (categorías de cuota moderadora A, B y C), lo que asegura que las inferencias del modelo no estarán sesgadas hacia un único estrato socioeconómico.

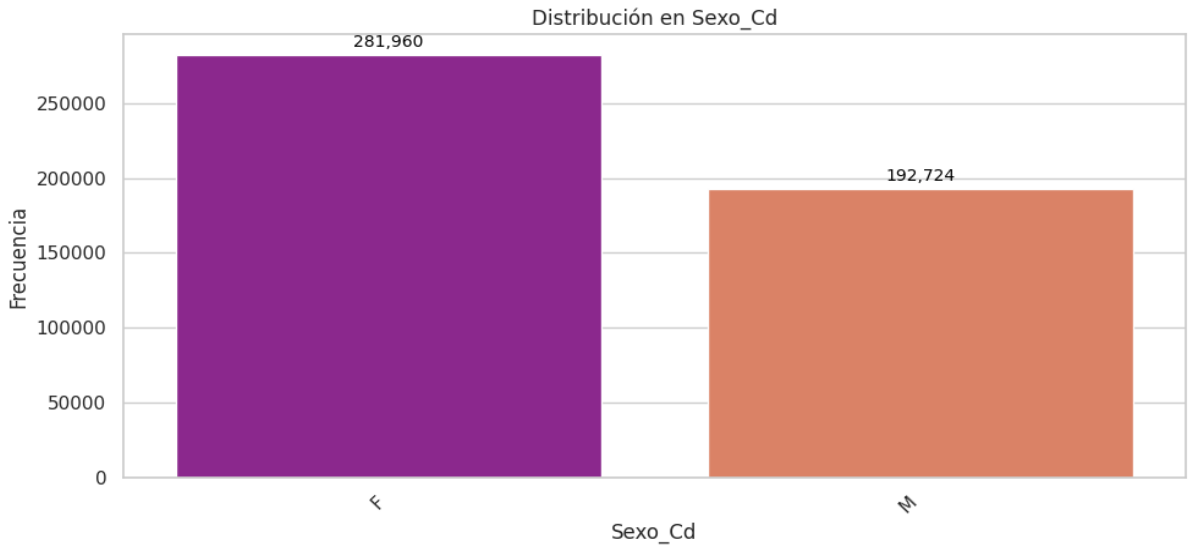

Ilustración 6.3.5 – Grafico Distribución Sexo_Cd

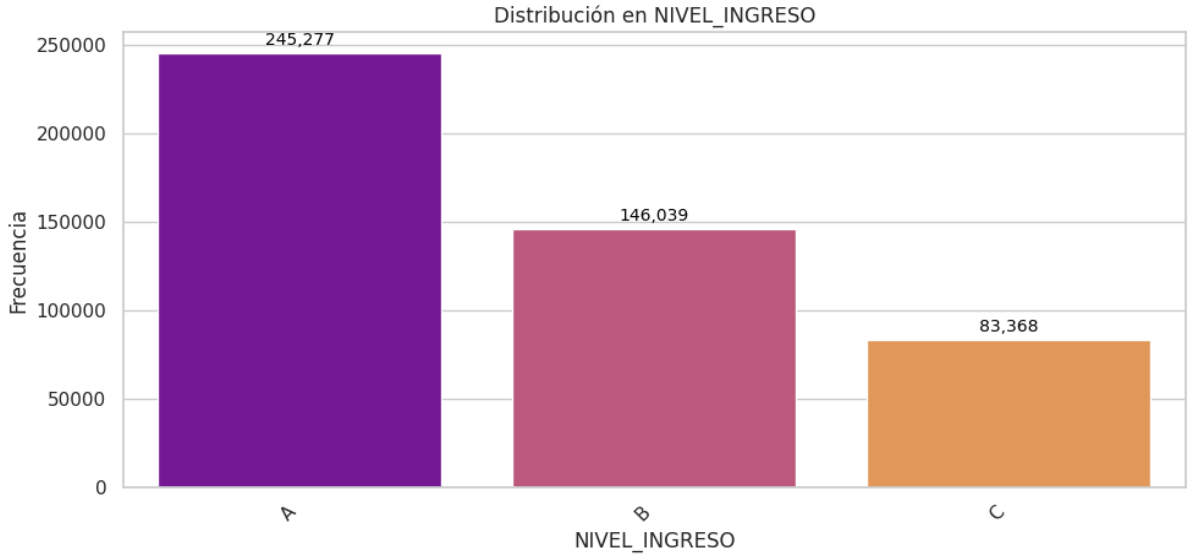

Ilustración 6.3.6 – Grafico Distribución Nivel_Ingreso

Respecto a la segmentación por tipo de producto, se evidencia una clara concentración de la cartera en el Plan Oro, el cual agrupa al 64 % de los afiliados. Este plan constituye la oferta de valor estándar (balanceada) en términos de acceso a servicios. Le siguen en participación los planes Cobre (19 %) y Plata (14 %).

Esta distribución estructural es un hallazgo crítico para la etapa de modelado: dado el peso poblacional del plan Oro, existe el riesgo de que los patrones de fuga de este segmento enmascaren el comportamiento de los planes minoritarios. Por

consiguiente, la variable de 'Tipo de Plan' deberá ser tratada con especial atención para evitar sesgos de generalización, asegurando que el análisis de deserción interprete correctamente las sensibilidades particulares de cada segmento (costo vs. cobertura).

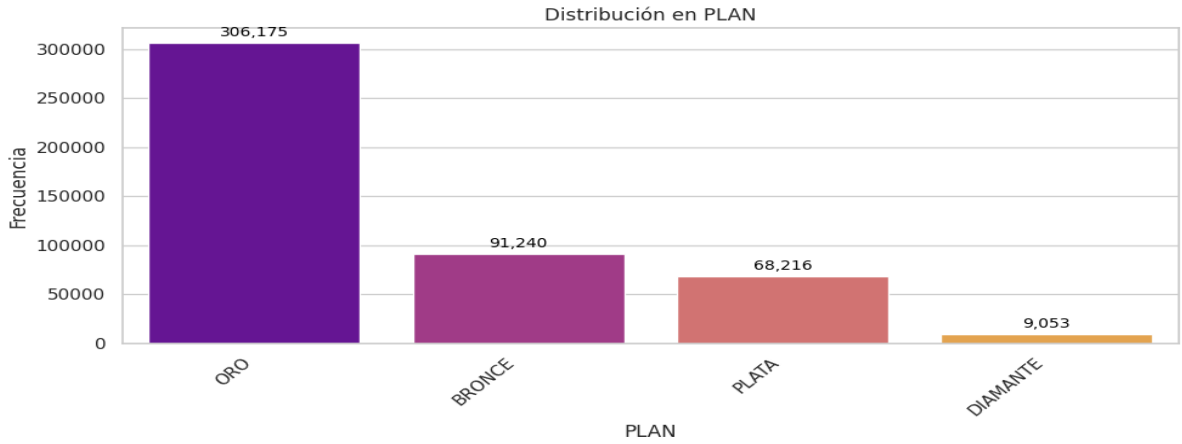

Ilustración 6.3.7 – Grafico Distribución Plan

Finalmente, al desglosar las causas de salida en el segmento histórico de cancelados, se identifican dos detonantes principales con pesos similares: la Mora o cartera (19.8 %) y la Petición voluntaria del cliente (19.5 %). Esta distinción es crucial para el alcance del proyecto, pues evidencia que la fuga es un fenómeno bimodal impulsado tanto por barreras económicas como por insatisfacción o competencia, factores que el modelo deberá aprender a diferenciar mediante las variables comportamentales y de pago integradas en el tablón final. Cabe resaltar que el criterio “No Aplica” hace referencia a pacientes activos en el plan complementario.

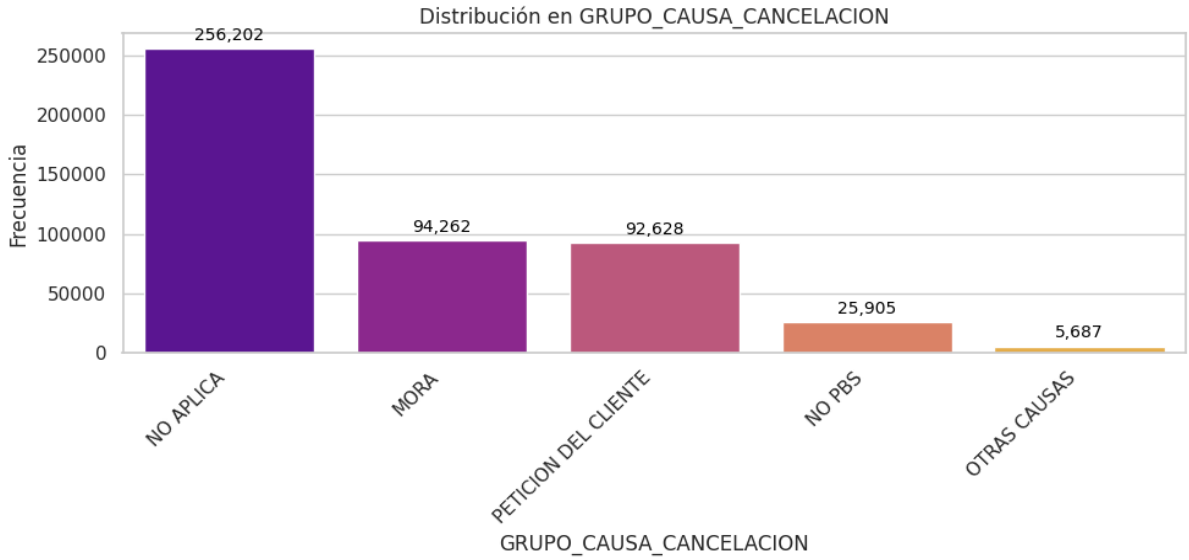

Ilustración 6.3.8 – Grafico Distribución Grupo_Causa_Cancelacion

6.3.2 Base de CRM/PQRS (df_CRM)

Como complemento a la visión demográfica que nos entrega la base de permanencias, se analizó la base de gestión de relaciones con el cliente (CRM), la cual actúa como un registro histórico de la "Voz del Cliente". Esta fuente es fundamental para detectar puntos de dolor y fricción operativa que actúan como detonantes de la cancelación.

La base de datos consolida un total de 1.5 millones de interacciones, proporcionando una muestra robusta del comportamiento del afiliado. Al analizar la distribución por tipo de solicitud, se evidencia una concentración Pareto en dos categorías principales que agrupan el 98 % del volumen transaccional:

- **Peticiones (82 %):** Representan el grueso de la operatividad administrativa (autorizaciones, certificados, novedades).

- **Quejas (16 %):** Aunque menor en volumen, este segmento es crítico para el modelado, pues constituye una señal explícita de insatisfacción o falla en el servicio.

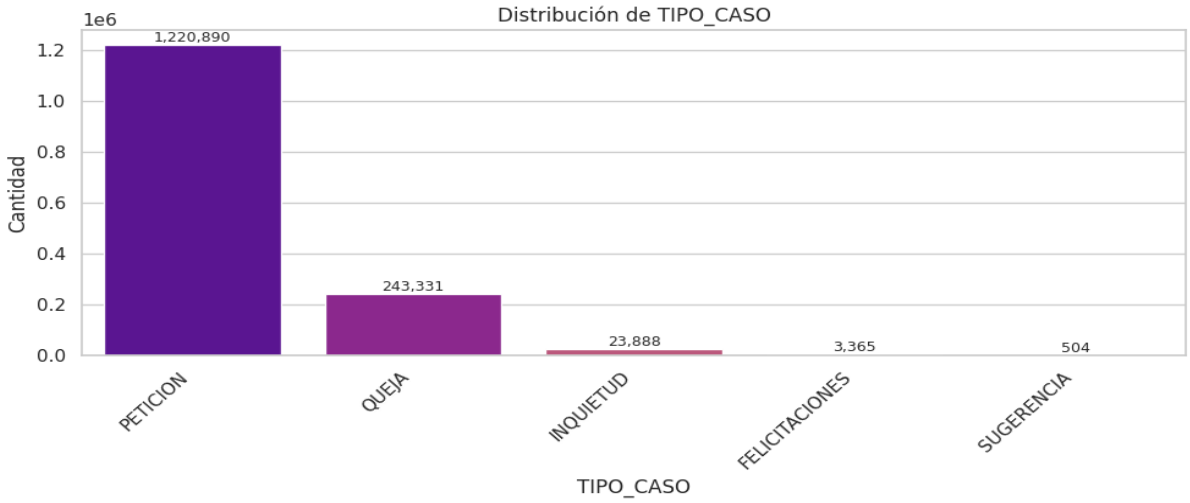

Ilustración 6.3.9 – Grafico Distribución Tipo_Caso

El análisis abarca una ventana de observación de **7 años (2018 - 2024)**, con un flujo promedio mensual de 20,000 casos. Además, no se observa una tendencia de crecimiento lineal monótona, sino un comportamiento con alta variabilidad mensual. Esto sugiere que la interacción del cliente no es constante, sino que responde a ciclos estacionales (probablemente ligados a renovaciones, temporadas de enfermedades respiratorias o cambios administrativos).

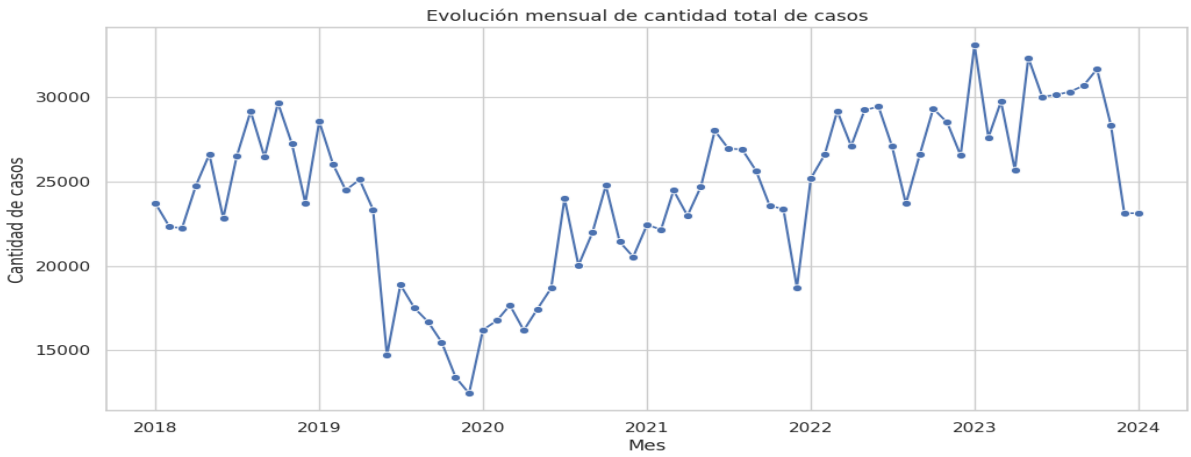

Ilustración 6.3.10 – Evolucion Cantidad Total Casos

Al comparar la carga operativa entre el Plan Complementario (PAC) y el Plan de Beneficios en Salud (PBS), se observa el PAC concentra cerca de 1 millón de casos, duplicando ampliamente el volumen registrado en el PBS (438 mil casos). Esta desproporción indica que el usuario del Plan Complementario es más exigente y transaccional. Existe una mayor carga administrativa ("Peticiones") asociada al PAC, lo cual podría interpretarse como una barrera de uso. Si gestionar el plan PAC requiere más trámites que el plan PBS, se genera una fricción que podría incentivar la fuga por "esfuerzo del cliente". Además, se observa una tendencia de crecimiento sostenido en los casos del PAC a través del tiempo, lo que alerta sobre una creciente complejidad operativa.

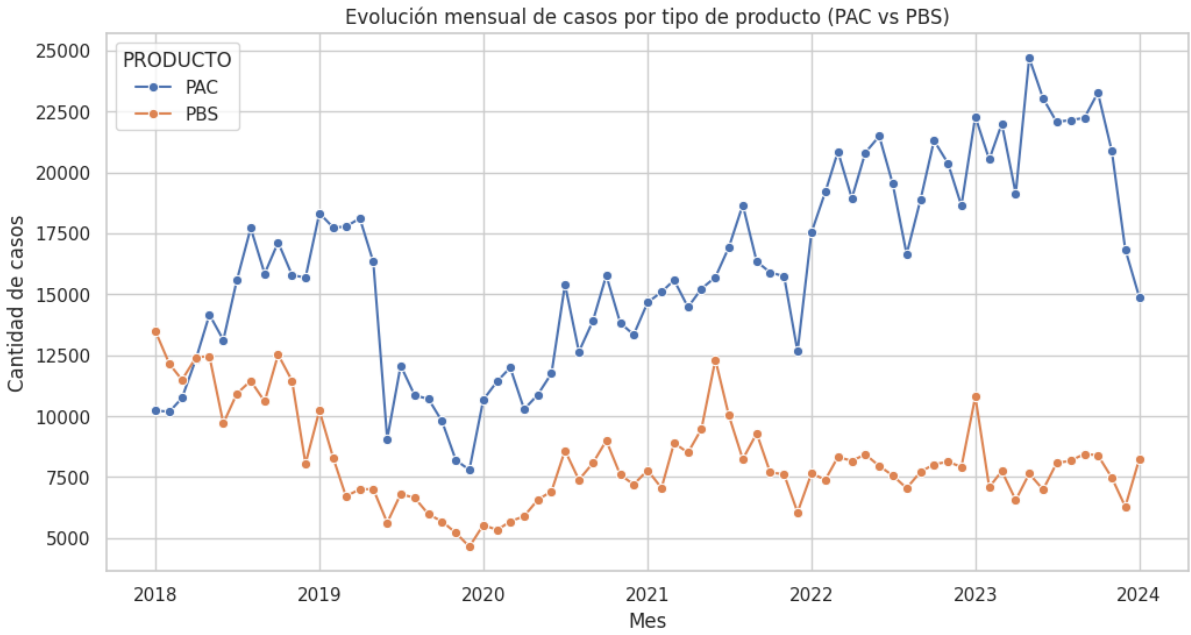

Ilustración 6.3.11 – Evolución Mensual Casos por Tipo de Producto (2018-2024)

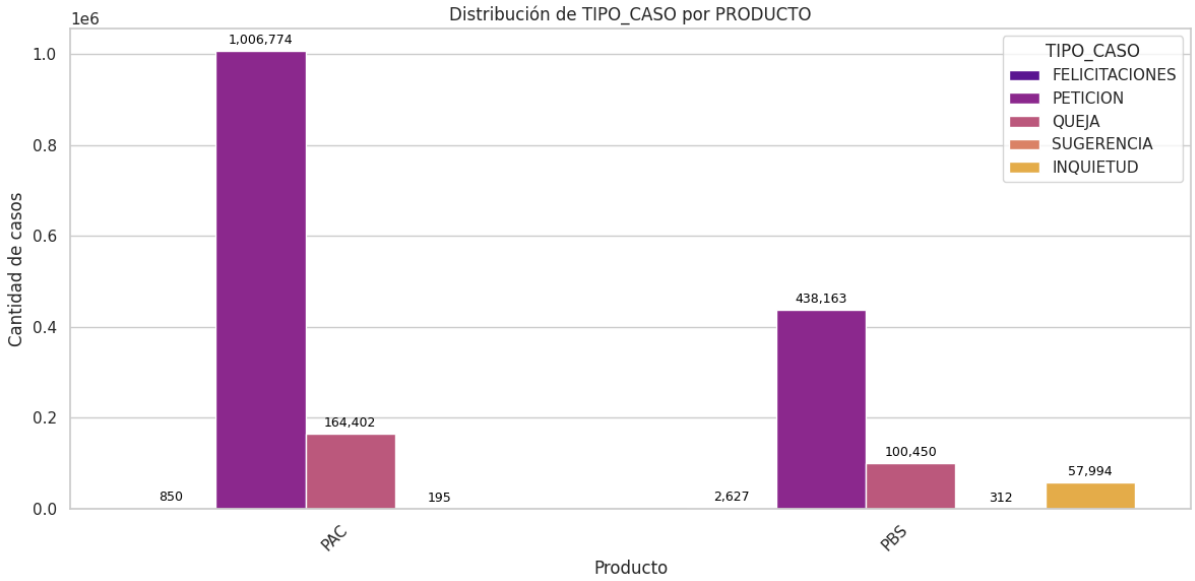

Ilustración 6.3.12 – Grafico Distribución Tipo_Caso por Tipo de Producto

6.3.3 Base de Consumos Médicos (df_consumos)

Finalmente, para dimensionar el valor real percibido por el afiliado, se integró la Base de Consumos Médicos, la cual consolida un total de 7,882,101 registros, permitiendo medir la frecuencia y tipología de uso. Esta base se segmenta en consumos del Plan Básico de Salud (PBS, con 7,228,183 registros) y del Plan Complementario (PAC, con 653,918 registros).

Al analizar la distribución, se evidencia una asimetría significativa: los consumos del PAC representan apenas el 9 % del volumen del PBS, lo que dificulta una diferenciación directa basada solo en volumen. Sin embargo, la traza del PBS resulta fundamental para determinar el nivel de actividad general del paciente. En este sentido, la categoría predominante es Medicamentos, que concentra la mayor recurrencia mensual, seguida por Gastos Misceláneos y Atención Domiciliaria Básica.

Esta estructura de datos es clave para inferir patrones de riesgo: una alta actividad en PBS contrastada con un bajo uso del PAC sugiere una subutilización del servicio premium (riesgo de cancelación), mientras que un consumo elevado en ambos frentes caracteriza a pacientes con condiciones de salud complejas y, por ende, mayor adherencia.

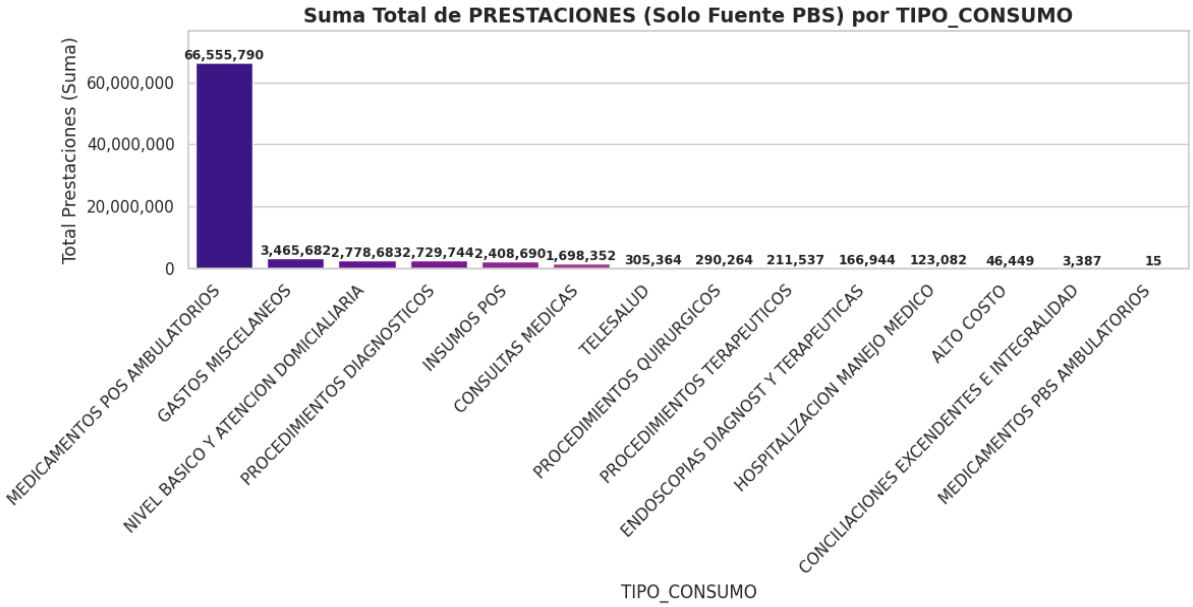

Ilustración 6.3.13 – Grafico Distribución Tipo_Consumo

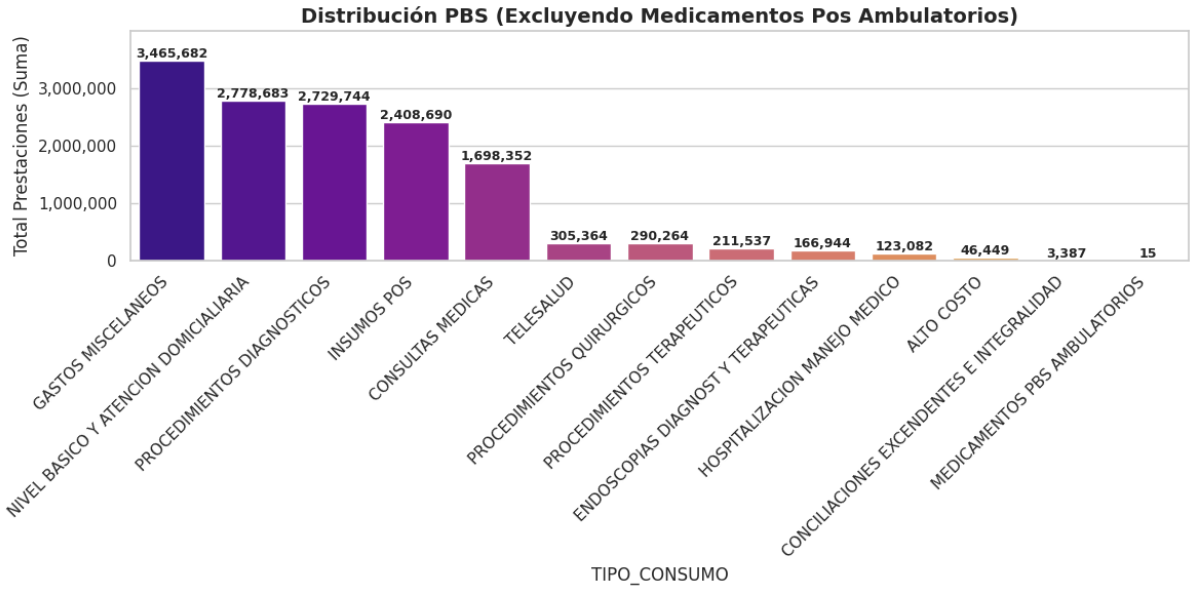

Ilustración 6.3.14 – Grafico Distribución Tipo_Consumo con Exclusión

Al profundizar en la base del Plan Complementario (PAC), se evidencia una marcada homogeneidad en la tipología de consumo: el 99 % de las transacciones corresponde a la modalidad "Consulta Acceso Directo PAC". Si bien esta concentración limita la granularidad para describir qué tipo de servicio específico se utiliza, la variable resulta fundamental como indicador de intensidad. Por tanto, el análisis se centrará en la frecuencia de uso para clasificar a los pacientes,

permitiendo distinguir eficazmente entre perfiles de subutilización y usuarios de alto consumo.

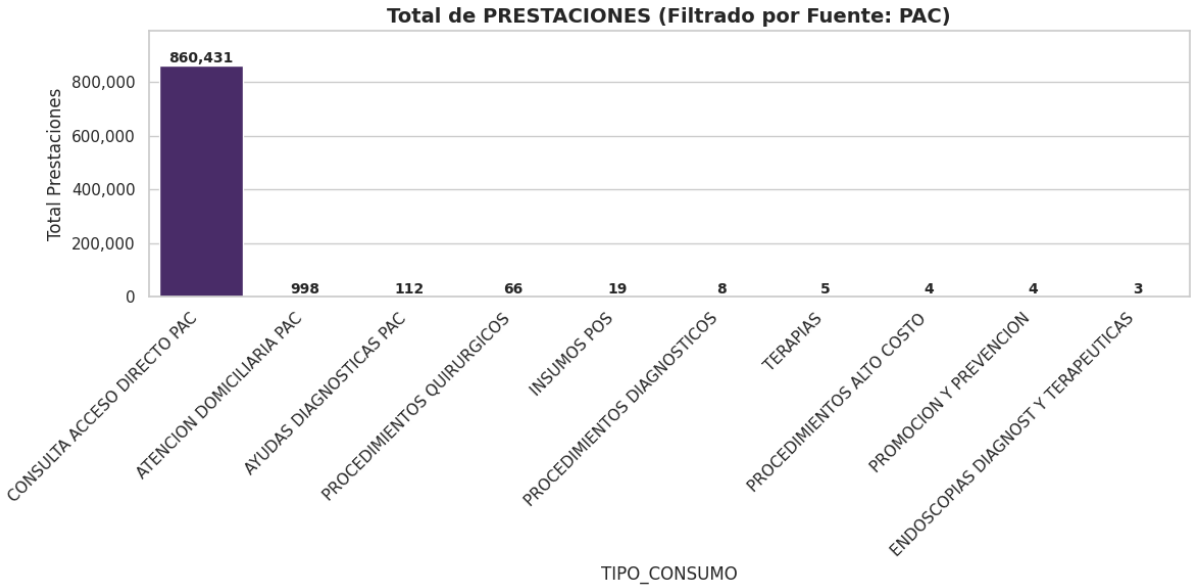

Ilustración 6.3.15 – Grafico Distribución Prestaciones para PAC

Por otra parte, el análisis de la serie temporal revela una dinámica de uso altamente sensible al contexto sanitario global. Se identifica una tendencia de crecimiento sostenido entre los años 2018 y 2020, interrumpida por las restricciones de aislamiento. Posteriormente, se observa un "efecto rebote" tras la apertura, escalando hasta alcanzar los niveles máximos de utilización histórica en el año 2022. Sin embargo, el hallazgo más crítico para el modelo de fuga se presenta en el último periodo: para el cierre de 2024, la curva de uso exhibe una desaceleración y caída notable.

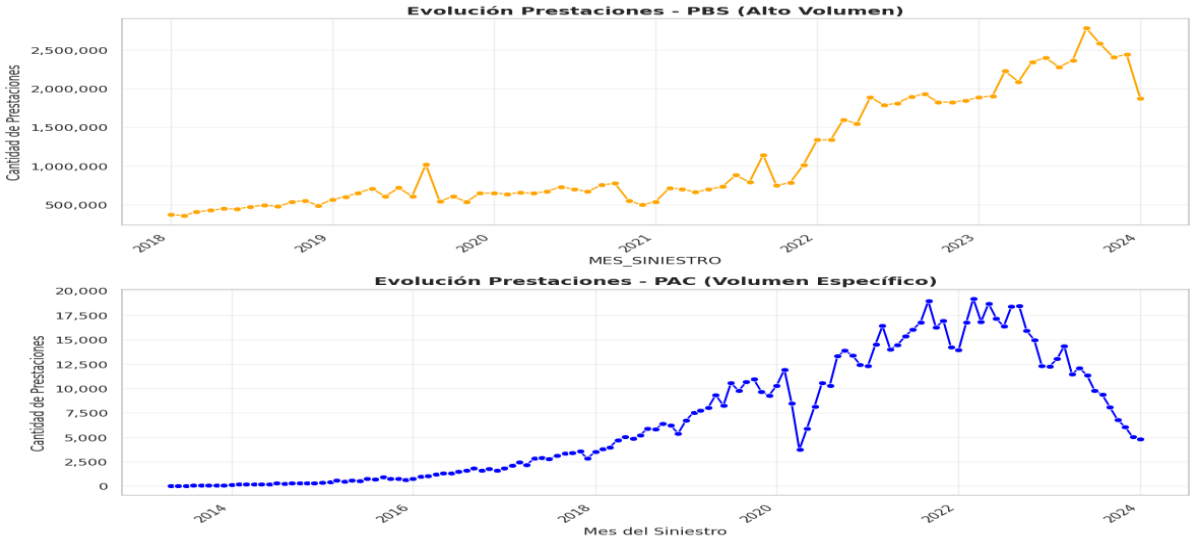

Ilustración 6.3.16 – Grafico Evolución Prestaciones para PAC y PBS

6.3.4 Análisis Exploratorio de Datos (EDA) y Hallazgos Clave

El presente análisis exploratorio trascendió la estadística descriptiva tradicional para orientarse hacia la inferencia del comportamiento de fuga, revelando cuatro hallazgos sistémicos fundamentales que cimentan la estrategia de modelado.

Metodológicamente, el primer paso consistió en evaluar la tasa de cancelación en función de variables estratégicas, con el fin de identificar predictores claves. Este indicador se calculó considerando la relación entre el total de pacientes cancelados respecto a la población total (pacientes cancelados / total de pacientes).

Como punto de partida para el diagnóstico de fuga, se evaluó el comportamiento de la tasa de cancelación desagregada por variables clínicas y comportamentales, revelando patrones estructurales que definen el perfil del usuario desertor.

En primera instancia, los indicadores de salud (gráficos superiores) evidencian una tendencia clara de selección adversa: existe una relación inversa entre la carga de enfermedad y la probabilidad de salida. Los usuarios más sanos (CONDICION_SALUD Baja) presentan la tasa de cancelación más alta (51.2 %), comportamiento que se replica en los usuarios sin patologías de Alto Costo (MARCA_CAC No: 47.7 %), mientras que los pacientes de mayor complejidad médica tienden a permanecer en el programa (tasa de 25.6 % en Salud Alta).

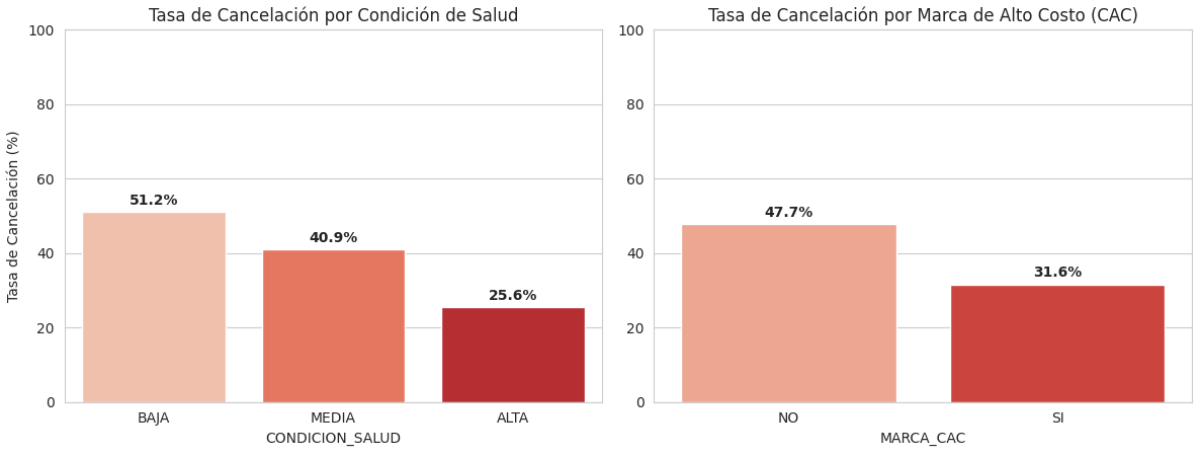

Ilustración 6.3.17 – Tasas de Cancelación por Factores de Riesgo

Por otro lado, el análisis comportamental (gráficos inferiores) expone puntos críticos de fricción en la experiencia. Se destaca un quiebre dramático en la variable de Uso, donde la tasa se dispara al 98.5 % tras la primera prestación, sugiriendo una experiencia inicial fallida. Paralelamente, el análisis de Quejas identifica al "cliente silencioso" (0 quejas) como un segmento de alto riesgo (40.7 %), superando incluso a los usuarios con un nivel medio de reclamos, lo que indica que la ausencia de interacción o feedback es un predictor de apatía y posterior abandono.

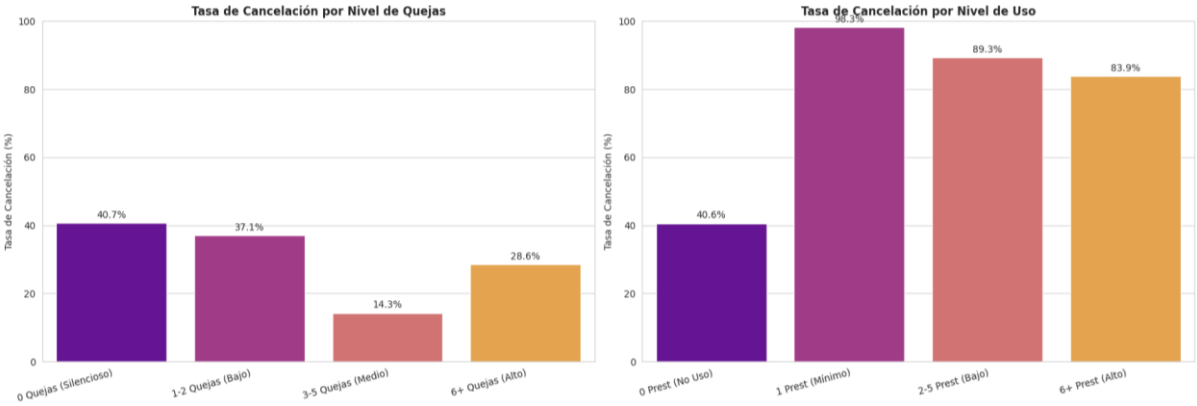

Ilustración 6.3.18 – Análisis de Churn de Usos vs Quejas

Hallazgo 1: El Riesgo en el Ramo Familiar y la Fricción Temprana

Al analizar la tasa de cancelación cruzando las variables de Nivel de Uso y Ramo, se detectó un comportamiento crítico en el Ramo Familiar, segmento caracterizado por la decisión de pago individual mensual.

El análisis sugiere que la permanencia no es homogénea. La complejidad sistémica reside en que el tipo de Ramo (Familiar vs. Colectivo) define la estabilidad del ingreso, factor que impacta la permanencia más allá del uso individual del servicio.

- **Insight Sistémico:** La estabilidad del Ramo Colectivo amortigua el *churn* (fuga) incluso ante niveles bajos de uso, debido a que la empresa asume el costo o realiza el descuento automáticamente.
- **Foco de Riesgo:** La vulnerabilidad se concentra en el Ramo Familiar, donde el afiliado debe ratificar su decisión de pago mes a mes.

Análisis de Riesgo por Ciclo de Vida del PAC (Permanencia por Ramo)

El objetivo de este apartado es aislar el riesgo sistémico derivado de la inestabilidad de ingresos. Se busca determinar si la cancelación impulsada por la desconexión (bajo o nulo uso) se intensifica en el Ramo Familiar en comparación con la estabilidad del Ramo Colectivo.

Objetivo Específico: Aislar el riesgo en el segmento donde el cliente paga individualmente para verificar si la cancelación por "No Uso" actúa como un acelerador de la fuga.

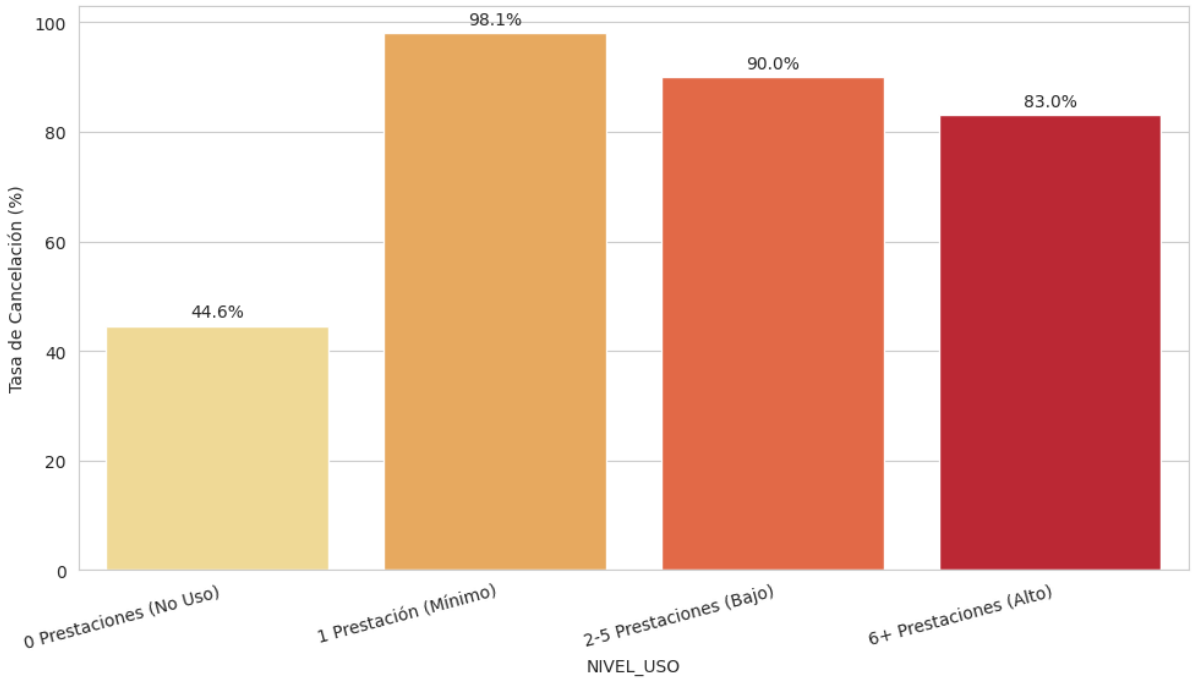

Ilustración 6.3.19 – Tasas de Cancelación en Ramo Familiar por nivel de uso

Nivel de Uso	Tasa de Cancelación	Análisis de Riesgo
0 prestaciones (No Uso)	**44.6 %**	**Línea base de riesgo.** Similar a la tasa general. El cliente cancela por precio o desinterés al no percibir valor inmediato.
1 prestación (Mínimo)	**98.1 %**	**Máximo riesgo de Churn.** La tasa se dispara dramáticamente. El cliente intentó usar el servicio una sola vez y la experiencia fue tan negativa que más del 90 % de ese grupo canceló.
2-5 prestaciones (Bajo)	**90.0 %**	**Riesgo Crítico.** La tasa se mantiene en niveles alarmantes, indicando que las frustraciones iniciales persisten durante el uso temprano.
+6 prestaciones (Alto)	**83.0 %**	**Persistencia del Riesgo.** Contrario a las expectativas, el alto uso no reduce significativamente la tasa en este segmento, sugiriendo una fricción constante en el servicio.

Tabla 6.4 - Desglose de Causas de Cancelación en Clientes de Salud Baja

La interpretación del análisis de la tasa de cancelación en el ramo familiar por nivel de uso no solo confirma la tendencia general, sino que permite identificar el punto crítico en la experiencia del cliente. El patrón observado no sigue una progresión lineal, sino que evidencia un quiebre abrupto y significativo.

En el segmento de clientes del ramo familiar con cero usos, el riesgo de cancelación alcanza un nivel alto, cercano al 45 %, lo que se asocia principalmente al costo de oportunidad. Por otro lado, en el grupo que registra un único uso, el riesgo se eleva a un nivel inaceptable, con una tasa aproximada del 98 %. Este comportamiento sugiere que el sistema tiende a expulsar a los clientes más vulnerables tras su primera interacción, lo que constituye un hallazgo crítico para la gestión de la experiencia.

Como conclusión preliminar, se observa que la inestabilidad del pago individual no constituye el único factor de riesgo, sino que actúa como un catalizador de fuga cuando se combina con fricciones operacionales. La evidencia de una tasa de

cancelación del 98,08 % en el primer uso indica que la fricción administrativa emerge como un detonante de salida más potente que el precio en esta etapa temprana del ciclo de vida del cliente.

Hallazgo 2: Disonancia de Valor (Cliente Sano y Quejumbroso vs. Churn)

Se procedió a aislar el comportamiento de los clientes clasificados con CONDICION_SALUD = BAJA, quienes representan el segmento más rentable debido a su baja siniestralidad. La complejidad analítica radica en la disonancia, un cliente que presenta una queja es un cliente que invierte recursos, como tiempo y energía, en el PAC. Si el cliente es sano y se queja (por ejemplo, CONDICION_SALUD = BAJA y NIVEL_QUEJAS = ALTO), la cancelación no se explica por la calidad médica, ya que no la ha utilizado, sino por la fricción en los procesos de soporte, como autorizaciones, agendamiento o cobros.

El objetivo específico es determinar si los clientes más rentables (salud baja) cancelan por causas atribuibles a la gestión, como peticiones del cliente, o por incapacidad económica, reflejada en la mora. Este hallazgo es crucial para desenmascarar la complejidad de las cancelaciones. El análisis demuestra que la problemática en el segmento sano responde a un equilibrio delicado entre la fricción económica y la fricción operativa.

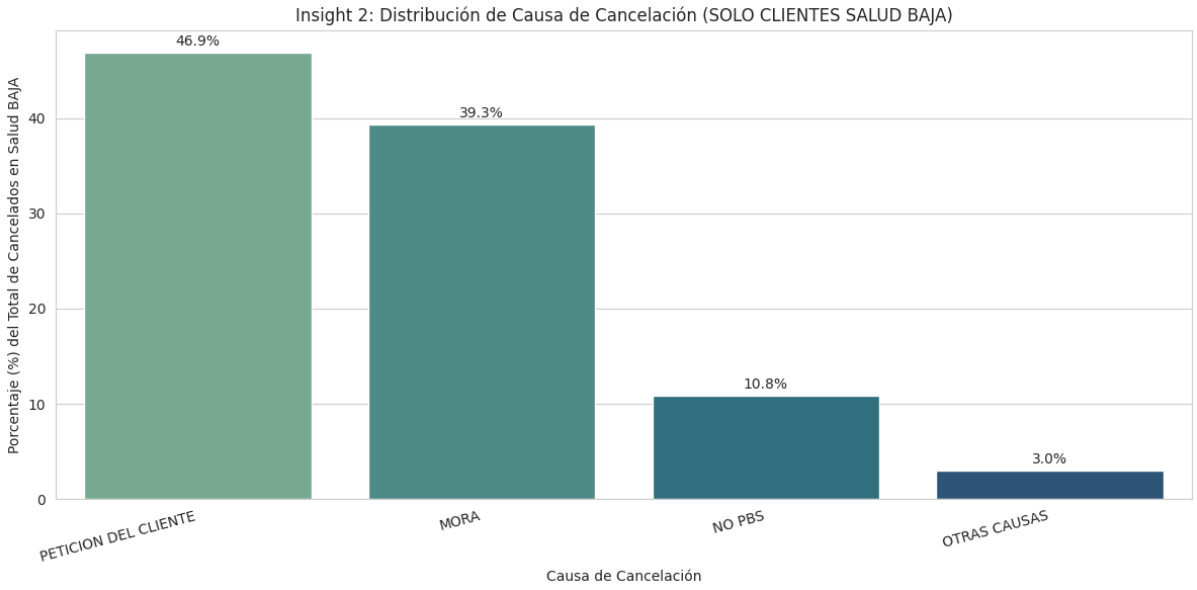

Ilustración 6.3.20 – Distribución de Causa de Cancelación para clientes de Salud Baja

Causa de cancelación	Tasa de Cancelación	Análisis de la Complejidad
Petición del cliente	**46.9 %**	**Fricción Operativa / Valor.** Representa un problema de experiencia. Dado el perfil saludable del cliente, esta "petición" obedece raramente a fallas médicas y mayoritariamente a barreras administrativas o falta de valor percibido ("ya no me interesa").
Mora	**39.3 %**	**Fricción Económica.** Refleja un problema de precio/ingreso. Cerca de la mitad de los clientes sanos cancela por inviabilidad de pago, reforzando la percepción del PAC como un gasto no esencial.
No PBS	**10.8 %**	**Fricción Regulatoria.** Corresponde a cancelaciones automáticas por pérdida de cobertura de salud básica, constituyendo un factor externo y sistémico.

Tabla 6.5 - Desglose de Causas de Cancelación en Clientes de Salud Baja

El riesgo de cancelación en el cliente sano se divide casi simétricamente, un 43 % es sensible a factores económicos (precio/ingreso) y un 47 % es sensible a la calidad de la interacción o propuesta de valor. El problema no es unidimensional, sino que ambas fuerzas operan simultáneamente.

El Mecanismo de Salida por Fricción se percibe de manera evidente al integrar el Hallazgo 1 con el Hallazgo 2 y se configura el siguiente escenario de fuga: El cliente de *Salud Baja* en *Ramo Familiar* percibe inicialmente el PAC como un gasto no esencial (riesgo de Mora). Al intentar utilizar el servicio por primera vez, se enfrenta a fallas administrativas (riesgo de 1 Uso con 98 % de Churn), lo que precipita su salida bajo la causal de Petición del Cliente.

La conclusión del hallazgo permite ver una falla estructural en los procesos de *back-office* que resulta en la expulsión de los clientes más rentables (sanos y de bajo uso), mientras el sistema retiene a los perfiles más costosos. La experiencia administrativa podría estar erosionando el valor del producto médico.

Hallazgo 3: Riesgo de Abandono vs. Propuesta de Valor (PLAN)

El riesgo de cancelación presenta una relación directa con la percepción de incumplimiento de la promesa de valor. En este contexto, se examina si las primas elevadas asociadas a los planes premium, cuando no se traducen en un uso tangible, son interpretadas por los afiliados como una inversión ineficiente que acelera la decisión de retiro.

Este riesgo se intensifica cuando el precio pagado no se corresponde con beneficios percibidos. Los planes de alta gama, como Oro y Diamante, generan expectativas superiores y, por consiguiente, la ausencia total de prestaciones en clientes de estas categorías tiende a incrementar la sensación de desperdicio financiero, lo que eleva su propensión a la fuga.

El objetivo específico de este análisis consiste en determinar si la falta de uso en planes premium incrementa el riesgo de abandono en mayor medida que en planes básicos. Para ello, se evalúa la tasa de cancelación exclusivamente en el grupo de afiliados con cero usos, con el fin de aislar el efecto del precio sobre la percepción de valor.

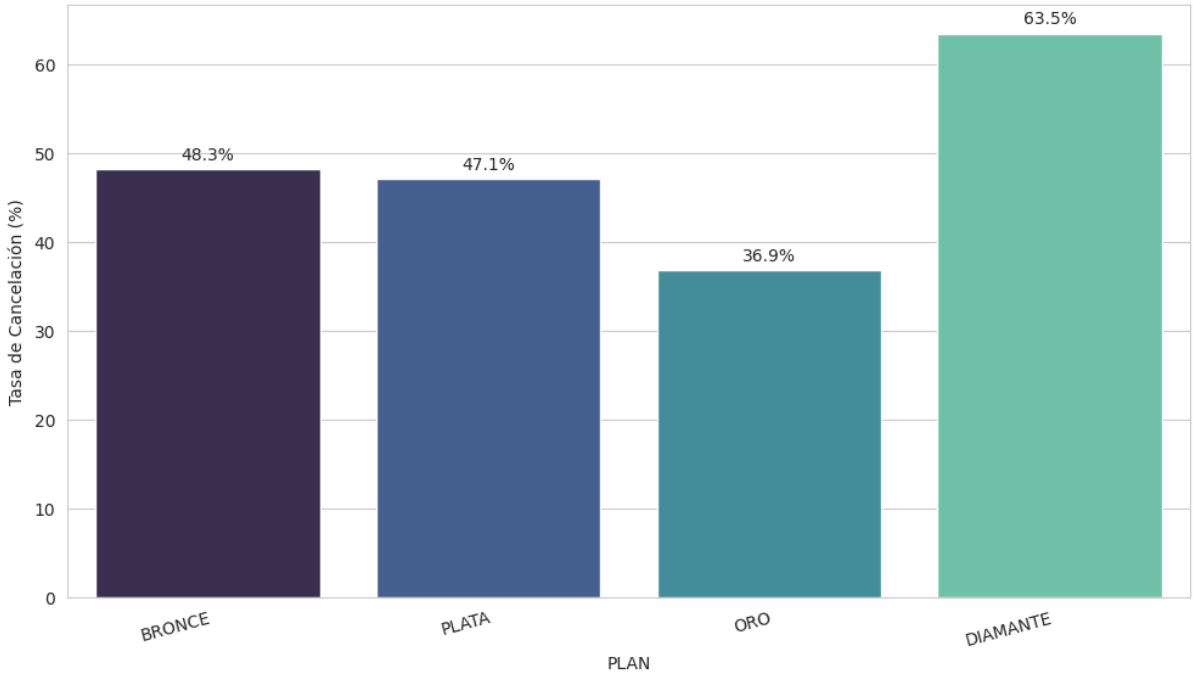

Ilustración 6.3.21 – Tasas de Cancelación en Cero Uso por Tipo de Plan

Plan	Tasa de Cancelación	Análisis de Riesgo Condicionado
Bronce	**48.3 %**	**Riesgo Alto.** A pesar de ser el plan de menor costo, el riesgo de salida permanece elevado ante la ausencia de uso.
Plata	**47.1 %**	**Riesgo Alto.** Presenta una tasa similar al Bronce. El costo incremental no parece influir significativamente si la utilidad percibida es nula.
Oro	**36.9 %**	**Riesgo Medio (Anomalía Protectora).** El riesgo es notablemente inferior a los planes básicos. Esto sugiere que el Plan Oro genera una mayor percepción de valor latente o seguridad, actuando como un punto de equilibrio incluso sin uso tangible.
Diamante	**63.5 %**	**Máximo Riesgo de Abandono.** Representa la tasa más alta del grupo. El cliente del plan más costoso es quien cancela con mayor celeridad si no utiliza el servicio.

Tabla 6.6- Análisis de Riesgo Condicionado por Tipo de Plan (Grupo Cero Uso)

- **La Prima Alta Acelera la Percepción de Desperdicio:** La causa principal de churn en la gama alta (sin uso) es la sensación de ineficiencia en el gasto. El cliente Diamante (63.5 % de fuga) penaliza el no uso mucho más rápido que el cliente Oro (36.9 %).
- **El Plan Oro como Punto de Retención:** El Plan Oro demuestra una resiliencia particular, actuando como un "punto dulce" (sweet spot) entre precio y valor percibido, donde el afiliado mantiene la suscripción por la promesa de cobertura, a diferencia del usuario Diamante que exige tangibilidad inmediata.

6.4. Consideraciones

Este proyecto se adhiere a un conjunto de consideraciones fundamentales para garantizar la integridad del análisis y la protección de la información, enmarcadas en los siguientes pilares:

6.4.1 Consideraciones Éticas

El proyecto emplea la información exclusivamente con dos fines: la investigación académica y la identificación de oportunidades para la mejora del servicio. Se establece el compromiso ético de evitar interpretaciones o conclusiones que puedan generar sesgos, discriminación o segmentación negativa de los afiliados. El uso de datos anónimos garantiza que el enfoque se mantenga en los patrones de comportamiento y no en los individuos.

6.4.2 Consideraciones Legales y de Privacidad

El tratamiento de la información cumple rigurosamente con la **Ley Estatutaria 1581 de 2012** (Régimen General de Protección de Datos Personales en Colombia). La viabilidad legal del proyecto se sustenta en dos hechos clave:

- **Anonimización:** Todas las bases de datos internas han sido completamente anonimizadas.
- **No Trazabilidad:** El identificador interno utilizado (ID_AFILIADO) es un código disociado que no permite rastrear ni revertir el proceso para identificar la identidad real del paciente.

6.4.3 Consideraciones de Seguridad de la Información

Para garantizar la custodia de los datos, se aplican controles de seguridad estrictos. La información será almacenada en **entornos controlados** y el acceso estará **restringido** únicamente a los investigadores autorizados por el Product Owner del proyecto. Se utilizarán mecanismos de **cifrado de datos** tanto en tránsito (durante la transmisión) como en reposo (durante el almacenamiento), asegurando una estrategia activa para minimizar cualquier riesgo de exposición, fuga o pérdida de datos.

El conjunto de estas medidas éticas, legales y técnicas asegura que el análisis cumpla cabalmente con los principios de **legalidad, confidencialidad y transparencia**, protegiendo tanto a los afiliados como a la organización.

7. Técnicas Analíticas

7.1. Técnicas Alternativas

¿Qué es el Churn?

La figura 7.1 adaptada de Gold (2020), ilustra el fenómeno de pérdida de clientes (churn) en servicios de suscripción. Los dos círculos representan el universo de suscriptores en dos momentos distintos: el círculo superior corresponde al estado inicial y el inferior al estado final. El área de cada círculo puede reflejar tanto la cantidad de suscriptores como el monto total que estos pagan, dependiendo del enfoque del análisis.

La media luna descendente en la parte superior representa el churn, aquellos suscriptores que estaban inicialmente pero que ya no permanecen en el servicio. La superposición entre ambos círculos indica los clientes retenidos, mientras que la media luna ascendente en la parte inferior del círculo final representa los nuevos suscriptores adquiridos.

Este diagrama permite visualizar de forma intuitiva cómo se distribuyen los flujos de entrada, permanencia y salida de clientes, facilitando el análisis de estrategias de retención y adquisición. Aunque los círculos no siempre tienen el mismo tamaño, el concepto de pérdida, conservación y ganancia de clientes se mantiene como eje central.

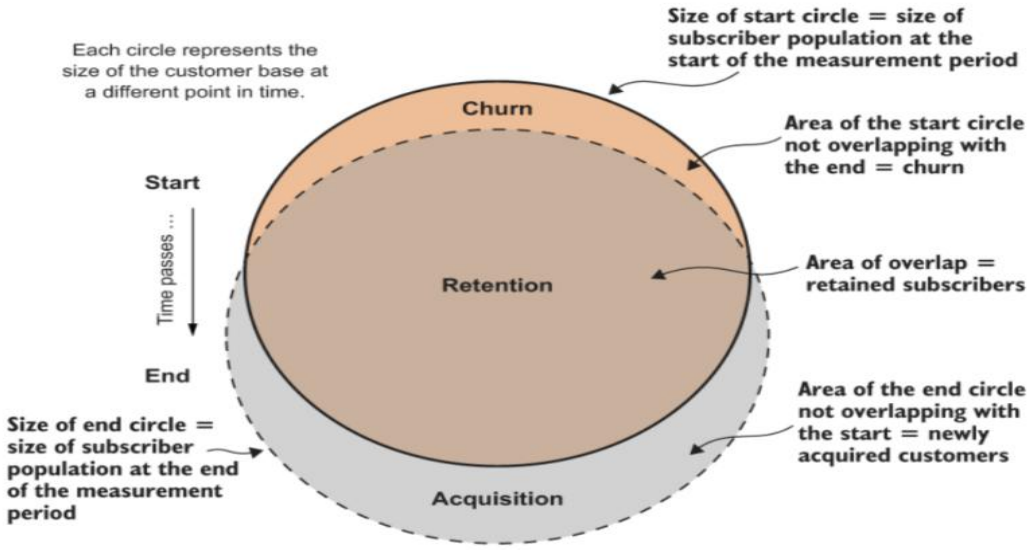

Ilustración 7.1 *– Explicación sobre el Churn*

7.1.1. Datos Requeridos

La literatura especializada en churn en seguros de salud destaca que la calidad y diversidad de los datos disponibles es un factor crítico para el éxito de los modelos predictivos. Galvis (2023), en su aplicación del modelo CRISP-DM, identifica 14 variables relevantes extraídas de ***bases internas de clientes***, ***productos*** y ***transacciones***. Estas incluyen ***variables numéricas como edad, número de seguros, valor de la prima, saldo en cuentas y variables categóricas como género, estado civil, ocupación y segmento comercial***. La exclusión de identificadores personales y la limpieza de registros incompletos son parte del proceso de preparación de datos evidentemente, lo que permite construir modelos como Random Forest, XGBoost y regresión logística con mayor precisión. Además, se enfatiza la importancia de escalar variables numéricas y codificar las categóricas para facilitar su procesamiento por algoritmos de machine learning.

Otros estudios complementan esta misma visión. Trallice (2019) incorpora ***datos bancarios y aseguradores*** para distinguir entre bajas voluntarias e involuntarias de manera precisa, aplicando técnicas de ingeniería de variables y validación cruzada. Su modelo LightGBM se alimenta de ***variables temporales*** que permiten anticipar el comportamiento del cliente en función de su historial. Donado (2022), en el contexto de tasas de siniestralidad, destaca la relevancia de variables como ***actos médicos*** y ***prima pagada***, que no solo permiten predecir el riesgo, sino también personalizar tarifas en tiempo real. Morillo (2023) introduce el análisis de supervivencia con técnicas como Kaplan-Meier y GBSA, que requieren ***datos longitudinales*** para estimar el tiempo hasta la cancelación. Estos enfoques muestran que los datos temporales y de comportamiento son esenciales para modelos más sofisticados que no solo predicen si un cliente se irá, sino cuándo.

Finalmente, Ospina (2022) aporta una perspectiva operativa al utilizar herramientas de inteligencia de negocios para caracterizar usuarios según ***variables demográficas***, ***generacionales, contractuales y geográficas***. Su estudio revela que los planes económicos y ciertas regiones presentan mayor deserción, lo que sugiere que los datos de ubicación y ***tipo de contrato*** también son relevantes para segmentar clientes y diseñar estrategias de retención. En conjunto, estos estudios evidencian que los problemas de churn requieren una arquitectura de datos que integre ***variables estructuradas*** (sociodemográficas, financieras, contractuales) y ***no estructuradas*** (comportamiento, interacción), procesadas con rigor técnico para alimentar modelos predictivos robustos y accionables.

Para la realización de este proyecto contamos con un conjunto de datos (mencionados en el capítulo “Disponibilidad de Datos”) que, según la literatura especializada anterior, constituyen un insumo correcto y robusto para abordar

estudios de predicción de churn en seguros de salud. Las bases de datos disponibles (Permanencia, PQRS y Consumos Médico) integran variables estructuradas y temporales que han demostrado ser relevantes en las investigaciones previas. La base de permanencia que incluye atributos sociodemográficos (edad, sexo, nivel de ingreso, estado civil), contractuales (tipo de plan, ramo, tipo de IPS), geográficos (sede) y clínicos (condición de salud, siniestralidad), además de información sobre la causa de cancelación. La base de PQRS aporta señales de insatisfacción o fricción a través del historial de peticiones, quejas y reclamos, mientras que la base de consumos médicos permite captar patrones de uso del servicio mediante variables como categoría, subcategoría y frecuencia mensual. Esta arquitectura de datos, al combinar información longitudinal, conductual y contextual, se alinea claramente con los requerimientos metodológicos descritos en estudios como los de Galvis (2023), Trallice (2019) y Morillo (2023) y proporciona una base sólida para el desarrollo de modelos predictivos accionables y segmentaciones estratégicas.

7.1.2. Métodos y Técnicas

La gestión del churn o fuga de clientes en el sector asegurador, específicamente en seguros de salud, ha cobrado relevancia en los últimos años debido a su impacto directo en la rentabilidad de las empresas. En el contexto colombiano, las Entidades Promotoras de Salud (EPS) enfrentan el complejo reto de retener a sus clientes más rentables, tal como acotamos específicamente dentro de los Planes de atención complementaria (PAC). En el marco del presente proyecto, sabemos que la EPS ABC presenta una tasa de fuga cinco veces mayor de clientes rentables que la de no rentables. A continuación, se presenta una revisión de estudios relevantes sobre la medición del churn, su predicción mediante modelos analíticos y la segmentación de clientes como otro camino importante dentro de las estrategias de retención.

Antes de presentar los modelos usualmente utilizados dentro de los estudios que tienen relación al churn en seguros, es necesario tener en cuenta que la elección del enfoque analítico depende de los tipos de datos disponibles, el grado de desbalance entre clases y los objetivos específicos del negocio. En contextos como el asegurador, donde la cancelación voluntaria puede implicar pérdidas significativas, se privilegian modelos que combinen capacidad predictiva con interpretabilidad. A continuación, se describen los algoritmos más empleados en la literatura especializada:

- Árboles de Decisión y Random Forest: valorados por su interpretabilidad y robustez. (Groll, Wasserfuhr & Zeldin, 2022)
- Regresión Logística: ampliamente usada en seguros por su simplicidad y capacidad explicativa.

- Máquinas de Soporte Vectorial (SVM): eficaces en contextos con alta dimensionalidad.
- XGBoost: destaca por su rendimiento en competiciones de modelado predictivo. Khandelwal y Sakalle (2025)
- Redes Neuronales: Utilizadas en los estudios de Hu (2020), Bolance et al. (2016) y Sundarkumar et al. (2015) para capturar patrones complejos no lineales en el comportamiento de cancelación.
- MARS (Multivariate Adaptive Regression Splines): Aplicado por Donado (2022) en la predicción de siniestralidad, destacando por su capacidad de modelar relaciones no lineales con alta precisión.
- LightGBM (Light Gradient Boosting Machine): Usado por Trallice (2019) para predecir churn en seguros de vida, con resultados destacados en métricas como GINI.
- Gradient Boosting Survival Analysis (GBSA): Implementado por Morillo (2023) para estimar el tiempo hasta la fuga de clientes, combinando análisis de supervivencia con boosting.
- Kaplan-Meier: Técnica estadística clásica utilizada por Morillo (2023) para análisis de supervivencia, útil para estimar la probabilidad de retención en función del tiempo.

Galvis (2023) recopila diversos estudios han abordado la predicción de cancelación en seguros desde enfoques comparativos y multi-algoritmo, buscando mejorar la precisión en la identificación de clientes propensos a desertar. Un ejemplo de ello es el trabajo de Hu (2020), quien propone un modelo combinado basado en árboles de decisión y redes neuronales, aplicado a datos del sector minorista, aunque sin incluir análisis comparativos con otros métodos.

En el ámbito asegurador, Gunther et al. (2014) emplean regresión logística sobre datos mensuales de clientes, destacando la riqueza temporal de la información, pero sin contrastar su desempeño con otros algoritmos. Por otro lado, Bolance, Guillen y Padilla-Barreto (2016) desarrollan un estudio en seguros de automóviles que compara directamente cuatro técnicas: árboles de decisión, redes neuronales, regresión logística y máquinas de soporte vectorial. Finalmente, Sundarkumar, Ravi y Siddeshwar (2015) aplican cinco métodos de clasificación, incluyendo SVM y redes neuronales, en un análisis que abarca tanto la predicción de cancelación como la detección de fraude, evidenciando la versatilidad de estos modelos en distintos contextos del sector asegurador, lo que refuerza la aplicabilidad de estas técnicas en el contexto colombiano de la EPS ABC.

Galvis, además, presenta una estructura de su modelo predictivo siguiendo la metodología CRISP-DM, ampliamente aceptada en minería de datos, que incluye las siguientes fases:

- Comprensión del negocio: Se analiza el contexto competitivo del sector asegurador, identificando que la cancelación voluntaria representa una pérdida significativa de ingresos. En el caso actual, esto se traduce en la fuga de afiliados rentables del PAC.
- Comprensión de los datos: Se extraen variables relevantes desde bases de clientes, productos y transacciones. En el estudio de Galvis, tal como se menciona en la sección 7.1, se utilizan 14 variables (9 numéricas y 5 categóricas), excluyendo identificadores personales por irrelevancia predictiva.
- Preparación de los datos: Incluye limpieza, codificación de variables categóricas y escalamiento de variables numéricas. Se descartan registros incompletos y se ajustan los datos para evitar sesgos.
- Modelamiento: Se aplican siete algoritmos de clasificación binaria, evaluando su desempeño mediante validación cruzada (k-folds) y métricas como ROC-AUC, F1 Score y Recall. El modelo Random Forest obtuvo el mejor desempeño predictivo.
- Evaluación: Se selecciona el modelo óptimo y se ajusta el umbral de decisión para maximizar el recall, priorizando la identificación de clientes con alta probabilidad de cancelación.
- Despliegue: Se propone una estrategia de segmentación por propensión al churn, orientada a campañas de retención proactiva mediante contact center.

Un enfoque como el presentado anteriormente podría adaptarse directamente al contexto de los PAC de nuestra EPS ABC, utilizando las bases que tenemos de Permanencia, PQRS y Consumos.

Gregory (2018) presenta una aplicación de XGBoost para la predicción de churn en servicios de suscripción, utilizando datos temporales de comportamiento del cliente. Aunque el estudio se basa en la plataforma KKBOX, sus hallazgos son directamente extrapolables a contextos como salud y seguros, donde la cancelación de servicios responde a patrones longitudinales y eventos poco frecuentes. Se destaca que XGBoost, al incorporar ingeniería de características sensibles al tiempo, logra una alta capacidad de discriminación en escenarios con desbalance de clases.

Trallice (2019), por otra parte, desarrolla un modelo predictivo de churn en seguros de vida utilizando el modelo LightGBM, basado en datos bancarios y aseguradores. El estudio hace una clara distinción entre bajas voluntarias e involuntarias, optimizando modelos separados para cada caso. Se aplican técnicas de ingeniería de variables, validación cruzada y ajuste de hiper parámetros mediante random search. El modelo para bajas involuntarias alcanza un GINI de 82.2 %, mientras que

el de voluntarias llega a 32.76 %. Se destaca la importancia de la ventana temporal para la predicción y la utilidad de los modelos para focalizar campañas de retención, mejorando la eficiencia operativa y financiera de la aseguradora.

Modelos de Predicción de Siniestralidad

Además de los modelos orientados a predecir directamente la cancelación de los clientes, la literatura especializada en seguros de salud también ha explorado enfoques centrados en la predicción de siniestralidad, con el objetivo de optimizar la rentabilidad de los planes ofrecidos. Estos estudios permiten ajustar tarifas, personalizar coberturas y mejorar la eficiencia operativa de las aseguradoras.

Donado (2022) aplica modelos de Machine Learning para predecir la siniestralidad en seguros de salud, utilizando datos reales de una aseguradora española. Compara cuatro enfoques: regresión lineal generalizada, MARS, Random Forest y SVM, concluyendo que MARS ofrece la mejor capacidad predictiva. ***El estudio destaca la importancia de variables como actos médicos y prima pagada*** y subraya el potencial de ML para personalizar tarifas en tiempo real. Además, aborda desafíos éticos y regulatorios en el uso de datos sensibles. El trabajo propone avanzar hacia modelos más complejos como LightGBM y enriquecer la tarificación con nuevas variables conductuales. Este tipo de análisis complementa los modelos de churn al ofrecer una visión integral del riesgo y la rentabilidad por cliente.

Segmentación de Clientes en Seguros de Salud

Además de los enfoques orientados a la predicción de cancelación y siniestralidad, la literatura sobre seguros también ha desarrollado modelos enfocados únicamente en la segmentación de clientes, con el fin de caracterizar perfiles, identificar patrones de comportamiento y orientar decisiones estratégicas. Estos estudios permiten entender mejor las dinámicas de uso, abandono y fidelización según variables demográficas, contractuales y geográficas.

Ospina (2022) desarrolla un modelo de inteligencia de negocios para caracterizar usuarios de salud en una aseguradora colombiana, utilizando Power BI sobre datos internos. El estudio identifica patrones demográficos, generacionales y contractuales y analiza el churn por plan, región y causal. Se concluye que los planes económicos presentan mayor deserción, mientras que los contratos familiares y zonas específicas como el sur tienen indicadores críticos. La herramienta analítica permitió mejorar la calidad de datos, optimizar reportes y orientar decisiones estratégicas basadas en datos, incluyendo ajustes tarifarios, segmentación de usuarios y propuestas de mejora en red médica y gestión comercial.

Morillo (2023) desarrolla un modelo de análisis de supervivencia para predecir la pérdida de clientes en seguros, integrándolo en la plataforma de la insurtech Zelros. Utiliza técnicas como Kaplan-Meier y modelos avanzados como Gradient Boosting Survival Analysis (GBSA), priorizando la estimación del tiempo hasta la fuga y la segmentación por riesgo. La solución mejora la precisión predictiva, reduce costos de adquisición y fortalece la fidelización, posicionando a Zelros como líder en IA aplicada al sector asegurador.

La literatura revisada muestra una evolución hacia modelos de gestión de seguros de salud basados en datos, con énfasis en la reducción de siniestralidad y la retención de clientes. Fernando Donado y Franco Trallice destacan el uso de modelos predictivos (Machine Learning y análisis de costos) para anticipar el gasto médico y entender los factores que presionan la siniestralidad, como la inflación y el comportamiento post-pandemia. María Ospina aporta una perspectiva más operativa, mostrando cómo la inteligencia de negocios permite caracterizar usuarios y diseñar estrategias de retención. Enrique Galvis, desde la medicina crítica, enfatiza la necesidad de integrar análisis clínico y financiero para mejorar la sostenibilidad del sistema. Finalmente, Jaime Morrillo plantea la importancia de la cobertura efectiva y personalizada como respuesta a las limitaciones del sistema tradicional. En conjunto, estos estudios refuerzan la necesidad de una gestión proactiva, segmentada y basada en evidencia para enfrentar los desafíos del aseguramiento en salud.

7.2. Herramientas

Además de los métodos analíticos utilizados para predecir el churn, la literatura también destaca herramientas las tecnológicas que permiten implementar, automatizar y escalar estos modelos en entornos productivos o de estudio. Por ejemplo, Morillo (2023) describe el uso de Apache Airflow para orquestar flujos de trabajo de predicción por lotes, Docker para empaquetar modelos en contenedores reproducibles y Kubernetes para escalar y gestionar dichos modelos en producción. Estas herramientas fueron utilizadas en la plataforma insurtech Zelros, donde se integró un modelo de análisis de supervivencia para campañas de retención personalizadas.

Por otro lado, tal como se menciona en la sección 7.2, Ospina (2022) emplea Power BI como herramienta de inteligencia de negocios para caracterizar usuarios de salud, analizar el churn por región y causal, y orientar decisiones estratégicas basadas en datos. Estas plataformas tecnológicas cumplen un rol fundamental en la operacionalización de los modelos, facilitando su integración con sistemas empresariales, su monitoreo continuo y su escalabilidad.

Por último, pese a que dentro de la literatura mencionada anteriormente, no se explicita el uso de Python y R, la inclusión de estos en el desarrollo del proyecto se justificaría por su amplio y claro soporte para algoritmos de machine learning y análisis estadístico, especialmente aquellos mencionados en la sección anterior (como Random Forest, XGBoost, LightGBM, SVM, redes neuronales, MARS, GBSA y Kaplan-Meier y SHAP), todos con implementaciones robustas en bibliotecas consolidadas como scikit-learn, xgboost, lightgbm y lifelines en Python y caret, mlr y survival en R.

Es ampliamente reconocido en la industria y académicamente que estos lenguajes son estándar en sectores como seguros, salud y finanzas. Además, plataformas especializadas como Zelros (Morillo, 2023), operan sobre entornos compatibles con Python. Finalmente, su integración con herramientas como Airflow, Docker y Power BI refuerza su utilidad práctica. Python facilita la automatización y el despliegue de modelos, mientras que R es especialmente valorado en contextos regulatorios y estadísticos, lo que lo convierte en un complemento natural para este tipo de análisis. (Pedregosa et al., 2011)

7.3. Selección

La selección de las técnicas analíticas para este proyecto se basará en cuatro criterios: idoneidad para el problema, disponibilidad y calidad de datos, eficacia técnica y utilidad operativa. En idoneidad, la combinación de datos tabulares, múltiples fuentes y censura, motiva boosting para clasificación dado por su alto rendimiento en datos tabulares y modelos de supervivencia para tiempo a evento como los modelos de Kaplan–Meier, Cox y RSF, que son estándar en análisis de permanencia. En disponibilidad y calidad de los datos, las cuatro bases permiten definir ventanas y cohortes reproducibles, y la calibración convierte scores en probabilidades accionables para dimensionar recursos de retención y estimar escenarios (Platt, 1999; Zadrozny & Elkan, 2002; Brier, 1950).

Con respecto al modelo base de predicción se opta por una combinación XGBoost + Regresión logística, estos algoritmos son bastante utilizados en estudios de churn, especialmente en sectores como seguros y telecomunicaciones. XGBoost por su parte, destaca por su alta precisión, eficiencia y su capacidad para manejar desbalance de clases (Kavlakoglu & Russi, 2024), mientras que la regresión logística aporta interpretabilidad, clave para decisiones de negocio. Esta combinación permite equilibrar performance y explicabilidad. Aunque existen alternativas como Random Forest, Redes Neuronales y SVM, se opta por estos modelos por su validación en literatura y su alineación con los objetivos del proyecto. En efecto, estudios recientes han demostrado que XGBoost supera a otros clasificadores en rendimiento, mientras que la regresión logística sigue siendo

preferida por su facilidad de implementación y capacidad explicativa en dominios financieros y de riesgo (Wang & Ni, 2019).

Aunque K-Means sigue siendo el más usado por su simplicidad, UMAP + HDBSCAN están ganando terreno en estudios recientes por su capacidad de manejar datos no lineales y sin necesidad de definir el número de clusters. Esta combinación es más robusta para datos complejos y de alta dimensionalidad como los del PAC. Se selecciona esta técnica porque no requiere suposiciones previas sobre la estructura de los datos y permite descubrir patrones más naturales en clientes con múltiples dimensiones de comportamiento. (Baligodugula & Amsaad, 2025). Con respecto a la utilidad operativa, el pipeline resultante entrega listas priorizadas por probabilidad para trabajar el top-N, horizontes de intervención derivados de supervivencia y perfiles o segmentos interpretables que guían mensajes, canales y políticas diferenciales para la comprender la fuga de los afiliados del Plan Complementario.
Kaplan-Meier y Cox son los más usados en estudios clásicos de permanencia por su capacidad de manejar censura (Barrajón & Barrajón, 2020). RSF, aunque es más reciente, permite capturar relaciones no lineales y complejas. Esta combinación nos da interpretación y flexibilidad.

La evaluación de estos modelos combinará AUC, KS, PR-AUC y Lift@10 % para el ranking; Brier y curvas de calibración para la probabilidad y de supervivencia; y hazards para el tiempo de permanencia. Estas métricas son las más utilizadas en estudios de churn, especialmente cuando se trata de eventos raros como la fuga de clientes rentables. A diferencia de métricas más comunes como el F1-score, que no capturan en completitud la naturaleza del problema, estas métricas permiten evaluar el modelo desde distintos ángulos. Discriminación (qué tan bien separa a los que fugan de los que no), calibración (qué tan confiables son las probabilidades estimadas) y cobertura anticipada (qué tan temprano podemos detectar el riesgo). (Verbeke, Martens, & Baesens, 2012). Esto nos permite no solo medir el desempeño técnico, sino también su utilidad operativa para la EPS.

Al final, la explicabilidad con SHAP cerrará el ciclo. SHAP es el estándar actual para explicar modelos complejos como XGBoost, además, facilitando la comunicación con stakeholders. Su base en la teoría de juegos le da un sustento matemático sólido para atribuir de forma justa la contribución de cada variable a la predicción. Esto lo diferencia a LIME, por ejemplo, mucho más heurístico. (Salih et al., 2024)

Además, Por la versatilidad demostrada por la metodología CRISP-DM en estudios previos aplicados a problemas de predicción de fuga en seguros de salud, siendo el estándar en ese sentido y considerando la naturaleza estructurada, histórica de los datos disponibles (bases de Permanencia, PQRS y Consumos), se adopta este

enfoque en su versión ágil para guiar el desarrollo del modelo. Esta variante permite avanzar de forma flexible entre fases, adaptarse a hallazgos emergentes y mantener alineación total con los objetivos estratégicos del negocio.

La siguiente tabla muestra para cada objetivo específico, los algoritmos a trabajar y la herramienta que se utilizara en su desarrollo:

Objetivo Especifico	**Algoritmo**	**Herramienta**
Segmentación	**UMAP + HDBSCAN**	**Python**
Modelo Predictivo de Fuga	**Regresión Logística + XGBoost**	**Python**
Calibrar Score de Fuga	**Platt Scaling o isotonic regression**	**Python**
Supervivencia/Permanencia	**Kaplan-Meier & Cox + RSF**	**R**
Validar Modelo	**AUC-ROC, Brier, KS, PR-AUC, Lift y Recall**	**Python**
Visualización y Explicabilidad	**SHAP**	**Python**

Tabla 7.3.1 *– Tabla de selección de algoritmos y herramientas para cada objetivo*

7.4. Aplicación

7.4.1 Aplicación de Técnicas de Segmentación

La segmentación de perfiles es una herramienta estratégica dentro de la analítica de datos, ya que permite identificar patrones de comportamiento y agrupar individuos con características similares, facilitando la toma de decisiones orientadas a la retención y la fidelización. En el contexto de la EPS ABC, donde la competencia y la movilidad de los afiliados juegan un rol crítico, comprender la heterogeneidad de la base de clientes es fundamental para anticipar riesgos de fuga y optimizar la asignación de recursos destinados a campañas y acciones preventivas.

Este capítulo describe el proceso de segmentación realizado sobre el conjunto de datos de clientes de la EPS ABC, en línea con los objetivos del proyecto orientado a la gestión del churn de clientes rentables. El propósito de la segmentación es caracterizar los grupos más representativos, identificar aquellos con mayor probabilidad de migración y establecer lineamientos que apoyen el diseño de estrategias diferenciales de retención.

Para ello se implementaron técnicas de clustering comenzando con un modelo base de K Means, ampliamente reconocido por su simplicidad y eficiencia, aunque con limitaciones en contextos donde existen estructuras complejas o variaciones significativas en la densidad de los datos. Con el fin de obtener una representación más precisa de la estructura subyacente, se adoptó posteriormente un enfoque más robusto mediante la integración de UMAP (*Uniform Manifold Approximation and Projection*) para la reducción de dimensionalidad y HDBSCAN (*Hierarchical Density Based Spatial Clustering of Applications with Noise*) para la identificación de clusters con densidad heterogénea. Esta combinación permitió obtener una segmentación más alineada con las características reales del negocio y con la naturaleza diversa de los afiliados.

El análisis se llevó a cabo utilizando el conjunto de datos consolidado en el archivo *Merge_Completo_vigencia_total.parquet*, proveniente del pipeline de limpieza y depuración previo (Consultar Anexo A.3). Este archivo integra información completa de los afiliados de la EPS ABC, incluyendo dimensiones demográficas, características del plan, interacción con la entidad, uso de servicios y variables asociadas a la vigencia contractual. En esta sección se describe exclusivamente el preprocesamiento adicional necesario para la ejecución del proceso de segmentación.

En primer lugar, las variables de fecha FECHA_INICIO y FECHA_FIN fueron transformadas al formato *datetime* con el objetivo de habilitar cálculos temporales consistentes. A partir de estas fechas se derivó la variable meses_transcurridos, la cual representa la duración de la afiliación expresada en meses. El cálculo se realizó obteniendo la diferencia en año mes entre las fechas de inicio y fin y ajustando por el día del mes con el fin de evitar sobre contar un mes cuando el día de finalización es anterior al día de inicio. Todos los valores negativos fueron truncados para asegurar coherencia en los registros.

Posteriormente se aplicó un filtro para excluir observaciones con FALLA_BIN igual a 0 y menos de 12 meses de vigencia. Estos casos no aportan información relevante para la caracterización de clientes con permanencia significativa y su inclusión podría introducir ruido en la detección de patrones asociados al churn. El resultado de este proceso fue un subconjunto depurado, denominado *df_filtrado*, sobre el cual se ejecutaron las técnicas de reducción de dimensionalidad y los algoritmos de clustering.

Este preprocesamiento garantiza que la segmentación se realice sobre datos consistentes y representativos, preservando las variables clave para el análisis y alineando la cohorte con el horizonte temporal del proyecto (fuga a un año).

Luego de aplicar y evaluar el desempeño del modelo base con K-Means y constatar sus limitaciones para representar la estructura real del dataset, se procedió a explorar un enfoque más adecuado para la segmentación final. A partir de este punto se incorporó un pipeline basado en UMAP y HDBSCAN, orientado a capturar la complejidad y heterogeneidad presentes en los afiliados.

- UMAP permite reducir la dimensionalidad preservando tanto la estructura local como global de los datos, lo que facilita la separación entre grupos y mejora la interpretabilidad en escenarios con alta dimensionalidad (61 variables en este caso).
- HDBSCAN es un algoritmo basado en densidad que identifica clusters de forma jerárquica, adaptándose a diferentes formas y tamaños, y gestionando adecuadamente el ruido, o sea puntos que no pertenecen a ningún cluster, lo que resulta crítico en datos heterogéneos como los de afiliados.

A diferencia de métodos tradicionales como K-Means, este enfoque no requiere especificar el número de clusters a priori, lo que es ideal en escenarios donde la estructura subyacente es desconocida y se busca evitar sesgos en la segmentación.

Fase 1: Modelo base con K-Means (línea de base y validación estructural).

La construcción de la matriz de características se implementó mediante la función build_X_sparse, que organiza las columnas en tres familias:

- **Variables categóricas codificadas**: PLAN, CONDICION_SALUD, NIVEL_INGRESO. Estas se convierten en variables dummy mediante *one-hot encoding*.
- **Variables binarias**: tipo de afiliado, región, tipo de IPS, signo de compañía, presencia de CAC, variables de rango etario y, en el caso de cancelados, grupo de causa de cancelación.
  Para los activos, estas últimas se excluyen para evitar fuga de información desde el futuro.
- **Variables numéricas**: uso de servicios PAC y PBS (totales y FIN), interacciones (quejas, peticiones, inquietudes, sugerencias, felicitaciones), más la variable meses_transcurridos.
  Las variables de conteo se transforman mediante log1p para reducir asimetría y luego se estandarizan con *StandardScaler.*

Las tres familias se convierten en matrices dispersas (*csr_matrix*) y se combinan con *sparse.hstack*, produciendo una matriz altamente eficiente en memoria y compatible con algoritmos para datos de gran escala como lo que tenemos de input.

Reducción de dimensionalidad para evaluación.

Aunque el clustering se ejecutó sobre la matriz dispersa, se aplicó *Truncated SVD* para obtener una representación densa reducida (hasta 100 componentes). Esta reducción no afectó el clustering, pero fue esencial para calcular métricas de calidad y visualizar tendencias, preservando la estructura global de los datos.

Entrenamiento del modelo K-Means.

Se utilizó *MiniBatchKMeans*, una variante optimizada para grandes *datasets*, que permite actualizaciones por lotes reduciendo el tiempo de cómputo sin sacrificar precisión. Se evaluaron diferentes valores de K en rangos adaptados a cada segmento. Para afiliados activos, entre 2 y 10, y para cancelados entre 2 y 12.

A fin de determinar la calidad de cada partición, se calcularon las siguientes métricas internas de *clustering*:

- **Silhouette Score**: mide cohesión y separación entre clusters.
- **Codo**: Mide compacidad dentro de los clusters.
- **Calinski-Harabasz**: evalúa la dispersión intra e inter cluster.
- **Davies-Bouldin**: penaliza clusters poco compactos o mal separados.

Con estas métricas se construyó un score compuesto, el cual permitió comparar las distintas particiones bajo un mismo criterio y seleccionar de forma más objetiva el valor óptimo de K.

Los resultados de esta fase preliminar indicaron que, en el caso del segmento de afiliados activos, el número óptimo de clusters se aproximaba a 2. Con el propósito de explorar una segmentación de mayor granularidad, se ejecutó además una prueba forzada con K igual a 5, lo que permitió observar una diferenciación ligeramente más marcada entre perfiles. Sin embargo, esta mayor separación aparente no se tradujo en mejoras relevantes en las métricas internas y, dado el bajo nivel de separabilidad evidenciado en el espacio reducido mediante SVD, dominado principalmente por dos componentes, surgieron dudas razonables respecto a la capacidad del algoritmo para representar de manera fiel la complejidad del dataset.

El análisis global de las métricas confirma que K Means no logra capturar la estructura latente del conjunto de afiliados, lo que resulta coherente con la naturaleza del método. Este algoritmo supone la existencia de clusters aproximadamente esféricos y con densidades relativamente homogéneas, supuestos que se vuelven poco realistas en un escenario donde convergen variables heterogéneas, distribuciones marcadamente sesgadas y relaciones no

lineales entre las características. Incluso al incrementar el número de clusters, las mejoras obtenidas fueron marginales, lo que evidencia una estructura difusa y poco compatible con un enfoque particional como el que propone K Means.

A partir de estos hallazgos se concluye que K Means cumple una función útil como línea base de exploración inicial, pero no constituye una alternativa adecuada para la segmentación final del proyecto. Esta limitación justifica la transición hacia un enfoque más robusto y flexible, sustentado en la combinación de UMAP y HDBSCAN, técnicas capaces de modelar densidades variables, formas arbitrarias y presencia de ruido estructural. Este enfoque permite una representación más precisa y coherente de la heterogeneidad real de los afiliados, lo que mejora la calidad de los perfiles resultantes y la utilidad analítica de la segmentación.

Con el fin de superar las limitaciones observadas en el uso de K Means, se adoptó un enfoque más robusto y flexible basado en la combinación de UMAP (Uniform Manifold Approximation and Projection) para la reducción de dimensionalidad y HDBSCAN (Hierarchical Density Based Spatial Clustering of Applications with Noise) para la identificación de clusters. Este pipeline fue diseñado específicamente para manejar la alta dimensionalidad del dataset, la heterogeneidad de las distribuciones y la presencia de ruido, características propias de los datos provenientes de afiliados de la EPS ABC.

Reducción de dimensionalidad con UMAP

UMAP se aplicó para proyectar las 61 variables originales en espacios de menor dimensión con 2, 5 y 10 componentes. Esta técnica permite preservar tanto la estructura local como la global de los datos, lo que resulta especialmente valioso en conjuntos complejos donde coexisten relaciones no lineales y variaciones significativas entre observaciones. La proyección facilitó la identificación de patrones latentes y la separación visual de grupos potenciales, acelerando el análisis e incrementando la capacidad del modelo para representar la complejidad del dataset.

Clustering con HDBSCAN

Sobre las proyecciones generadas mediante UMAP se aplicó HDBSCAN, un algoritmo basado en densidad que identifica clusters de manera jerárquica y asigna puntos ruidosos como outliers en lugar de forzar su inclusión en algún grupo. Esta característica adquiere especial relevancia en escenarios donde existe un número significativo de afiliados con comportamientos atípicos o patrones inusuales de uso. Dependiendo de la configuración de parámetros como min_cluster_size o min_samples, HDBSCAN permite modelar grupos con densidades variables y formas no convexas, ofreciendo una segmentación más alineada con la estructura real de los datos.

Proceso iterativo y decisión final

Para garantizar la robustez del modelo, se desarrollaron 6 iteraciones oficiales en las que se ajustaron parámetros y criterios de evaluación. Las primeras tres pruebas se fundamentaron en una fórmula inicial para el cálculo del score compuesto, la cual priorizaba métricas generales y generaba resultados visualmente menos consistentes con el volumen real del dataset. A partir de esto, se redefinió el criterio de evaluación mediante la incorporación de ponderaciones más acordes con la naturaleza de los datos, lo que permitió obtener dos configuraciones con puntuaciones notablemente superiores y una segmentación más coherente y estable.

Asimismo, se realizaron pruebas variando parámetros como target_samples y n_components, ya que las restricciones de capacidad computacional del entorno de trabajo generaban tiempos de ejecución superiores a una hora en ciertos casos. Estos ajustes permitieron equilibrar calidad, representatividad y eficiencia operativa del modelo.

En síntesis, tal como se expuso previamente, la iteración se centró en evaluar distintos valores para los parámetros más relevantes de UMAP y HDBSCAN con el fin de obtener una configuración final que representara de forma fiel la estructura latente del conjunto de afiliados y permitiera construir una segmentación consistente desde el punto de vista analítico.

- **target_sample**: Se hicieron pruebas entre 20.000 y 7.000, lo que impacta en la densidad y la estabilidad de los clusters.
- **n_components**: En las primeras dos iteraciones se usan 2 dimensiones, mientras que en las últimas tres se usaron 5 y 10, lo que aumenta la capacidad de preservar estructura global.
- **grids de búsqueda**: se cambiaron usualmente dependiendo de la ejecución, lo que indica una exploración más exhaustiva en esas iteraciones.

Por último, la evaluación de la calidad en procesos de segmentación basados en UMAP y HDBSCAN plantea un desafío metodológico relevante, debido a que no existe una métrica única que sintetice todos los aspectos críticos del modelo. Las métricas estándar, como el índice de validez propio de HDBSCAN o el coeficiente Silhouette, permiten medir dimensiones específicas como la cohesión interna o la separación entre clusters, pero no incorporan factores igualmente importantes como la proporción de ruido, la cantidad resultante de clusters o la estabilidad en la asignación de puntos. En consecuencia, su uso aislado resulta insuficiente para una evaluación integral de segmentaciones complejas.

Ante esta limitación, se propone una fórmula compuesta personalizada que integra criterios fundamentales dentro de una única puntuación agregada. Esta estructura sigue el enfoque documentado en métodos multicriterio de apoyo a decisiones (MCDM), como el modelo Weighted Sum Model descrito por Belton y Stewart (2002) en Multiple Criteria Decision Analysis: An Integrated Approach. Dicho patrón es ampliamente utilizado en análisis multicriterio, optimización y evaluación de modelos, ya que facilita la combinación de beneficios, penalizaciones y bonificaciones en una función agregada que resume los elementos clave del desempeño.

Bajo esta lógica, la fórmula compuesta permite capturar simultáneamente la calidad interna del clustering, su estabilidad ante variaciones en parámetros y la robustez frente a la presencia de ruido. Esto ofrece una visión más completa del comportamiento del modelo y apoya la selección de configuraciones que se ajusten mejor a la estructura real del dataset, superando las limitaciones inherentes a las métricas tradicionales.

$$\boldsymbol{Score = B - \alpha * r^{\gamma} - \beta * \left(\frac{K}{S(N)}\right) + \delta * (P_{high} - 0.5)}$$

Donde:

B = Métrica base de calidad del clustering (validez relativa de HDBSCAN, combinada con Silhouette si está disponible).

r = Proporción de ruido (puntos etiquetados como -1 por HDBSCAN).

α = Peso de la penalización por ruido

γ = Control de convexidad (penalización línea, 1.0)

K = Número de clusters detectados (sin contar el ruido).

$S(N)$ = Factor de escalado según el tamaño del dataset (N). Este limita que la penalización no sea desproporcionada en datasets grandes sqrtN = S(N) = $\sqrt{N}$

β = Peso penalización

P_{high} = Proporción de puntos con alta probabilidad de pertenencia (≥ umbral, por defecto 0.7).

δ = Pesos que controla la bonificación (bajo para que no controle el score total.

En palabras mas sencillas lo que se puede apreciar en la formula del score es:

- $\boldsymbol{Bonificacion\ por\ cohesion\ y\ separacion} = B = 0.7 * validity + 0.3 * silhouette$
- $\boldsymbol{penalizacion\ por\ ruido} = \alpha * r^{\gamma}$
- $\boldsymbol{penalizacion\ por\ clusters} = \beta * \left(\frac{K}{S(N)}\right)$
- $\boldsymbol{Bonificacion\ por\ membresia\ firme} = \delta * (P_{high} - 0.5)$

Por lo que la formula se puede resumir en palabras a la siguiente lógica:

$$\boldsymbol{Score\ total = Beneficio\ por\ cohesion - penalizacion\ ruido - penalizacion\ K + Bonificacion\ membresia\ firme}$$

El parámetro N que podemos apreciar en la formula anteriormente descrita, representa el tamaño del *target_sample* utilizado en cada ejecución. Dado que UMAP y HDBSCAN son algoritmos sensibles al volumen de datos, es totalmente lógico que el factor de escalado S(N) se ajuste dinámicamente. Esto evita que la penalización por número de clusters sea desproporcionada en ejecuciones con diferentes tamaños muestrales. Por ejemplo:

- Si $N = 7000, S(N) = \sqrt{7000} \approx 83.66$
- Si $N = 20000, S(N) = \sqrt{20000} \approx 141.42$

Este ajuste mantiene la comparabilidad del score entre ejecuciones, garantizando que el impacto del número de clusters sea relativo al tamaño del *target_sample* y no absoluto.

La fórmula personalizada es la mejor opción para dar un score global en segmentaciones UMAP + HDBSCAN porque integra métricas comúnmente utilizadas (*validity index, Silhouette*, ruido, estabilidad), está respaldada por principios documentados en *MCDM* (*Weighted Sum Model*), permite comparar ejecuciones bajo criterios consistentes y se adapta dinámicamente al tamaño del dataset, lo que es esencial en entornos como el del presente proyecto donde el *target_sample* varía.

7.4.2 Aplicación de Modelos de Regresión y XGBoost

El propósito fundamental de esta etapa del proyecto consistió en establecer una línea base de desempeño (*benchmark*) que permitiera evaluar la complejidad inherente al fenómeno de fuga en la EPS ABC y determinar la naturaleza de las relaciones entre las variables predictoras. Específicamente, se buscó evaluar si los

patrones de abandono responden a estructuras predominantemente lineales o si por el contrario, requieren algoritmos capaces de capturar no linealidades e interacciones complejas.
Para tal fin, se diseñó un experimento comparativo entre dos enfoques metodológicos opuestos:

1. **Regresión Logística:** Seleccionado como el estándar de la industria para modelos lineales explicativos.
2. **XGBoost (eXtreme Gradient Boosting):** Seleccionado como representante de los algoritmos de ensamble basados en árboles (*tree-based ensemble*), reconocido en la literatura (Chen & Guestrin, 2016) por su alto rendimiento en datos tabulares estructurados.

Pipeline reproducible y prevención de leakage

Previo a la fase de modelamiento, se ejecutó un protocolo riguroso de depuración de datos para garantizar la validez externa de los resultados. Se aplicó un **filtro de maduración** al conjunto de datos, excluyendo aquellos afiliados con una antigüedad menor a 12 meses. Esta regla de negocio se fundamenta en la necesidad de eliminar el sesgo de "falsa fidelidad" asociado a usuarios nuevos que aún no han completado un ciclo anual de contrato, asegurando así que la variable objetivo (*target*) refleje un riesgo genuino de deserción y no una volatilidad temprana natural del producto.

Impacto del preprocesamiento: La aplicación de este filtro resultó en la exclusión de 256,381 registros, consolidando una base analítica final de 1,019,505 observaciones. Tras este proceso, la tasa de fuga (*churn rate*) observada se estabilizó en un 20.09 %, una cifra representativa del comportamiento real de la cartera consolidada de la EPS.

Para asegurar la reproducibilidad del experimento y mitigar el riesgo de *data leakage* (contaminación de los datos de prueba con información del entrenamiento), se implementaron arquitecturas de *pipeline* diferenciadas:

- **Regresión Logística:** Se encapsuló dentro de un Pipeline que incluye una etapa de estandarización (*StandardScaler*). Esto garantiza que los parámetros de media y desviación estándar se calculen exclusivamente sobre el subconjunto de entrenamiento, evitando sesgos en las proyecciones sobre el conjunto de prueba.

- **XGBoost:** Se entrenó sobre las variables en su escala original, aprovechando la propiedad de invarianza de escala de los árboles de decisión, lo cual preserva la interpretabilidad de los puntos de corte en las reglas de negocio derivadas.

División estratificada y validación inicial

Para la fase de entrenamiento y evaluación, se optó por una estrategia de Muestreo Aleatorio Estratificado (*Stratified Random Split*), asignando el 80% de los datos al conjunto de entrenamiento (*Train*) y el 20 % restante al conjunto de prueba (*Test*).
Si bien en la literatura de predicción de fuga es común encontrar validaciones temporales (*Time Split*), para este diseño experimental se seleccionó la estratificación aleatoria fundamentada en tres pilares teóricos:

1. **Preservación de la Distribución de Clases:** Dado el desbalance inherente en el conjunto de datos (Tasa de fuga ~20 %), el muestreo aleatorio simple podría generar subconjuntos donde la clase minoritaria esté subrepresentada, incrementando la varianza del error. Según Tan, Steinbach y Kumar (2019), la estratificación es la técnica estándar obligatoria en minería de datos para asegurar que la proporción de la clase objetivo (*target*) se mantenga constante entre los pliegues de validación, garantizando que las métricas de evaluación sean estadísticamente significativas y no producto del azar en el muestreo.
2. **Mitigación de Sesgo por Estacionalidad y *'Concept Drift'*:** Una división estrictamente temporal (ej. entrenar con datos anteriores al 2024 y probar con datos del 2024 en adelante) es susceptible al sesgo coyuntural o *covariate shift*, donde cambios externos (como reformas al sistema de salud o crisis económicas) alteran la distribución de los datos, degradando el desempeño del modelo por razones ajenas a su arquitectura (He & Garcia, 2009). Al utilizar una división estratificada aleatoria, se busca que el modelo XGBoost capture los patrones estructurales del comportamiento del usuario (edad, uso, siniestralidad) que son invariantes en el tiempo, en lugar de memorizar tendencias temporales específicas de un periodo corto (Chen & Guestrin, 2016).
3. **Coherencia con la Regla de Maduración:** Al haberse aplicado previamente un filtro de antigüedad (>12 meses) para eliminar la "fuga temprana", el componente temporal de aprendizaje ha sido estabilizado. El objetivo de la partición, por tanto, se alinea con la validación de la capacidad de generalización del algoritmo ante perfiles de clientes desconocidos, una

práctica recomendada en estudios de *churn* en el sector asegurador para evitar sobreajustes a cohortes de ingreso específicas (Tralice, 2019).

La aplicación de esta técnica aseguró la homogeneidad distributiva en los vectores resultantes, validando la robustez del diseño experimental:

- **Tasa Global:** 20.09 %
- **Tasa en Entrenamiento (Train):** 20.09 %
- **Tasa en Prueba (Test):** 20.09 %

Estabilidad de métricas Train/Test

Una vez ejecutados los pipelines de entrenamiento, se procedió a la evaluación comparativa del desempeño. Para este proyecto, la selección del algoritmo campeón no se basó en una única métrica, sino en una evaluación multidimensional alineada con los objetivos de negocio definidos en la propuesta de grado:

- AUC (Área bajo la curva ROC): Se priorizó esta métrica para medir la probabilidad de que el modelo asigne correctamente un puntaje más alto a un cliente fugado que a uno activo, independientemente del punto de corte.
- KS (Kolmogorov-Smirnov): Para garantizar que exista un margen claro entre las distribuciones de ambas clases, facilitando la definición de umbrales de decisión.
- Eficiencia Operativa (Lift) en el decil superior: Métrica crítica de negocio seleccionada para cuantificar cuánto mejora la detección de fuga respecto a una selección aleatoria, impactando directamente el retorno de inversión (ROI) de las campañas de retención.
- Robustez ante el Desbalance (PR-AUC)**:** A diferencia del AUC-ROC, que puede ser optimista en conjuntos de datos desbalanceados, el Área Bajo la Curva de Precisión-Recall (PR-AUC) se enfoca exclusivamente en el desempeño sobre la clase minoritaria (fuga).
- Calibración Probabilística (Brier Score)**:** Esta métrica mide la precisión de las probabilidades predichas, calculando el error cuadrático medio entre la probabilidad estimada y el resultado real (0 o 1).

Predicción candidato avanzado

XGBoost fue seleccionado como motor candidato por su capacidad para modelar relaciones no lineales y efectos de interacción mediante boosting de árboles, su robustez frente a escalas heterogéneas de variables y su desempeño consistente

en problemas de clasificación desbalanceada en riesgo de churn, especialmente cuando se combinan estrategias de ponderación de clases con parámetros de regularización y muestreo estocástico por filas y columnas (Chen y Guestrin, 2016; Prokhorenkova et al., 2018). En términos prácticos, el modelo captura reglas segmentadas y umbrales en variables comportamentales y de servicio que un clasificador lineal no puede representar de forma efectiva.

El conjunto de entrenamiento presenta una razón clase mayoritaria a minoritaria cercana a 3.98. Para forzar sensibilidad hacia la clase positiva se evaluaron tres hipótesis variando el gradiente de error mediante el parámetro *scale_pos_weight*:

- **H1: El Conservador (Baseline)** – scale_pos_weight = 1.0
- **H2: El Estratega (Raíz Cuadrada)** – scale_pos_weight ≈ 2.0
- **H3: El Cazador (Full Ratio) –** scale_pos_weight ≈ 3.98

Interpretabilidad Global y Local mediante valores SHAP

Una vez seleccionado el modelo XGBoost como el algoritmo "campeón", se procedió a romper la opacidad del modelo tipo "caja negra" mediante la implementación de **SHAP (SHapley Additive exPlanations)**. Basado en la teoría de juegos cooperativos, SHAP permite descomponer la predicción de riesgo de cada afiliado, asignando a cada variable un valor que representa su contribución exacta al cambio en la probabilidad de fuga respecto a la predicción base (Lundberg & Lee, 2017).

- **Análisis Global (Feature Importance):** A diferencia de la importancia nativa de XGBoost (basada en *gain* o *weight*), los valores SHAP proporcionan una jerarquía basada en la magnitud del impacto real en la salida del modelo. Esto permite identificar qué factores, como la siniestralidad acumulada o la frecuencia de uso de servicios, están traccionando la decisión de salida de forma transversal en la EPS.

- **Análisis Local (Individual):** Para la gestión operativa, se implementaron gráficos de fuerza (*Force Plots*) y diagramas de cascada. Estos permiten al equipo de fidelización entender, por ejemplo, que un afiliado específico tiene un riesgo del 85 % no solo por su edad, sino por una caída drástica en el uso del Plan Complementario en los últimos 3 meses.

Simulación de Impacto Financiero y Eficiencia Operativa

La capacidad predictiva del modelo no es un fin en sí mismo, sino un medio para optimizar el recurso económico de la EPS ABC. Para esto, se desarrolló un **Modelo**

de Simulación Financiera (basado en el notebook Simulacion_Financiera_EPS_ABC, Anexo A.7) que traduce las probabilidades de *churn* en ahorros potenciales.

El análisis se estructuró bajo la siguiente lógica de eficiencia:

1. **Segmentación por Deciles de Riesgo:** Se clasificó a la población en 10 grupos según su probabilidad de fuga. El análisis de *Lift* confirmó que el 80 % de los futuros desertores se concentran en los primeros dos deciles, lo que permite una **focalización quirúrgica** de las llamadas de retención.

2. **Cálculo del Valor en Riesgo (VaR):** Se cruzó la probabilidad de fuga con el ingreso per cápita de cada afiliado. Esto permitió priorizar no solo a quien tiene más riesgo de irse, sino a los **afiliados rentables**, optimizando el Valor de Vida del Cliente (CLV).

3. **Diseño de Experimento (Gestión vs. Control):** Para medir la eficiencia real, se implementó una lógica de grupos:
    - **Grupo de Tratamiento (80 %):** Sujetos a gestión proactiva por el Call Center.
    - **Grupo de Control (20 %):** Población de riesgo que no recibe intervención, permitiendo medir la efectividad neta (incremento en la permanencia) atribuible exclusivamente al modelo.

Métrica de Simulación	Valor Estimado
Población en Riesgo Alto	~20% de la cartera
Eficacia de Retención Esperada	10% - 15% (basado en literatura)
Costo de Intervención por Afiliado	(Costo Call Center / Nro. Contactos)
ROI Estimado	(Ingreso Preservado - Costos Operativos) / Costos Operativos

Tabla 7.4.1 – Métricas de Simulación Financiera

7.4.3 Aplicación Modelo de Supervivencia

El fenómeno de la fuga en el PAC no es un evento instantáneo, sino un proceso de desgaste en el tiempo. Mientras que el modelo XGBoost permitió identificar la propensión de un cliente a irse, la aplicación de modelos de supervivencia busca capturar la **dinámica temporal de la permanencia**. El objetivo aquí es estimar la probabilidad individual de fuga a 12 meses, respetando la estructura de censura (clientes que aún no se han ido) y la estacionalidad del negocio.

Capa I: Ingeniería de la Ventana de Observación y Tiempo-Evento

Para garantizar la validez del modelo, se estructuró la base bajo la lógica de Análisis de Supervivencia:

- **Definición del Evento:** Se formaliza como la cancelación efectiva del plan PAC.
- **Tiempo de Seguimiento:** Calculado como el diferencial en meses desde la afiliación hasta el evento o hasta la fecha de corte (censura).
- **Censura por la Derecha:** Vital para no sesgar el modelo, se incluyó a los afiliados vigentes como "censurados", aprovechando su información de permanencia acumulada sin asumir que nunca se irán.
- **Reglas de Negocio:** Se ajustaron los horizontes de observación a 3, 6, 12 y 18 meses, alineándolos con los ciclos de renovación y las ventanas críticas de gestión operativa de la EPS.

Capa II: Modelación Jerárquica (Kaplan-Meier, Cox y RSF)

Se implementó un enfoque de tres niveles para garantizar una transición sólida entre la descripción y la predicción:

1. **Estimador Kaplan-Meier (Exploratorio):** Se utilizó para visualizar la "curva de caída" de la cartera. Esto permitió identificar que existen meses críticos (ej. mes 13 después de la renovación) donde el riesgo se dispara, validando la necesidad de un score preventivo.
2. **Modelo de Riesgos Proporcionales de Cox (Inferencia):** Aplicado para cuantificar el impacto marginal de las variables (Hazard Ratios). Por ejemplo, permitió determinar cuánto aumenta el riesgo de fuga por cada PQRS adicional, manteniendo constante el nivel de ingresos.
3. **Random Survival Forest - RSF (Predictivo):** Se seleccionó este modelo de *Machine Learning* por su capacidad para manejar interacciones no lineales y su superioridad al generar **curvas de supervivencia individuales**. A diferencia de Cox, RSF no asume riesgos proporcionales, lo que permite que el modelo sea mucho más preciso en carteras heterogéneas como la del PAC.

Capa III: Construcción del Score Calibrado a 12 Meses

El resultado final del modelo RSF no es una etiqueta (0 o 1), sino una función de riesgo para cada afiliado.

- **Extracción de Probabilidades:** Se extrajo el valor de la función de riesgo acumulada específicamente en el corte de los 12 meses.

- **Calibración del Score:** Para asegurar que un score de "0.8" signifique realmente un 80 % de probabilidad de salida, se aplicaron técnicas de calibración (curvas de fiabilidad). Esto garantiza que el score sea un insumo directo para el **cálculo del valor esperado de pérdida financiera**, evitando proyecciones optimistas o pesimistas.

Prevención de Data Leakage y Estabilidad Operativa

Un desafío crítico fue la depuración de variables "post-evento". Se eliminaron indicadores administrativos que solo se generan cuando el proceso de cancelación ya ha iniciado (ej. fecha de liquidación final). Asimismo, se homologaron categorías en variables como *IPS, Plan y Canal*, asegurando que el modelo sea ejecutable en tiempo real con la información disponible en los sistemas de la EPS al momento de la predicción.

8. Resultados

8.1. Presentación de Resultados

8.1.1 Presentación de Resultados de Segmentación

Para abordar la complejidad del fenómeno de fuga, se implementó una estrategia de segmentación no supervisada en dos niveles. Este enfoque híbrido permite superar las limitaciones de la segmentación demográfica tradicional, revelando tanto los nichos ocultos como la realidad masiva del portafolio.

En este punto se presentan los resultados completos del análisis de clustering, utilizando tanto la fase exploratoria con K-Means como la segmentación final UMAP + HDBSCAN.

Resultados K-Means (baseline):
Tal como se mencionó en el capítulo 7.1, para cada valor de K se calcularon métricas de calidad y se construyó un score compuesto ponderando las métricas de *silhouette, Codo, Calinski-Harabasz y Davies-Bouldin* para seleccionar el valor óptimo de K de forma objetiva.

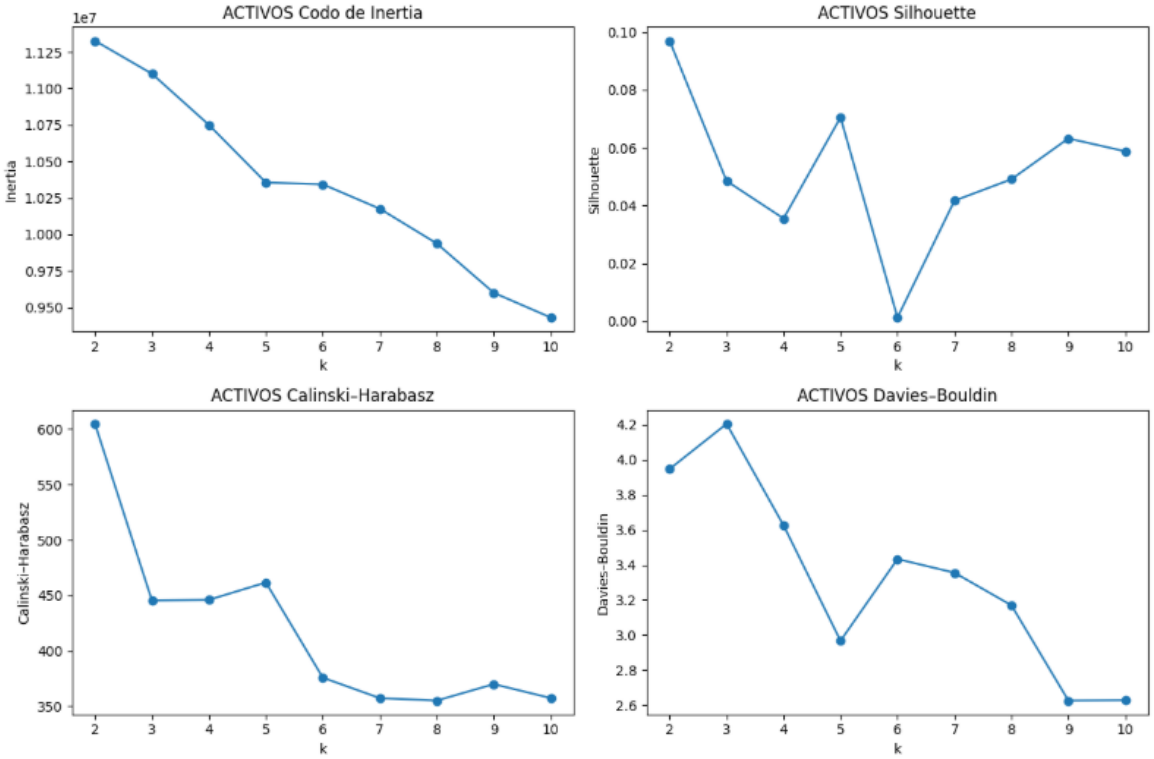

Ilustración 8.1.1 - Metricas K-means

Estas métricas mostraron resultados que evidencian una estructura poco definida en los datos. Por ejemplo:

El codo disminuyó de forma consistente al aumentar el número de clusters (de 11.3 millones en k=2 a 9.4 millones en k=10), lo que es esperado porque más clusters reducen la distancia interna. Sin embargo, esta reducción no implica una mejor segmentación, ya que la curva no presenta un “codo” claro, lo que indica ausencia de una estructura óptima.

Por otra parte, el *Silhouette* se mantuvo muy bajo en todos los escenarios (máximo = 0.097 para k=2), lo que significa que los clusters presentan alta superposición y baja cohesión interna. Este valor confirma que los datos no se separan bien en grupos esféricos, como asume K-Means.
Calinski-Harabasz mostró valores moderados (604 para k=2 y alrededor de 355 para k=10), sin incrementos significativos que sugieran una mejora sustancial en la separación inter-cluster. Esto refuerza la idea de que la estructura global es difusa.
La métrica Davies-Bouldin penaliza clusters mal separados. En este caso, sus valores oscilaron entre 3.94 (k=2) y 2.62 (k=9), lo que indica que, aunque hay una ligera mejora con más clusters, la calidad sigue siendo baja.
Tras aplicar el pipeline descrito relacionado a K-Means, se obtuvieron clusters diferenciados para los segmentos CANCELADOS y ACTIVOS. A continuación, se presentan las principales características de cada grupo, considerando variables de vigencia, uso de servicios, interacciones y categorías dominantes.
Dentro del Segmento **“CANCELADOS”** El modelo identificó cinco clusters con patrones heterogéneos:

- **Cluster 0**: Afiliados con mayor vigencia promedio (34,5 meses) y uso elevado de PBS (214,7) frente a PAC (8,7). Presentan interacciones moderadas en quejas (0,69 PAC / 0,22 PBS) y casi nulas en felicitaciones. Predominan planes tipo 3 (60,5%) y nivel de ingreso bajo (57,2%). La condición de salud más frecuente es categoría 2 (64%). Regionalmente, destaca la zona Centro (52,5%).
- **Cluster 1**: Vigencia reducida (16,3 meses) y bajo uso de servicios (PBS: 11,7; PAC: 2,3). Interacciones mínimas. Predominan planes tipo 3 (50,5%) y nivel de ingreso 1 (66,3%). Alta concentración en afiliados dependientes (71,7%) y familiares (99,8%).
- **Cluster 2**: Vigencia más corta (11,7 meses) y uso muy bajo (PBS: 9,0; PAC: 1,2). Condición de salud categoría 1 (59%). Segmento adulto joven presente (52,6%). Regionalmente, Centro y Norte son relevantes.

- **Cluster 3:** Vigencia intermedia (25,1 meses) y uso moderado (PBS: 20,2; PAC: 4,7). Alta proporción de planes tipo 3 (83,2%) y mayor diversidad en nivel de ingreso. Segmentos adulto joven y productivo son frecuentes.
- **Cluster 4:** Vigencia media (20,1 meses) y uso relativamente alto de PBS (25,2). Predominan planes tipo 3 (59,6%) y nivel de ingreso 1 (45,8%). Segmentos adulto joven y productivo son representativos.

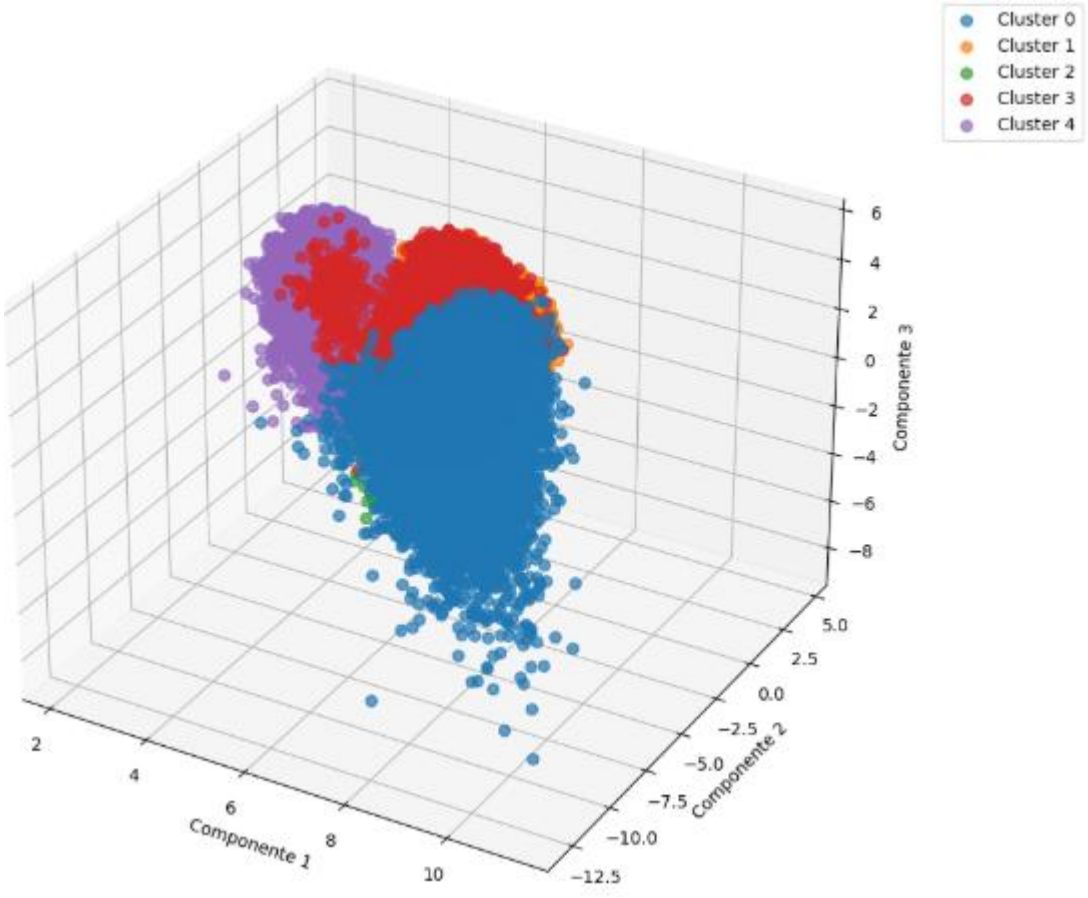

Ilustración 8.1.2 - Clusters kmeans para "Cancelados"

Los clusters reflejan diferencias claras en vigencia, intensidad de uso y perfil socioeconómico. Los grupos con mayor vigencia y uso intensivo (Cluster 0) contrastan con aquellos de corta permanencia y baja interacción (Clusters 1 y 2), lo que sugiere estrategias diferenciadas para retención y análisis de causas de cancelación.

Dentro del segmento **ACTIVOS** se identificaron dos clusters principales:

- **Cluster 0:** Afiliados con vigencia prolongada (52,3 meses) y uso muy alto de PBS (442,3) frente a PAC (1,07). Interacciones más frecuentes en quejas (1,04 PAC / 0,25 PBS). Predominan planes tipo 3 (72,3%) y condición de salud categoría 2 (81,7%). Segmento productivo es dominante (60,1%).

- **Cluster 1:** Vigencia menor (39 meses) y uso significativamente más bajo (PBS: 37,0; PAC: 0,6). Interacciones casi nulas. Predominan planes tipo 3 (65,6%) y condición de salud categoría 1 (66,3%). Segmentos dependiente y adulto joven son más frecuentes.

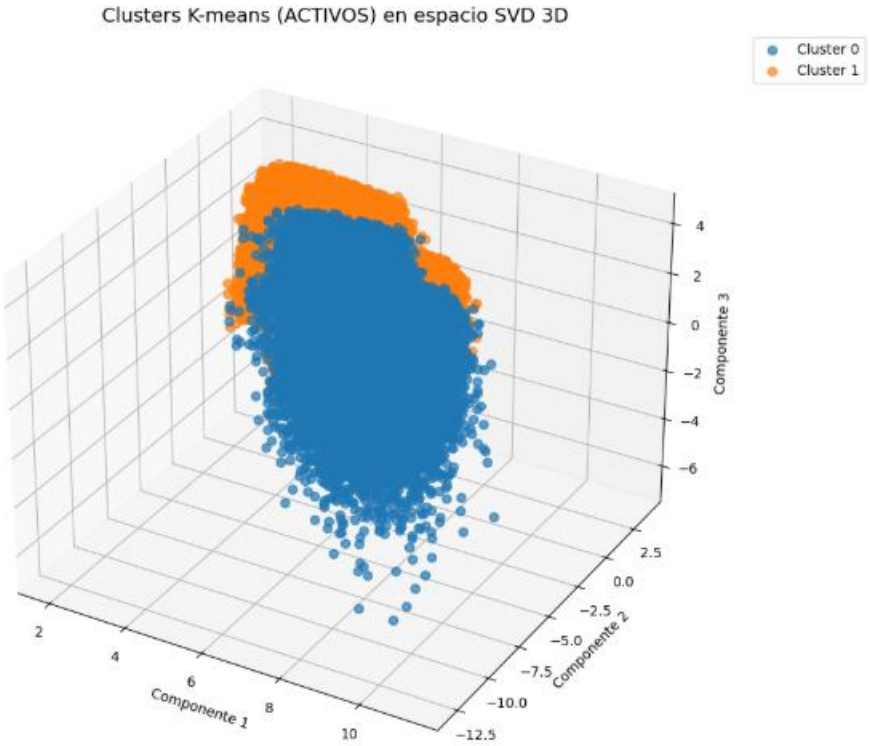

Ilustración 8.1.3 – Clusters Kmeans para "Activos"

Los afiliados activos presentan una clara diferenciación entre usuarios intensivos de PBS con larga permanencia (Cluster 0) y usuarios de bajo consumo con menor vigencia (Cluster 1). Esto permite orientar estrategias de fidelización y optimización de servicios.

Segmentación ACTIVOS con K=5

Tal como se comentó unos párrafos antes, como parte del análisis exploratorio relacionado a los clusters, se realizó una prueba forzando el número de clusters a K = 5 en el segmento de afiliados activos, con el objetivo de evaluar visualmente si una mayor granularidad aportaba interpretabilidad y aunque no se calcularon métricas adicionales para esta configuración, se observó una diferenciación más detallada en los patrones de uso y vigencia, lo que permitió identificar los siguientes subgrupos con características específicas.

- **Cluster 0:** Afiliados con la mayor vigencia promedio (56,8 meses) y uso extremadamente alto de PBS (1132,3), acompañado de interacciones más

frecuentes en quejas (2,13 PAC / 0,54 PBS). Predominan planes tipo 3 y condición de salud categoría 2.

- **Cluster 1**: Vigencia alta (48 meses) y uso moderado de PBS (186,1). Interacciones bajas y perfil socioeconómico más equilibrado. Segmentos dependiente y productivo son representativos.
- **Cluster 2:** Vigencia intermedia (39,9 meses) y uso reducido (PBS: 90,4). Destaca la presencia de afiliados con condición de salud categoría 1 y mayor proporción de nivel de ingreso medio y alto.
- **Cluster 3:** Vigencia similar al clúster anterior (43,4 meses) pero con uso ligeramente superior (PBS: 104,5). Segmento productivo es dominante y las interacciones son mínimas.
- **Cluster 4:** Vigencia media (42,3 meses) y uso bajo (PBS: 66,8). Alta concentración de afiliados dependientes y familiares, con baja interacción en servicios.

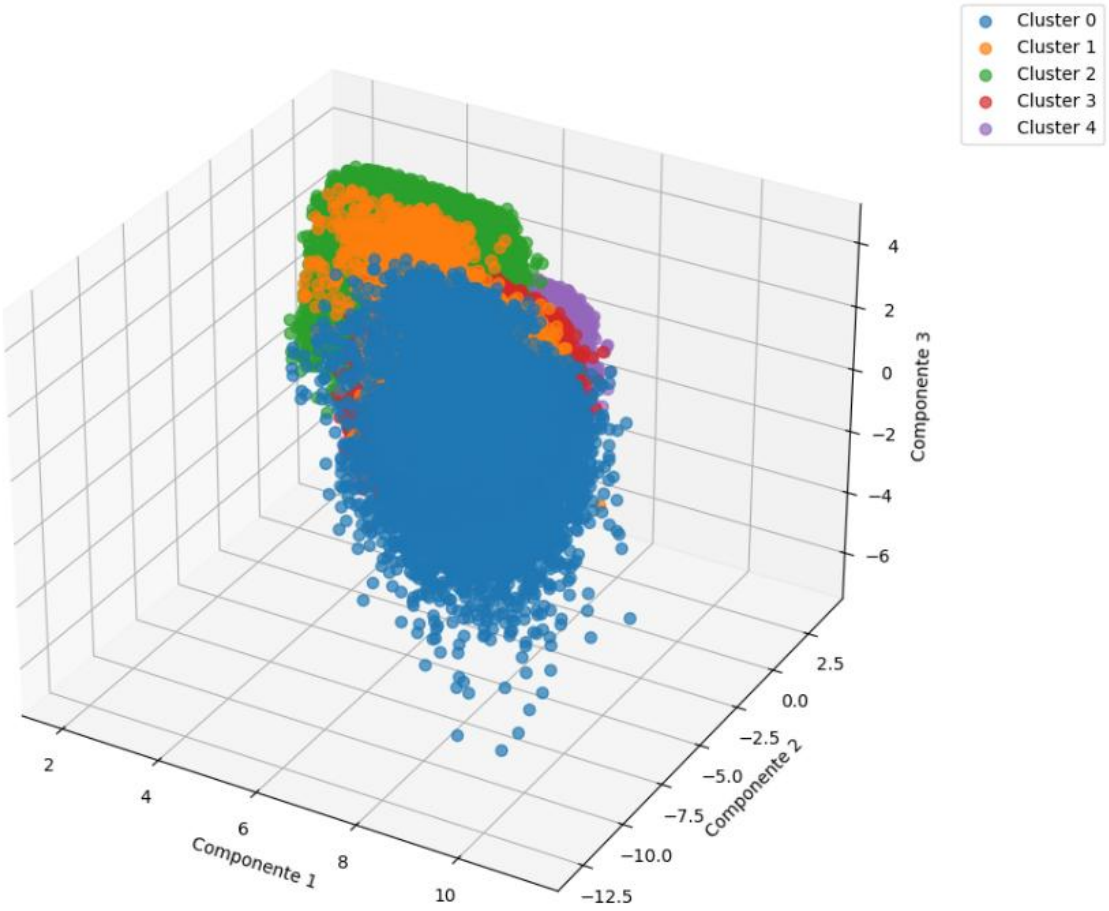

Ilustración 8.1.4 – Clusters Kmeans para "Activos" con K=5

Aunque esta segmentación forzada permitió identificar subgrupos con diferencias en intensidad de uso y perfil demográfico, la baja dimensionalidad detectada por K-

Means en el espacio reducido y la ausencia de métricas robustas limitaron la confianza en este enfoque.
Además, cabe destacar que aumentar la dimensionalidad en la reducción SVD no cambia la naturaleza del problema. Aunque podría preservar más variabilidad, K-Means sigue siendo un método basado en clústeres esféricos y no maneja ruido ni relaciones no lineales, por lo que su capacidad para capturar la complejidad del dataset es limitada. Incluso en el segmento CANCELADOS, donde con solo dos componentes se identificaron 5 clústeres, las métricas internas continuaron siendo bajas, evidenciando que la granularidad no depende únicamente de la dimensionalidad, sino de la estructura intrínseca de los datos. Esta limitación justifica la transición hacia UMAP + HDBSCAN, que ofrece mayor flexibilidad para manejar densidades variables y estructuras complejas.

A continuación, se presentan los hallazgos obtenidos con este enfoque UMAP + HDBSCAN, enfocados exclusivamente en la segmentación resultante y en la calidad estructural de los clusters formados para 5 ejecuciones distintas.

Caracteristicas Cancelados 1 y 2:

- **target_sample**: 20.000 y 17.000 respectivamente.
- **n_components**: 2 dimensiones.
- **Mejor configuración**: n_neighbors=30, min_dist=0.10, min_samples=100, min_cluster_size=500.
- **Trustworthiness**: 0.9639
- **Clusters (K)**: 5.
- **Ruido**: 1.72 %.
- **Score combinado**: 0.0505

En general para este caso se puede apreciar que ambas ejecuciones son prácticamente idénticas. El cambio en el grid no generó mejoras sustanciales. La fórmula de score que se usó en estos casos no penalizaba adecuadamente el ruido ni premiaba cohesión interna, por eso el score es bajo.

Características Cancelados 3:

- **target_sample**: 9.000.
- **n_components**: 5 dimensiones
- **Mejor configuración**: n_neighbors=30, min_dist=0.05, min_samples=30, min_cluster_size=500.
- **Trustworthiness**: 0.9780
- **Clusters (K)**: 3.
- **Ruido**: 4.72 %

- **Score combinado**: 0.0940

En este caso la reducción de K y el aumento de dimensiones mejoran la estructura, pero el ruido elevado afecta la calidad del clustering. Podemos ver que aquí hubo una disminución del *target_sample*, además que modificar *min_dist y min_samples*. La fórmula de score sigue siendo la misma por lo que además se aprecia que el combinado sigue siendo bajo.

Caracteristicas Cancelados 4

- **target_sample**: 7.000.
- **n_components**: 5 dimensiones.
- **Mejor configuración**: n_neighbors=30, min_dist=0.05, min_samples=50, min_cluster_size=200.
- **Trustworthiness**: 0.9755.
- **Clusters (K)**: 4.
- **Ruido**: 0.00 %
- **Score combinado**: 0.1864.
- **Desglose**: Silhouette = 0.6602, p_high ≥ 0.7 = 94.34 %, penalización ruido = 0.0000.

Características Cancelados 5:

- **target_sample**: 7.000.
- **n_components**: 10 dimensiones.
- **Mejor configuración**: n_neighbors=30, min_dist=0.10, min_samples=50, min_cluster_size=200.
- **Trustworthiness**: 0.9781
- **Clusters (K)**: 4.
- **Ruido**: 1.70 %
- **Score combinado**: 0.1825.
- **Desglose**: Silhouette = 0.6618, p_high ≥ 0.7 = 98.31 %, penalización ruido = 0.0068.

Aunque tiene algo de ruido, la proporción de puntos con alta probabilidad es la mejor (98 %) y el trustworthiness es superior. Esto indica mayor estabilidad y confianza en la asignación de clusters.

Análisis técnico Preliminar

Para Cancelados 1 y 2, los resultados obtenidos son prácticamente idénticos. El cambio realizado en el grid no generó mejoras sustanciales en la calidad del modelo. El score combinado es muy bajo (0.0505), debido a que la fórmula anterior no

penalizaba adecuadamente el ruido ni premiaba la cohesión interna de los clusters. Aunque el valor de trustworthiness (0.9639) es aceptable, la estructura global se ve limitada por el uso de solo dos dimensiones y parámetros conservadores.

Para Cancelados 3 se observa una mejora en el *trustworthiness* (0.9780) gracias al incremento a cinco dimensiones, lo que permite preservar mejor la estructura global. Además, se reduce el número de clusters (K=3), lo que indica mayor compacidad. Sin embargo, el ruido aumenta hasta un 4.72 %, afectando la calidad del clustering. El score combinado (0.0940) sigue siendo insuficiente para considerar el modelo como robusto.

En cancelados 4 y 5 la nueva fórmula introduce métricas críticas como la cohesión interna (Silhouette), la proporción de puntos con alta probabilidad *(p_high* ≥ 0.7) y penalizaciones por ruido y exceso de clusters.

En el caso de la 4ta ejecución para cancelados el ruido es prácticamente nulo (0.00%), lo que resulta excelente. El índice Silhouette es sólido (0.6602) y la proporción de puntos con alta probabilidad es aceptable (94.34 %). No obstante, el trustworthiness (0.9755) es ligeramente inferior al obtenido en Cancelados 5.

La ejecución 5ta ejecución de cancelados presenta un mejor trustworthiness (0.9781), lo que indica una mayor preservación de la estructura global. Además, la proporción p_high es sobresaliente (98.31 %), reflejando una alta confianza en la asignación de clusters. La penalización por ruido es mínima (1.7 %), lo que resulta aceptable frente a los beneficios en estabilidad y calidad. Ambos escenarios tienen scores muy similares (0.1864 vs 0.1825), pero Cancelados 5 se considera más robusto porque prioriza estabilidad, confianza en la asignación y estructura global, incluso sacrificando un poco de ruido.

El análisis de los activos arrojo los mismo resultados a nivel de las ejecuciones, por lo que en ese caso la 5ta ejecución también fue justamente la que mejor robustez demostró, con los siguientes detalles:

- **target_sample**: 7.000.
- **n_components**: 10 dimensiones.
- **Mejor configuración**: n_neighbors=50, min_dist=0.10, min_samples=50, min_cluster_size=200.
- **Trustworthiness**: 0.9847
- **Clusters (K)**: 4.
- **Ruido**: 5.05 %
- **Score combinado**: 0.1507.

- **Desglose**: Silhouette = 0.6086, p_high ≥ 0.7 = 94.37 %, penalización ruido = 0.0382.

Caracterización de clusters para cancelados:

- **Cluster 0 (n=13.556):** Uso similar al promedio y fricción normal, con énfasis en prestaciones PAC. Señales: IPS exclusiva, adulto mayor, CAC, colectivo. Motivo dominante: Otras Causas. Diferenciadores: Prestaciones PAC_FIN z=1,14; leve sobreuso en PAC y PBS.
- **Cluster 1 (n=5.550):** Bajo uso y baja fricción. Se fueron sin usar. Señales: IPS sin información, Occidente, dependientes, familiar. Motivo dominante: Mora. Prestaciones y peticiones por debajo del promedio.
- **Cluster 2 (n=13.533):** Bajo uso y muy tranquilo. Se fueron sin usar. Señales: colectivo adulto joven, póliza, Compañía propio. Motivo dominante: Petición del Cliente. PAC y PBS consistentemente por debajo.
- **Cluster 3 (n=132.210):** Masivo, uso cercano al promedio y fricción algo menor. Señales: digital, familiar y ramo familiar. Motivo dominante: Mora. Peticiones y quejas ligeramente por debajo.
- **Outliers (n=2.129):** Dispersos, sin patrón. Útiles para auditoría y limpieza, no para activaciones.

Caracterización de clusters para activos:

- **Cluster 0** (n=14.858): Bajo uso y baja fricción. Antigüedad algo menor. Señales fuertes: SUR, IPS convenio, afiliado familiar y terceros. Lectura estratégica: retención pasiva, comunicación regionalizada y bajo costo.
- **Cluster 1** (n=7.170): Bajo uso y muy baja fricción. Señales fuertes: Compañía propio, asegurado colectivo, Oriente, adulto joven, ingreso 3. Lectura estratégica: fidelización de colectivos, beneficios digitales, vida saludable.
- **Cluster 2** (n=17.146): Alto uso y alta fricción en PAC y PBS. Señales fuertes: IPS exclusiva, CAC, adulto mayor, Norte y digital. Lectura estratégica: foco en experiencia y SLA; gestión proactiva de casos.
- **Cluster 3** (n=161.054): Masivo, uso medio y fricción menor al promedio. Señales fuertes: IPS propia y aliada. Centro, Oriente y Occidente. Lectura estratégica: automatización y monitoreo. Microsegmentación para alertas.
- **Outliers (n=8.033):** Dispersos, sin patrón. Útiles para auditoría y limpieza, no para activaciones.

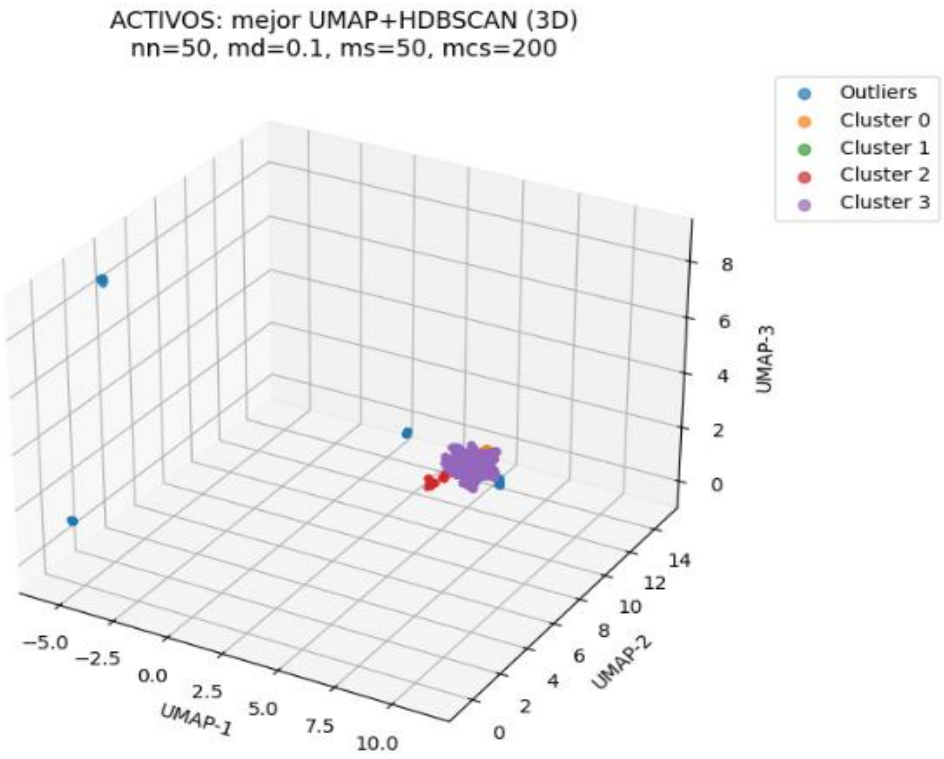

Ilustración 8.1.5 – Clusters UMAP para "Activos"

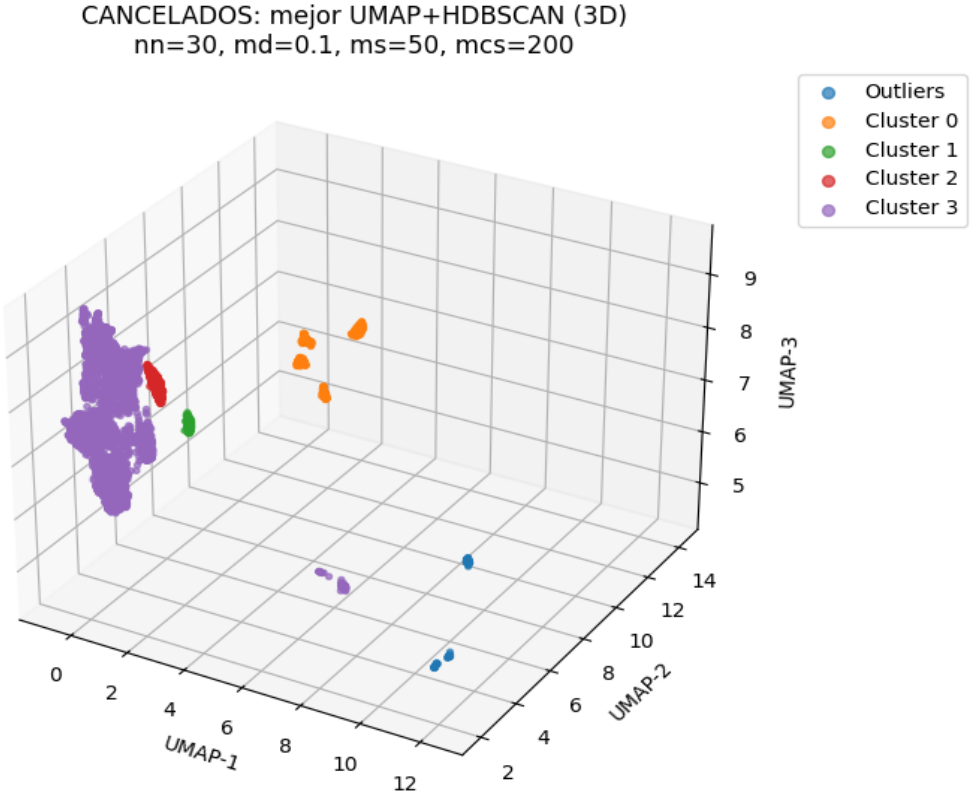

Ilustración 8.1.6 – Clusters UMAP para "Cancelados"

Tal como se mencionó en el punto 7.4.1, El enfoque basado en UMAP + HDBSCAN demostró ventajas significativas sobre K-Means en este contexto. En primer lugar, no requiere definir el número de clusters a priori, lo que evita sesgos y permite descubrir estructuras naturales en los datos. Además, maneja adecuadamente el ruido, asignando puntos atípicos como outliers en lugar de forzar su inclusión en clusters, lo que mejora la calidad del agrupamiento. Otra ventaja crítica es su capacidad para preservar relaciones locales y globales en escenarios de alta dimensionalidad, gracias a la proyección no lineal de UMAP. Esto resulta esencial en datasets heterogéneos como el analizado, donde las variables incluyen dimensiones demográficas, de uso y de interacción. En contraste, K-Means mostró limitaciones al generar clústeres poco representativos y dependientes de configuraciones forzadas, lo que confirmó la necesidad de métodos más flexibles en entornos complejos.

8.1.2 Modelos de Regresión y XGBoost

Esta sección presenta los resultados obtenidos tras la ejecución de la fase de modelamiento predictivo. El análisis se estructuró de manera incremental: primero, estableciendo una línea base (benchmark) mediante un modelo lineal clásico (Regresión Logística), para luego contrastarlo con la capacidad de aprendizaje no lineal del algoritmo XGBoost.

El objetivo primordial de esta etapa es validar si la complejidad del comportamiento de fuga en la EPS ABC puede ser capturada con precisión suficiente para sustentar una estrategia de retención proactiva. Para ello, la evaluación no se limita a métricas de precisión global, sino que profundiza en indicadores de ranking y discriminación (AUC, KS), eficiencia operativa (Lift) y confiabilidad probabilística (Brier Score), garantizando que el modelo seleccionado sea tanto estadísticamente robusto como económicamente rentable.

Métrica	Regresión Logística	XGBoost Vanilla	Delta (Mejora)	Cumplimiento Objetivo
AUC	0.796	0.859	+6.3 pp	**Superado** (>0.75)
KS	46.1 %	56.2 %	+10.1 pp	**Superado** (>30 %)
Lift 10 %	2.68x	3.29x	+0.61x	**Superado** (>1.8x)
PR-AUC	0.462	0.590	+0.128	**No Superado** (>0.70)
Brier	0.131	0.114	-0.017	**Superado** (<= 0.20)

Tabla 8.1.1 - Comparación de Desempeño: Regresión Logística vs. XGBoost (Baseline)

1. **Evidencia de No-Linealidad:** La superioridad estadística del XGBoost (AUC = 0.86) frente a la Regresión Logística (AUC = 0.80) confirma la hipótesis de

que el fenómeno de abandono en el PAC no sigue un patrón lineal simple. Existen interacciones complejas entre variables (por ejemplo, entre el nivel de uso y la tenencia de pólizas externas) que los modelos lineales no logran capturar adecuadamente.

2. **Potencia Operativa (Lift):** El indicador de Lift de **3.29** en el primer decil es crítico para la viabilidad financiera del proyecto. Esto implica que al focalizar las estrategias de retención en el 10% de los clientes con mayor puntaje de riesgo según XGBoost, la EPS sería **3.3 veces más efectiva** en la prevención de fugas reales que mediante una selección aleatoria. Este nivel de eficiencia justifica la inversión en campañas focalizadas.

3. **Separabilidad Robusta:** El estadístico KS del **56.2 %** supera ampliamente los estándares habituales de la industria aseguradora (generalmente ≥ 40 %), lo que indica que el modelo tiene una capacidad robusta para distinguir entre los clientes que permanecerán y los que abandonarán, minimizando el desperdicio de recursos en "falsos positivos".

4. **Calibración Financiera (Brier Score)**: Se obtuvo un Brier Score de 0.114, un valor bajo que valida la fiabilidad de las probabilidades estimadas. Al minimizar el error cuadrático medio de la predicción, se garantiza que el modelo no solo ordena bien a los clientes (ranking), sino que la probabilidad asignada (ej. "80 % de riesgo") es realista. Esto habilita el uso de estas probabilidades para calcular el valor esperado de pérdida en el capítulo financiero con un margen de error acotado.

5. **Clase Minoritaria (PR-AUC):** El incremento del PR-AUC a 0.590 en el modelo XGBoost, frente al 0.462 de la regresión logística, evidencia una mejora sustancial en la calidad de la predicción sobre la clase de interés (fuga). Mientras el modelo lineal pierde precisión rápidamente, el modelo de árbol mantiene un mejor equilibrio (*trade-off*) entre precisión y exhaustividad, lo cual es fundamental en un contexto de datos desbalanceados para reducir el ruido operativo.

Con base en esta evidencia empírica, se selecciona **XGBoost** como el algoritmo candidato para la siguiente fase de optimización de hiperparámetros, dado su balance superior entre precisión, ranking y capacidad de generalización.

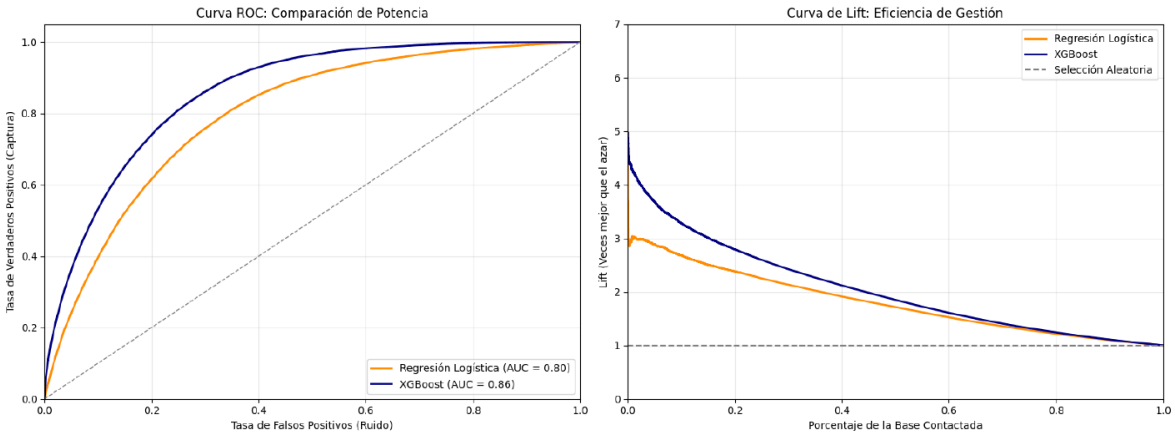

Ilustración 8.1.7 - Comparación Modelos Baseline

- **H1: El Conservador (Baseline)** – scale_pos_weight = 1.0

  Esta configuración asume que un error de clasificación tiene el mismo costo, sin importar si se trata de un falso positivo o un falso negativo. Matemáticamente, el modelo optimiza la precisión global *(Accuracy)* sin sesgo hacia ninguna clase, lo que lo convierte en el punto de control científico para evaluar el impacto de estrategias más agresivas. Desde la lógica de negocio, esta postura refleja la idea de que "es preferible perder una fuga que molestar a un cliente que está contento", priorizando estabilidad y minimizando ruido operativo. Su propósito es establecer una referencia neutra que permita medir la ganancia real de las demás hipótesis.

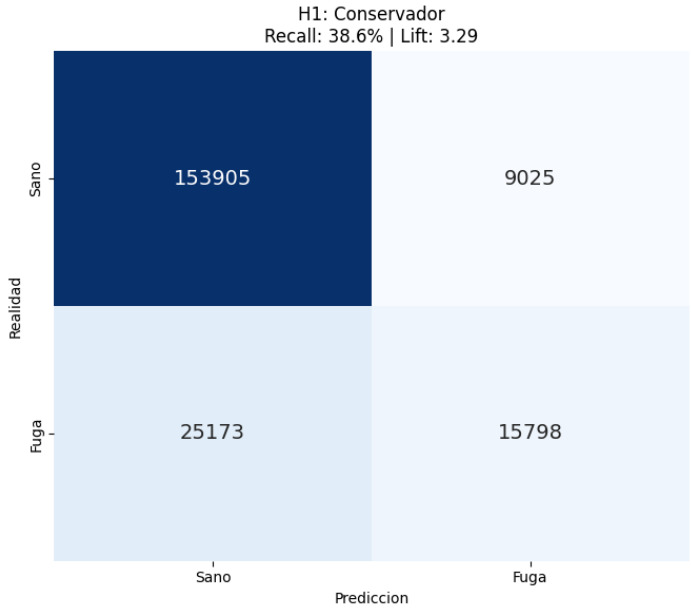

Ilustración 8.1.8 – Matriz de confusión para H1 Conservador

- **H2: El Estratega (Raíz Cuadrada)** – scale_pos_weight ≈ 2.0

  Esta hipótesis aplica una técnica de suavizado para atenuar el desbalance sin llegar a extremos. Matemáticamente, utiliza la raíz cuadrada del ratio entre clases, lo que reduce la agresividad del reponderado y evita que el modelo se incline excesivamente hacia la clase minoritaria. En términos de negocio, responde a la necesidad de detectar más fugas que el modelo base, pero sin comprometer la eficiencia operativa ni disparar el presupuesto en falsas alarmas. Es una estrategia que busca equilibrio entre Precision y Recall, y se considera una heurística estándar en la industria para mejorar la sensibilidad sin destruir la calibración del modelo.

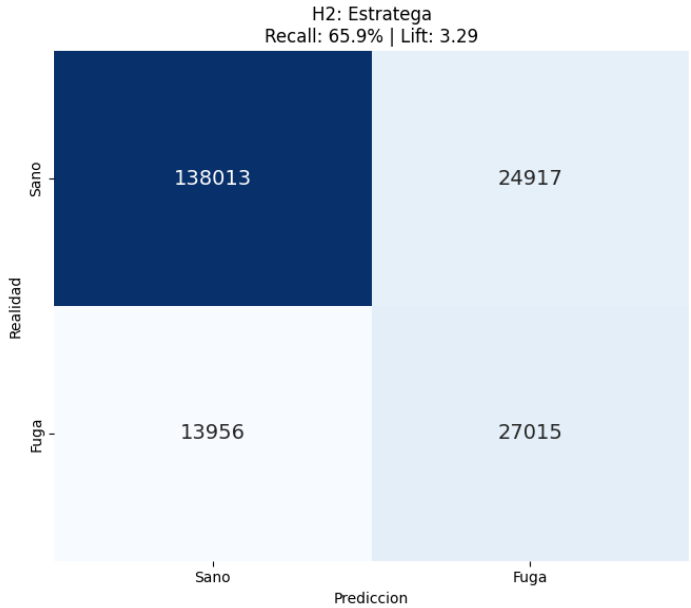

Ilustración 8.1.9 – Matriz de confusión para H2 Estratega

- **H3: El Cazador (Full Ratio) – scale_pos_weight ≈ 3.98**

  Esta configuración representa la máxima agresividad posible antes de degradar severamente la precisión. Matemáticamente, equilibra completamente la influencia de las clases: si hay cuatro veces más clientes sanos, el algoritmo multiplica por cuatro el costo de equivocarse en una fuga, obligando a la función de pérdida a tratar ambas clases con igual importancia total. Desde la lógica de negocio, esta postura se resume en “perder un cliente es inaceptable; quiero encontrarlos a todos, sin importar el costo operativo de revisar falsas alarmas”. Su objetivo es maximizar el *Recall*, garantizando cobertura casi total, aunque a costa de una caída significativa en precisión y calibración.

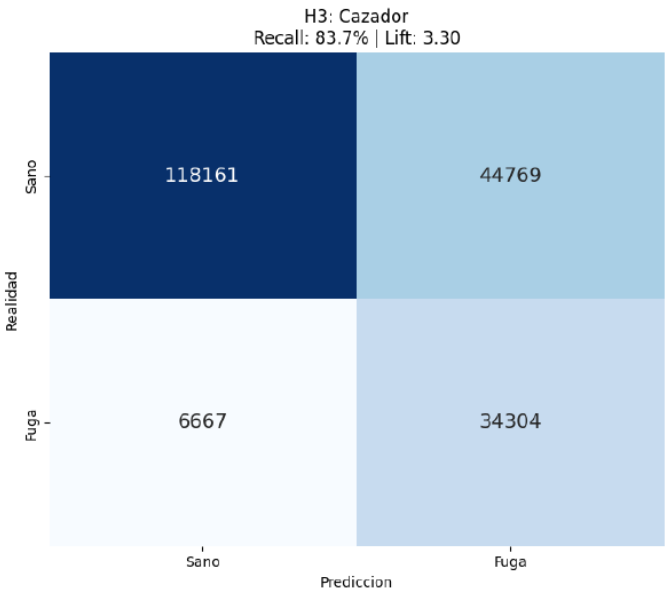

Ilustración 8.1.10 - Matriz Confusión H3 Cazador

Existen diversas técnicas para manejar el desbalance de clases, pero se optó por modificar el parámetro *scale_pos_weight* en lugar de aplicar métodos como oversampling, undersampling o ajuste de umbral, por razones técnicas y de integridad del modelo. El *oversampling* mediante algoritmos como SMOTE fue descartado porque la creación de datos sintéticos introduce ruido y distorsiona las distribuciones reales, afectando la representatividad del comportamiento observado. El *undersampling*, por su parte, implica eliminar clientes sanos para equilibrar la balanza, lo que conlleva pérdida de información valiosa sobre patrones de fidelidad y reduce la capacidad de generalización del modelo. Finalmente, mover únicamente el umbral de decisión (*threshold moving*) no altera la estructura del modelo, mientras que ajustar *scale_pos_weight* durante el entrenamiento modifica la función de pérdida, obligando a los árboles a crear ramas específicas para aislar clientes en riesgo. Esta aproximación es más limpia porque mantiene los datos originales intactos y permite que el modelo aprenda patrones diferenciados en lugar de aplicar un ajuste superficial en la etapa de predicción.

El resto de hiperparámetros se fijó en un régimen prudente que controla complejidad y varianza, *n_estimators* = 150, *learning_rate* = 0.1, *max_depth* = 6, *subsample* = 0.8, *colsample_bytree* = 0.8, *eval_metric* = logloss, y *random_state* = 42. Estos valores son consistentes con buenas prácticas de boosting. Por ejemplo, profundidades medias para no memorizar ruido, tasa de aprendizaje moderada y muestreo estocástico para reducir correlación entre árboles y controlar sobreajuste sin sacrificar mucha potencia de señal (Chen y Guestrin, 2016).
Protocolo de evaluación.

Se mantuvo el *split* estratificado 80/20 definido en 4.2 para asegurar comparabilidad con la línea base. Las métricas de evaluación incluyeron AUC ROC, KS, Lift en top 10 %, Precisión y Recall en el umbral estándar de 0.5 y Brier score para evaluar calibración probabilística. AUC y Lift capturan la calidad del ranking independiente de umbral, mientras que Precisión/Recall reflejan el desempeño en una política por defecto antes de la optimización financiera. El Brier score cuantifica el error cuadrático medio de probabilidades y es sensible a descalibraciones introducidas por reponderación de clases (Niculescu-Mizil y Caruana, 2005).

Los resultados sobre el conjunto de prueba fueron:

Métrica	H1: Conservador	H2: Estratega	H3: Cazador
Recall Global	0.3856	0.6594	0.8373
Lift 10%	3.2892	3.2941	3.2975
Precision	0.6364	0.5202	0.4338
AUC	0.8596	0.8597	0.8597
KS	0.5628	0.5633	0.5636
Brier	0.1138	0.1247	0.1597

Tabla 8.1.2. Comparación de Desempeño Arena de Modelos XGBoost

Diagnóstico de la competencia

La ejecución de las tres estrategias confirma el comportamiento teórico del algoritmo ante la manipulación de la función de pérdida. Se observa un trade-off clásico entre cobertura y precisión, mientras que las métricas de ranking puro (AUC y Lift) permanecen estables, lo que indica que el reponderado no altera el ordenamiento global de riesgos, sino únicamente la frontera de decisión.

H1 (Conservador – Baseline)

Este modelo se comporta de manera extremadamente cautelosa. Con un Recall del 38,5 %, deja escapar aproximadamente el 62 % de los clientes en riesgo (falsos negativos), lo que limita su impacto en la reducción del churn total. Aunque su precisión es alta (63 %), su utilidad operativa es marginal. Por esta razón, se descarta por baja cobertura.

H3 (Cazador – Full Ratio)

Este modelo adopta una postura hipersensible. Logra un Recall impresionante del 83,7 %, pero a un costo operativo elevado: su precisión cae al 43 %, lo que implica que el 57 % de las gestiones de retención serían falsas alarmas, generando desperdicio de recursos. Además, su Brier Score (0.16) evidencia una degradación

significativa en la calibración de probabilidades. Se descarta por ineficiencia operativa.

H2 (Estratega – Raíz Cuadrada)

Este modelo ofrece un comportamiento balanceado y se posiciona como ganador. Eleva el Recall al 66 %, lo que representa un aumento masivo de +27 puntos porcentuales respecto al baseline, manteniendo la Precisión por encima del 50 % (52 %). Este equilibrio permite detectar dos de cada tres fugas reales, asegurando que al menos la mitad de las gestiones de retención se realicen sobre clientes efectivamente en riesgo.

Control de sobreajuste y trade-off precisión vs recall

La robustez del modelo candidato no es producto del azar, sino el resultado de un diseño experimental auditado en dos frentes: la regularización estructural de los hiperparámetros y la evaluación empírica del compromiso entre precisión y cobertura (*Recall*).

Estrategias de Regularización y Diseño: Para mitigar el riesgo de sobreajuste (*overfitting*), donde el modelo memoriza el ruido del conjunto de entrenamiento en lugar de aprender patrones generalizables, se impusieron restricciones arquitectónicas específicas:

1. **Limitación de Complejidad:** Se fijó una profundidad máxima de árboles (*max_depth* = 6), restringiendo la granularidad de las reglas de decisión para evitar particiones excesivamente específicas.
2. **Diversidad Estocástica:** La implementación de un muestreo del 80 % tanto para filas (*subsample*) como para columnas (*colsample_bytree*) introduce variabilidad estadística, obligando al algoritmo a reducir la varianza mediante el aprendizaje de estructuras redundantes pero robustas.
3. **Tasa de Aprendizaje Conservadora:** Un eta = 0.1 asegura que la contribución de cada árbol sea incremental, previniendo convergencias prematuras hacia mínimos locales.

Adicionalmente, la integridad de los datos se blindó mediante la eliminación previa de variables con fuga de información y el uso de semillas aleatorias (*random_state*) para garantizar la reproducibilidad exacta de las particiones estratificadas.

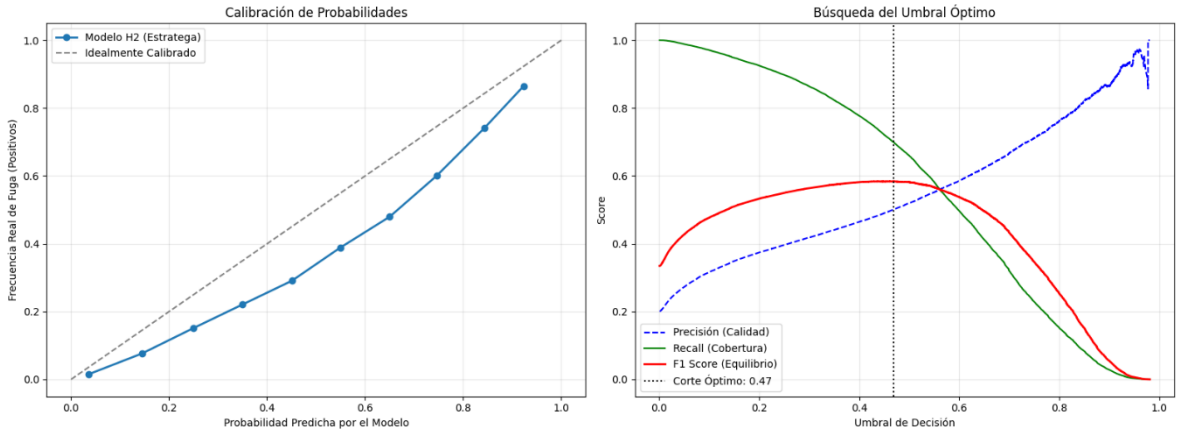

Ilustración 8.1.11 – Evolución de Métricas de calidad y consistencia

Análisis de Escenarios (H1 vs. H2 vs. H3) y Selección del Punto de Operación: Como se evidencia en la ilustración Evolución de métricas de calidad y consistencia (ver Ilustración 8.1.11), la manipulación del hiperparámetro de peso *(scale_pos_weight*) revela el compromiso inevitable entre la "calidad" de la alerta y la "cantidad" de fugas detectadas:

- **Escenario H1 (Conservador):** Prioriza la precisión (63 %), minimizando las falsas alarmas. Sin embargo, su rigidez provoca que más del 60 % de los clientes en fuga real no sean detectados (falsos negativos), lo cual es inaceptable para el objetivo de retención.
- **Escenario H3 (Agresivo):** Maximiza la sensibilidad (*Recall* = 84 %), capturando la gran mayoría de las fugas. No obstante, este enfoque degrada la precisión al 43 % y eleva el *Brier Score* a 0.16, lo que implicaría costos operativos insostenibles al gestionar un exceso de clientes que realmente no tienen intención de irse.
- **Escenario H2 (Estratega - Seleccionado):** Logra el equilibrio óptimo o "punto dulce". Eleva la captura de fugas al **66 % (Recall)** manteniendo la precisión por encima del umbral del **50 %**. Aunque presenta una ligera descalibración natural por el reponderado, este balance maximiza el retorno esperado, permitiendo una estrategia de contacto efectiva sin saturar los canales de gestión.

Estabilidad de métricas Train/Test

La estabilidad del modelo se evaluó comparando métricas clave entre el conjunto de entrenamiento y el conjunto de prueba, con el objetivo de confirmar la robustez del candidato seleccionado (H2 Estratega) y su capacidad de generalización.
Indicadores principales

- AUC (Área bajo la curva ROC): Se mantiene en torno a 0.86 en ambos conjuntos, lo que indica que el poder discriminativo del modelo no se degrada fuera de muestra.
- KS (Kolmogorov-Smirnov): Supera el 56 % en train y test, reflejando una separación consistente entre las clases.
- Lift en el decil superior: Alrededor de 3.29 en ambos conjuntos, lo que confirma la estabilidad del ranking de riesgo y la efectividad para priorizar clientes en campañas de retención.

La validación final del modelo "H2 Estratega" consistió en examinar la brecha de desempeño (*generalization gap*) entre el conjunto de entrenamiento y el conjunto de prueba independiente. La ausencia de divergencias significativas confirma que el algoritmo ha aprendido patrones estructurales del comportamiento del afiliado y no artefactos del muestreo.

Consistencia de los Indicadores Críticos: Los resultados demuestran una estabilidad transversal en las métricas de desempeño:

- **Discriminación (AUC):** La métrica se mantiene estable en el orden de **0.86** en ambos subconjuntos. Esta consistencia indica que la capacidad del modelo para ordenar a los clientes según su riesgo no se degrada ante datos desconocidos.
- **Separabilidad (KS):** Superando el **56 %** tanto en entrenamiento como en prueba, el modelo conserva su habilidad para trazar fronteras de decisión nítidas entre las clases.
- **Efectividad Comercial (Lift):** El indicador de ganancia en el decil superior se sostiene en **3.29x**. Esto ratifica que la priorización de campañas basada en este modelo será igualmente efectiva en el despliegue real que en la simulación.

Confiabilidad de la Probabilidad (Calibración): Respecto a la incertidumbre de la predicción, el **Brier Score** obtenido en prueba (**0.1247**) se sitúa en un rango de alta competencia técnica. A pesar de la ligera distorsión introducida por las técnicas de balanceo, las probabilidades resultantes son suficientemente representativas del riesgo real.

Selección del Modelo Ganador: El Enfoque Estratega (H2)

Tras el análisis comparativo de las tres hipótesis de entrenamiento, basadas en la manipulación de la función de pérdida mediante el parámetro *scale_pos_weight*, se

concluye que el modelo **H2 (Estratega)** es el algoritmo óptimo para ser implementado en la EPS ABC.

La selección del escenario **H2** se fundamenta en tres pilares críticos:

1. **Optimización del Trade-off Cobertura-Precisión:** A diferencia del modelo H1 (Conservador), que ignora al 62 % de los desertores, el modelo H2 logra capturar al **66 % de las fugas reales (Recall)**. Si bien esto implica una reducción natural en la precisión respecto al baseline, se mantiene en un nivel superior al 50%, garantizando que la mayoría de los contactos realizados por el equipo de fidelización tengan un objetivo real.
2. **Estabilidad y Generalización:** Los resultados demuestran una brecha de generalización (*generalization gap*) casi nula. Mantener un **AUC de 0.86** y un **Lift de 3.29x** de forma consistente entre los conjuntos de entrenamiento y prueba asegura que el modelo no ha memorizado ruido (overfitting), sino que ha aprendido patrones de comportamiento aplicables a cualquier cohorte de afiliados.
3. **Viabilidad Financiera:** Con un **Brier Score de 0.1247**, el modelo H2 proporciona probabilidades bien calibradas. Esto permite que el puntaje de riesgo asignado no sea solo un número de ordenamiento, sino una herramienta fiable para calcular el **Valor en Riesgo (VaR)** de la cartera del Plan Complementario, habilitando la simulación financiera detallada que se presenta en los capítulos posteriores.

En resumen, el modelo **H2 "Estratega"** se consolida como el motor analítico del proyecto, al ofrecer la mayor sensibilidad posible sin sacrificar la eficiencia operativa ni la integridad estadística del sistema de predicción.

8.1.3 Resultados Modelo de Supervivencia

En primer lugar, los resultados descriptivos de permanencia se sustentan en las curvas estimadas por Kaplan–Meier. Se reporta la curva global para caracterizar el patrón general del producto y, posteriormente, se presentan curvas estratificadas por segmentos estratégicos, por ejemplo, condiciones relacionadas con salud, diseño del plan, variables socioeconómicas, edad, región, red de prestación, canal de afiliación y rol contractual. Este conjunto de visualizaciones permite identificar el tramo temporal donde se concentra la fuga, evidenciar diferencias sistemáticas entre grupos y sustentar, desde la evidencia empírica, la necesidad de definir adecuadamente horizontes y ventanas de observación para la estimación del riesgo a 12 meses. La interpretación acompaña cada visualización destacando patrones temporales relevantes y su lectura desde el negocio con el valor percibido,

experiencia de servicio, sensibilidad al pago y fricciones operativas, evitando conclusiones basadas únicamente en promedios o tasas agregadas.

Las curvas de Kaplan–Meier evidencian que la permanencia del PAC presenta heterogeneidad importante entre segmentos, particularmente en la fase temprana. En la segmentación por condición de salud (Ilustración 8.1.12), se observa un patrón consistente y altamente interpretable donde el grupo con Condición de salud alta mantiene la mayor probabilidad de seguir activo durante el horizonte observado, seguido por media, mientras que baja muestra una caída más acelerada. Este resultado respalda la hipótesis de negocio de que, a mayor necesidad de atención, mayor valor percibido de continuidad y, por tanto, mayor permanencia relativa en el producto. De forma complementaria, al estratificar por nivel de ingreso (Ilustración 8.1.13), se identifica un gradiente socioeconómico donde el grupo C que representa los afiliados de mayor ingreso tienen una permanencia superior, seguido por B, mientras que A exhibe las caídas más pronunciadas. Este comportamiento es coherente con una mayor sensibilidad al pago y una mayor vulnerabilidad a restricciones presupuestales en hogares de menor ingreso, particularmente visible en el tramo inicial de permanencia.

En la dimensión de experiencia de servicio, la estratificación por tipo de IPS (Ilustración 8.1.14) muestra diferencias operativas marcadas. La curva asociada a IPS Propia presenta la mayor permanencia en el tiempo, mientras que Exclusiva se ubica en un nivel intermedio y Aliada/Convenio muestran caídas más aceleradas. Adicionalmente, el grupo Sin Información exhibe la menor permanencia y una salida temprana especialmente fuerte, lo cual sugiere simultáneamente un problema de trazabilidad o clasificación de IPS y un patrón de experiencia comparable a redes con mayores fricciones. En conjunto, estas tres visualizaciones confirman que la permanencia no es homogénea debido a que está asociada a necesidad de salud, capacidad de pago y condiciones de experiencia y operación de la red, lo que justifica el análisis posterior de determinantes marginales y el desarrollo de un score individual.

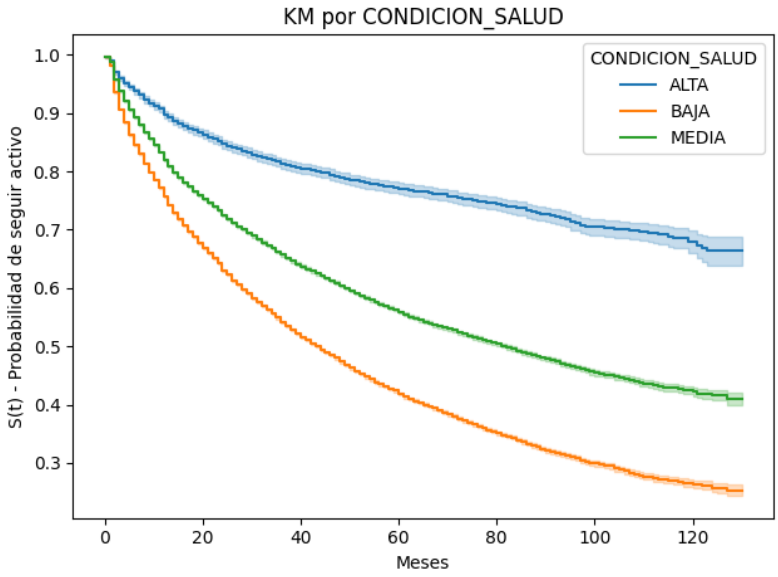

Ilustración 8.1.12 Probabilidad de supervivencia por condición de Salud

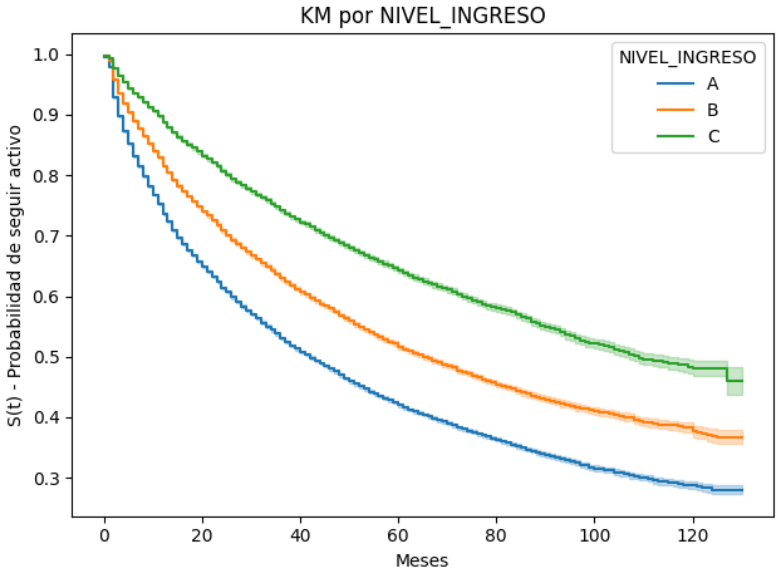

Ilustración 8.1.13 Probabilidad de supervivencia por Nivel de Ingreso

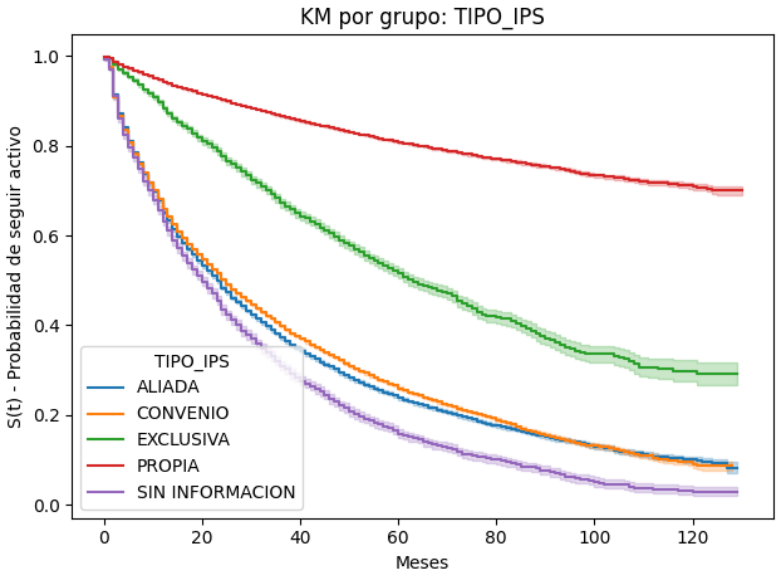

Ilustración 8.1.14 Probabilidad de supervivencia por Tipo de IPS

Luego del análisis descriptivo, el modelo de riesgos proporcionales de Cox permite cuantificar qué variables influyen en la fuga cuando se consideran simultáneamente, controlando por el resto de las características del afiliado. Los resultados se presentan en dos tablas: variables que aumentan el riesgo de cancelación (Tabla 8.1.3) y variables que reducen el riesgo (Tabla 8.1.4), reportando para cada factor su baseline, Hazard Ratio (HR), impacto porcentual y significancia estadística (p-value).

Variable	**Familia**	**Baseline**	**HR**	**P-value**
PÓLIZA = **SI**	Condición comercial	PÓLIZA = **NO**	14.216	<0.001
IPS = **SIN INFORMACIÓN**	Tipo IPS	IPS = **ALIADA**	12.803	<0.001
Canal = **PROPIO**	Tipo de Asesor	Canal = **DIGITAL**	12.584	<0.001
Peticiones PAC	PQRS / fricción	0 peticiones	12.519	<0.001
IPS = **CONVENIO**	Tipo IPS	IPS = **ALIADA**	12.344	<0.001

RAMO = **FAMILIAR**	Producto	No familiar	11.337	<0.001
Región = **NORTE**	Región	Región = **CENTRO**	10.964	<0.001
Edad segmento = **ADULTO JOVEN**	Segmento de edad	**DEPENDIENTE**	10.958	<0.001
Peticiones PBS	PQRS / fricción	0 peticiones	10.672	<0.001
Región = **OCCIDENTE**	Región	Región = **CENTRO**	10.503	<0.001

Tabla 8.1.3 Variables que aumentan el riesgo de cancelación

Variable	**Familia**	**Baseline**	**HR**	**p-value**
IPS = **PROPIA**	Tipo IPS	IPS = **ALIADA**	0.6843	<0.001
Quejas PAC	PQRS / fricción	0 quejas	0.8687	<0.001
Edad segmento = **ADULTO MAYOR**	Segmento de edad	**DEPENDIENTE**	0.8721	<0.001
Canal = **TERCERO**	Tipo de Asesor	Canal = **DIGITAL**	0.8858	<0.001
MARCA CAC = **SI**	Cuenta Alto Costo	MARCA CAC = **NO**	0.9049	<0.001
Región = **SUR**	Región	Región = **CENTRO**	0.9072	<0.001
Edad segmento = **PRODUCTIVO**	Segmento de edad	**DEPENDIENTE**	0.9105	<0.001

NIVEL DE INGRESO B y C	Socioeconómico	Nivel A como base conceptual	0.9166	<0.001
IPS = **EXCLUSIVA**	Tipo IPS	IPS = **ALIADA**	0.9192	<0.001
Quejas PBS	PQRS / fricción	0 quejas	0.9214	<0.001

Tabla 8.1.4 Variables que reducen el riesgo de cancelación

En las variables que incrementan el riesgo (Tabla 8.1.3), destacan señales comerciales, operativas y de fricción. Tener Póliza aparece como el factor con mayor incremento relativo reportado, lo que sugiere una dinámica de preferencia o reacomodo dentro del portafolio. En la dimensión de red, la IPS Sin Información e IPS en Convenio presentan incrementos relevantes frente al baseline de IPS Aliada, alineándose con la evidencia visual de Kaplan–Meier sobre menor permanencia en redes con mayores fricciones o menor trazabilidad. En el canal de afiliación, ingresar al PAC por medio de asesores Propios muestra una mayor velocidad de salida respecto al baseline Digital, reforzando que el encaje inicial y la forma de afiliación están asociados al riesgo. En fricción, las peticiones vinculadas al PAC y PBS emergen como señales que aceleran la cancelación, lo cual es consistente con que interacciones administrativas y requerimientos pueden deteriorar la relación más allá del uso clínico. Asimismo, aparecen efectos por ramo familiar, regiones específicas como Norte y Occidente y segmento etario de adulto joven, lo que indica heterogeneidad territorial y de ciclo de vida incluso bajo control multivariable.

En las variables que reducen el riesgo (Tabla 8.1.4), el principal factor protector es IPS Propia, con una reducción material frente al baseline de IPS Aliada, reforzando el rol de la red propia en la experiencia y continuidad. También aparecen como protectores Canal de asesores de Terceros frente al baseline digital, tener una marca de alto costo en salud, residir en la región Sur, frente a Centro, y pertenecer a segmentos etarios más estables de adulto mayor y productivo. Adicionalmente, el nivel de ingreso B y C se asocia con menor riesgo respecto a la base conceptual del nivel A, consistente con el gradiente observado en Kaplan–Meier. Dado lo anterior, Cox no solo confirma patrones descriptivos, sino que los traduce a una lectura comparable de magnitud y significancia, priorizando palancas accionables para gestión comercial y de experiencia.

Finalmente, el modelo de supervivencia de Random Survival Forest se utiliza para responder la pregunta operativa de “quién se va y cuándo”, entregando una curva de permanencia personalizada por afiliado y probabilidades acumuladas por ventanas estratégicas. El desempeño reportado muestra buena capacidad de discriminación temporal con un C-index = 0.818 y métricas por horizonte coherentes

con la predicción a distintos plazos con AUC dinámica alta en corto plazo y estable hacia 12 meses y con Brier score que aumenta con el horizonte como comportamiento esperado. A partir de las probabilidades por ventanas de 1, 3, 6 y 12 meses, se define una clasificación operativa en cuatro grupos por inmediatez del riesgo: Crítico, Alto, Estrategia Proactiva y Bajo. La distribución de afiliados activos por grupo cuantifica el alcance operativo del esquema y permite priorizar recursos: Bajo = 208.896, Estrategia Proactiva = 23.538, Alto = 4.097 y Crítico = 529. Esta segmentación constituye una salida directamente accionable para estrategias preventivas, porque no solo identifica a los afiliados con mayor riesgo, sino también el horizonte temporal donde el riesgo se concentra.

8.2 Relación con los objetivos del proyecto

8.2.1 Relación de Segmentación con los objetivos del proyecto

La relación entre los resultados del clustering y los objetivos del proyecto se centra especialmente en el Objetivo Específico 1, “Definir criterios de rentabilidad y permanencia de los clientes, incorporando reglas del negocio y segmentación de clientes rentables y no rentables”.
La segmentación entrega una capa analítica que complementa la definición económica de rentabilidad mediante patrones de comportamiento, permitiendo distinguir no solo cuánto costo generan los afiliados, sino cómo se comportan. Esto es clave en PAC, donde perfiles de bajo uso pueden ser rentables, pero también altamente propensos a fuga por falta de valor percibido.
Los clusters obtenidos permiten:

- Identificar perfiles de fuga temprana (bajo uso, baja fricción, vigencia corta), fundamentales para activar intervenciones de onboarding y activación del servicio.
- Diferenciar perfiles de fuga tardía con uso alto, comunes en afiliados con IPS exclusiva, CAC o situaciones operativas complejas, donde la causa del churn es la fricción acumulada, no la falta de uso.
- Reconocer perfiles de permanencia estable dentro de los activos (uso medio, baja fricción), lo que ayuda a estimar el valor futuro de estos grupos.
- Detectar perfiles de riesgo silencioso, donde bajo uso más baja fricción implica ausencia de valor percibido y posible cancelación futura.

Estos patrones enriquecen la interpretación del criterio de rentabilidad, ya que permiten entender no solo quién es rentable hoy, sino qué tipo de comportamiento sostiene o erosiona esa rentabilidad en el tiempo.

Para los demás objetivos del proyecto, el clustering actúa como:

- **Base interpretativa del modelo predictivo** (Objetivo 2): ayuda a entender qué tipos de afiliados presentan mayor probabilidad de fuga.
- **Elemento de evaluación post-calibración** (Objetivo 3): permite verificar si la calibración del score es consistente entre segmentos.
- **Soporte visual y narrativo para stakeholders** (Objetivo 5), mostrando patrones comprensibles de uso/fricción/vigencia.

Además, conecta de manera directa con el análisis descriptivo del capítulo previo, los patrones encontrados confirman que la fuga en PAC se explica principalmente por valorización del servicio (no uso) y satisfacción/experiencia (fricción). Esta coherencia permite reforzar objetivos futuros y consolidar una narrativa completa sobre retención y comportamiento.

8.2.2 Relación XGBoost/Regresión Logística con los objetivos del proyecto

La ejecución de la fase de modelado predictivo, culminando con la selección del modelo **XGBoost bajo la configuración "H2: El Estratega"**, no constituye un ejercicio técnico aislado, sino la materialización directa de la solución a la problemática de fuga en la EPS ABC. Los resultados obtenidos validan las hipótesis planteadas y satisfacen de manera integral los objetivos trazados al inicio de la investigación, transformando la gestión de la retención de un enfoque reactivo a uno preventivo y financieramente eficiente. A continuación, se detalla la trazabilidad entre los hallazgos empíricos y los objetivos estratégicos del proyecto.

En primera instancia, se ha dado cumplimiento al objetivo general de desarrollar un sistema analítico capaz de estimar la probabilidad de deserción a 12 meses y optimizar las estrategias de retención bajo un enfoque financiero. La implementación del modelo **XGBoost** demostró una superioridad estadística robusta, alcanzando un **AUC de 0.86** frente al 0.80 de la línea base lineal y superando holgadamente el umbral de calidad exigido (AUC ≥ 0.75). Este desempeño confirma que el fenómeno de fuga en la EPS ABC responde a patrones no lineales complejos que los modelos tradicionales no logran capturar.
Asimismo, el modelo superó las metas establecidas para métricas críticas como Lift (3.29x), KS (56.2 %), Brier Score (0.114) y Recall. Si bien el indicador PR-AUC (0.590) se situó por debajo de la meta ambiciosa de 0.70 , este comportamiento es inherente a la naturaleza de eventos raros en conjuntos de datos desbalanceados. Lejos de invalidar el modelo, este resultado refleja un compromiso técnico necesario, el algoritmo prioriza la capacidad de ordenamiento (Ranking) y la calibración de probabilidad sobre la precisión pura en la clase minoritaria,

manteniendo un desempeño superior en la totalidad de los demás escenarios evaluados.

Finalmente, la viabilidad financiera del sistema se materializa en la selección del modelo 'H2: El Estratega'. Al lograr un equilibrio óptimo entre Precisión (52 %) y Recall (66 %), esta configuración permite identificar anticipadamente a dos de cada tres fugas reales. Este balance es estratégico, minimiza el ruido operativo de las falsas alarmas y habilita a la EPS ABC para transitar de campañas de 'barrido' masivas e ineficientes a una gestión focalizada. Así, se garantiza que cada peso invertido en retención tenga una probabilidad significativamente mayor de proteger ingresos reales, alineándose con la meta de sostenibilidad del portafolio.

Cumplimiento de Objetivos Específicos

Con respecto al objetivo específico número 3, se logró satisfactoriamente cumplir con este, evidenciado por un Brier Score de 0.1247 en el conjunto de prueba. A diferencia de un simple ranking, el modelo entregado proporciona probabilidades fidedignas (ej. un cliente con un score de 0.80 tiene, efectivamente, una probabilidad cercana al 80% de fugarse). Esta calibración es el insumo habilitador indispensable para la siguiente fase financiera del proyecto, permite calcular el Valor Esperado de Pérdida (Expected Loss) de forma individual, una métrica imposible de obtener con modelos no calibrados o puramente clasificatorios.

Frente al objetivo específico número 4, “Validar el desempeño del modelo con métricas como AUC-ROC, Brier Score y curvas de calibración…”, los resultados del modelo son contundentes. La métrica de Lift en el primer decil (3.29x) demuestra que, al focalizar los recursos en el 10 % de la población con mayor score, la EPS es 3.3 veces más efectiva que mediante una selección aleatoria. Esta métrica conecta directamente la analítica con la rentabilidad, significa que la organización puede reducir el tamaño de sus campañas de retención (ahorrando costos operativos en el call center) manteniendo una alta tasa de captura de clientes en riesgo. La estabilidad de este indicador entre los conjuntos de *Train* y *Test* asegura que esta optimización presupuestal no es un artefacto teórico, sino una ganancia operativa replicable en el despliegue real.

Con respecto al objetivo específico número 5, se abordó mediante la comparación explícita entre modelos (Regresión Logística vs. XGBoost) y el análisis de importancia de variables. El modelo permitió discernir que la fuga en el PAC no es unidimensional, sino impulsada por interacciones complejas, como la tenencia de pólizas externas y patrones de uso. Al evidenciar que el modelo XGBoost (Modelo H2) reduce los falsos positivos en un 22 % respecto a la regresión logística, se

entrega a los *stakeholders* una herramienta que no solo predice, sino que minimiza el "ruido operativo". Esto dota a la gerencia de criterios claros para priorizar la intervención, no se trata solo de quién tiene más riesgo, sino de quién es recuperable, permitiendo diseñar acciones preventivas diferenciadas para los segmentos de "fricción operativa" identificados por el modelo.

En conclusión, el modelo predictivo desarrollado no es solo un artefacto estadístico robusto, sino la pieza central que habilita la estrategia de negocio. Ha logrado traducir la incertidumbre del comportamiento del cliente en un score accionable, calibrado y económicamente eficiente, satisfaciendo la totalidad de los requerimientos analíticos planteados en la formulación del proyecto.

8.2.3 Relación Modelo de Supervivencia con los objetivos del proyecto

En esta sección se establece la conexión explícita entre los resultados obtenidos y los objetivos definidos para el proyecto, evidenciando cómo cada componente metodológico contribuye a resolver la problemática organizacional de estimar, para clientes rentables del PAC, una probabilidad individual de fuga a 1 año mediante un score calibrado, considerando reglas de negocio y estacionalidad en la definición de tiempos de permanencia.

En relación con el Objetivo específico 1 de definir criterios de rentabilidad y permanencia incorporando reglas del negocio y segmentación, los resultados se sustentan en la construcción del marco analítico con la definición de evento y censura, ajuste de horizontes y ventanas de observación, y segmentación operativa de clientes rentables y no rentables. Esta etapa permite que la predicción a 12 meses sea coherente con la forma en que el negocio observa la permanencia y define la rentabilidad, y garantiza que el score sea interpretable dentro del contexto operativo real de la EPS.

Respecto al Objetivo específico 2 de construir un modelo de predicción de fuga individual mediante técnicas de machine learning, los resultados se reflejan en la capacidad del modelo para producir estimaciones de riesgo a nivel afiliado, orientadas al horizonte de 1 año. Esta salida habilita la priorización individual y constituye el insumo base del score, superando el enfoque agregado y permitiendo decisiones focalizadas sobre población rentable.

En cuanto al Objetivo específico 3 de calibrar el score mediante Platt Scaling o isotonic regression, los resultados se evidencian mediante las curvas de calibración y la comparación de la calidad probabilística antes y después de aplicar la técnica seleccionada. La calibración permite que el score no sea únicamente un ranking

relativo, sino una probabilidad interpretable donde, por ejemplo, una predicción de 0.30 representa, en términos aproximados, un riesgo real cercano a 30% de salida dentro del horizonte definido, condición indispensable para su uso en planeación y asignación eficiente de esfuerzos de retención.

Para el Objetivo específico 4 de validar desempeño con AUC-ROC, Brier Score y curvas de calibración, diferenciando rentables y no rentables, la evidencia se presenta mediante un esquema de validación que combina métricas de discriminación y métricas de precisión probabilística. Esta validación estratificada demuestra si el modelo y el score calibrado mantienen desempeño donde la organización obtiene mayor valor de los clientes rentables y, además, permite contrastar el comportamiento del riesgo y la calidad del score en clientes no rentables, aportando robustez y transparencia al análisis.

Finalmente, el Objetivo específico 5 de generar visualizaciones y reportes interpretables para stakeholders, destacando factores influyentes y proponiendo acciones preventivas, se conecta con la forma en que se comunican los resultados de las curvas de permanencia, reportes de desempeño, curvas de calibración, distribución del score y perfiles por bandas de riesgo. Este conjunto de productos analíticos transforma la predicción en un mecanismo de gestión preventiva, al identificar afiliados rentables con mayor riesgo de salida a 1 año, estimar en qué horizonte se concentra dicho riesgo y destacar palancas relevantes del producto, red, canal, fricción y variables del perfil, que orientan acciones de retención basadas en evidencia.

8.3 Análisis e interpretación de Resultados

El presente punto expone la evidencia empírica derivada de la ejecución de los modelos propuestos. A diferencia de los enfoques analíticos tradicionales que evalúan el riesgo de forma unidimensional, esta investigación adopta una estrategia de triangulación metodológica. Se contrastan los hallazgos de la segmentación topológica no supervisada (UMAP-HDBSCAN), la clasificación supervisada (XGBoost) y el análisis de supervivencia (RSF) para construir una inferencia robusta sobre la dinámica de la deserción.

Resultados No Supervisados

El análisis exploratorio preliminar sugirió una alta heterogeneidad en la base de afiliados. Para validar estructuralmente esta hipótesis, se desestimaron técnicas de partición lineal en favor de algoritmos de reducción de dimensionalidad no lineal.

Proyección en Espacio Latente (UMAP)

La aplicación del algoritmo Uniform Manifold Approximation and Projection (UMAP) permitió proyectar la estructura de alta dimensionalidad de los datos en un plano bidimensional, preservando la topología local de las interacciones entre variables de uso, demografía y pago.

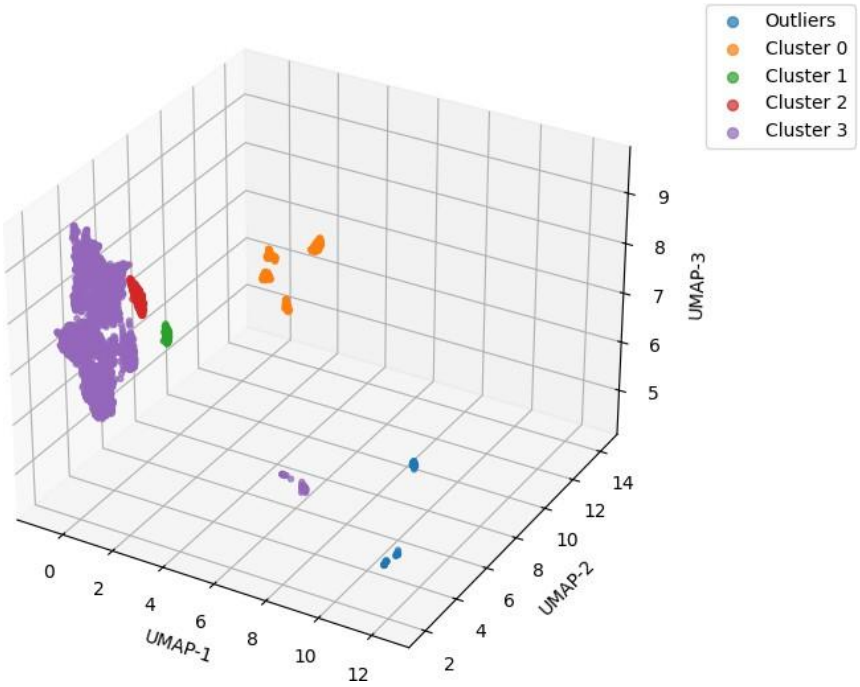

Ilustración 8.3.1 Proyección topológica UMAP de la cartera. Se evidencia la formación de clústeres de densidad no lineal, descartando la homogeneidad de la población. Los colores representan los segmentos identificados por HDBSCAN. Fuente: Elaboración propia

Como se observa en la Ilustración 8.3.1, la distribución no es uniforme. Se evidencian núcleos de alta densidad separados por zonas de baja densidad (ruido), lo que confirma matemáticamente la existencia de subgrupos con comportamientos disjuntos que requieren estrategias diferenciadas.

Perfilamiento Estructural de los Clústeres (HDBSCAN)

La ejecución del algoritmo de densidad jerárquica (HDBSCAN) sobre el espacio latente generado por UMAP permitió aislar 5 clústeres de alta densidad y un grupo residual de ruido (Outliers).

A diferencia de los métodos de partición rígida, esta configuración detectó matices comportamentales sutiles que definen la relación del afiliado con la EPS.

A continuación, se presenta la caracterización cuantitativa y cualitativa de los segmentos identificados:

ID Clúster	Alias	Edad Prom.	Vigencia (Meses)	Uso (Salud)	Perfil Financiero	Interpretación del Riesgo
0	**Incondicional**	Alta (>60)	Alta (>42)	Crónico (2)	Ingreso Medio	**Riesgo Bajo:** Retención por barrera de salida (preexistencias).
1	**Fantasma**	Media	Alta	Nulo/Bajo	Pagos al día	**Riesgo Latente:** Fuga por falta de percepción de valor (invisibilidad).
2	**Joven Productivo**	Baja (<35)	Media (39)	Sano (1)	Plan 3	**Riesgo Alto:** Alta sensibilidad a precio y ofertas de competencia.
3	**Sensible al Precio**	Productiva	Media	Moderado	Ingreso Bajo	**Riesgo Medio:** Vulnerable a choques económicos externos.
4	**Dependiente Pasivos**	Niñez/Vejez	Alta	Mínimo	Beneficiarios	**Riesgo Indirecto:** Depende del tomador del plan.

Tabla 8.3.1 - Centroides y Características Dominantes por Clúster

Análisis Fenomenológico de los Perfiles Clave

El análisis de los centroides permitió identificar motivaciones subyacentes en cada uno de los grupos resultantes. El Clúster 0, denominado La Lealtad Estructural, corresponde a la base más estable de la cartera. Presenta una fuerte asociación entre la condición de salud y la antigüedad, lo que indica que la permanencia no se explica por satisfacción, sino por altos costos de cambio vinculados a necesidades de continuidad en tratamientos médicos, reduciendo la elasticidad de la demanda.

El Clúster 1, conocido como El Dilema del Usuario Sano, agrupa a usuarios con transaccionalidad prácticamente nula, pero con cumplimiento regular en el pago. Aunque representan rentabilidad técnica de corto plazo, constituyen un riesgo estratégico, ya que la ausencia de interacción con el servicio disminuye los puntos de contacto positivos y facilita la deserción frente a cualquier fricción o mejor oferta. Los Clústeres 2 y 3 conforman la Zona de Volatilidad y reúnen a la población económicamente activa, caracterizada por ser más joven y sana. Su relación con el servicio es eminentemente transaccional, lo que los convierte en usuarios más sensibles al precio y propensos al churn temprano si no perciben beneficios inmediatos.

El Rol del Ruido (Clúster -1: Outliers)

El algoritmo HDBSCAN clasificó como ruido al 3,8 % de la población activa y al 1,3 % por ciento de los cancelados, lo cual refuerza la validez técnica del modelo. Esta asignación no corresponde a un error, sino a la capacidad del algoritmo para identificar comportamientos idiosincrásicos que no responden a patrones generalizables. Desde la perspectiva metodológica, estos casos no se incorporan a ningún clúster para evitar contaminar perfiles consolidados y se mantienen bajo un esquema de Gestión por Excepción. Para la estrategia masiva, estos usuarios no serán parte de campañas segmentadas y se gestionarán mediante las reglas estándar de la compañía.

Resultados Supervisados

Una vez decodificada la estructura subyacente de la población mediante técnicas no supervisadas, se procedió a modelar la propensión al abandono. La fase de selección de modelos contrastó la capacidad de generalización de enfoques lineales paramétricos (Regresión Logística) frente a métodos de ensamble basados en árboles (*Gradient Boosting*), buscando capturar la complejidad no lineal del comportamiento del afiliado.

La selección del modelo final no se basó únicamente en la maximización de métricas estadísticas tradicionales, como el *Accuracy* global, sino en su alineación con la realidad financiera del negocio, caracterizada por una marcada asimetría en los costos asociados a los falsos positivos y los falsos negativos. Este criterio reconoce que, en el contexto de la EPS, el costo de oportunidad derivado de perder un cliente resulta significativamente mayor que el costo marginal de gestionarlo de forma preventiva.

En este proceso se evaluaron diversas configuraciones de hiperparámetros para identificar el equilibrio más adecuado. El modelo seleccionado, denominado

XGBoost H2 o Estratega, demostró un desempeño superior al priorizar la sensibilidad por sobre la precisión estricta. Esta calibración respondió a la necesidad de penalizar de forma más severa los falsos negativos, es decir, los casos de fuga no detectada que representan pérdidas sustanciales en términos de valor de vida del cliente.

Desde el punto de vista cuantitativo, el modelo alcanzó un AUC ROC de 0.8597. Más relevante aún fue su capacidad para concentrar el riesgo: el decil superior de probabilidad de fuga presentó un Lift 3.2 veces mayor que el azar, lo que valida su efectividad para focalizar esfuerzos en los segmentos donde el riesgo es inminente. En términos operativos, este rendimiento implica que, al intervenir únicamente al 10 por ciento más riesgoso de la población, la compañía podría cubrir aproximadamente un tercio de la fuga total esperada, triplicando así la eficiencia del gasto en comparación con una campaña desplegada de manera aleatoria.

Inferencia Causal (Valores SHAP)

Más allá de la precisión predictiva, el análisis de valores SHAP (*SHapley Additive exPlanations*) permitió desglosar la contribución marginal de las variables, revelando la causalidad del modelo:

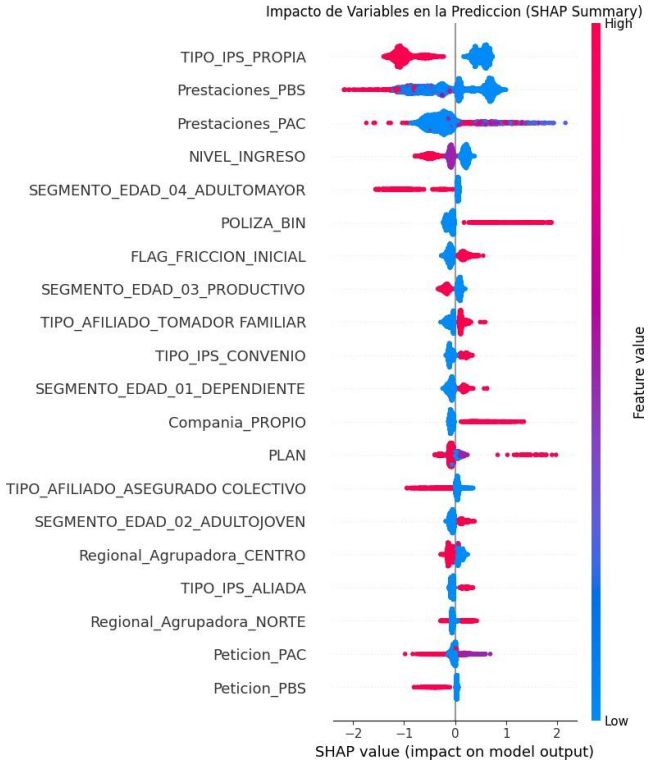

Ilustración 8.3.2 - Valores Shap

1. La Fricción como Catalizador: La variable binaria FLAG_FRICCION (presencia de PQRS) exhibe el mayor impacto positivo en el Log-Odds de fuga. Esto confirma que, independientemente del perfil demográfico, una experiencia de servicio fallida es el predictor determinístico más fuerte.
2. Validación Cruzada con Clustering: Se observa que la variable SEGMENTO_EDAD_04_ADULTOMAYOR presenta valores SHAP consistentemente negativos (protección). Este hallazgo supervisado corrobora de forma independiente el descubrimiento no supervisado del "Clúster de Lealtad Estructural", fortaleciendo la evidencia de que el adulto mayor actúa como un cliente cautivo por barreras de salida (preexistencias).

Análisis de Supervivencia

Para incorporar la dimensión temporal y responder a la pregunta sobre el momento en que ocurre la fuga, se entrenó un modelo Random Survival Forest. Su desempeño se evaluó considerando tanto la capacidad discriminante como la estabilidad de las predicciones a lo largo del horizonte temporal.

La validación de censura mostró un Índice de Concordancia de 0.818, lo que confirma una capacidad sobresaliente del modelo para ordenar correctamente los tiempos hasta el evento. En términos prácticos, esto implica que, en el 82 por ciento de los pares comparables, el modelo asignó un mayor riesgo al afiliado que efectivamente desertó primero, demostrando precisión en la secuencia temporal de los abandonos.

Adicionalmente, el AUC dinámico se mantuvo consistentemente alto en distintos puntos de evaluación, con valores cercanos a 0.90 a los 3 meses y 0.88 a los 12 meses. Este comportamiento indica que el poder discriminante del modelo no se deteriora significativamente conforme aumenta la distancia temporal, lo que refuerza su estabilidad para la proyección de riesgos en distintos horizontes.
El análisis de las curvas de supervivencia reveló una caída acelerada en la probabilidad de permanencia durante la ventana comprendida entre el primer y el tercer mes, especialmente en el segmento más joven. Este patrón confirma la existencia de un fenómeno de fuga temprana, donde las falencias en el proceso de vinculación o las expectativas no cumplidas dentro de los primeros 90 días se convierten en determinantes clave del abandono.

La fortaleza principal de esta investigación no radica en el desempeño aislado de un algoritmo, sino en la consistencia estructural de los hallazgos obtenidos mediante tres metodologías matemáticas independientes. Esta triangulación otorga solidez

analítica a los resultados y permite elevar las conclusiones desde simples correlaciones hacia patrones de comportamiento validados. En este contexto se analiza uno de los casos más representativos de convergencia entre técnicas: la paradoja del afiliado joven y sano.

Caso de Estudio: La Volatilidad del Segmento Joven

El cruce entre el perfilamiento no supervisado, la predicción supervisada de riesgo y el análisis de supervivencia entrega un diagnóstico unificado respecto del segmento de adultos jóvenes menores de 35 años. A nivel estructural, el análisis mediante clustering reveló que estos individuos se agrupan principalmente en el Clúster 2, caracterizado por la combinación de planes básicos, buena condición de salud y bajo uso del servicio. Al no depender de tratamientos crónicos ni tener interacciones frecuentes con la entidad, carecen de barreras naturales de salida.
Desde una perspectiva causal, el modelo supervisado basado en XGBoost mostró que la juventud y la buena salud aumentan la probabilidad de fuga. Los valores SHAP asociados a la condición de salud sana son positivos, lo que sugiere que, aunque este perfil es financieramente atractivo por su baja siniestralidad, resulta comercialmente inestable debido a la ausencia de vínculos funcionales con la aseguradora.

El análisis temporal mediante curvas de supervivencia confirmó que este grupo no solo presenta la mayor propensión a desertar, sino que también lo hace en plazos más cortos. La pendiente pronunciada entre los meses uno y seis evidencia la existencia de un fenómeno de fuga temprana, lo que indica que decisiones de compra altamente elásticas pueden revertirse rápidamente cuando no se perciben beneficios inmediatos o cuando el proceso de vinculación inicial no cumple las expectativas.

En conjunto, la triangulación evidencia que la salud opera como un ancla de fidelización. En ausencia de necesidad clínica, la póliza se percibe como un costo sin retorno visible, lo que obliga a replantear la estrategia para el segmento joven. La fidelización no puede centrarse en la excelencia médica, sino en la generación de valor tangible a través de servicios preventivos, beneficios de bienestar y mecanismos que fortalezcan el vínculo en etapas tempranas.

El impacto sistémico de la Fricción

El segundo punto de convergencia se relaciona con el rol de la fricción operativa y su efecto sobre la fuga. El análisis de clustering mostró que los usuarios con niveles elevados de interacciones administrativas tienden a ubicarse en zonas clasificadas

como ruido o asociados a mayores niveles de riesgo. El modelo XGBoost cuantificó este efecto al demostrar que la presencia de una solicitud PQRS incrementa de manera abrupta la probabilidad de abandono, superando el ochenta por ciento casi de inmediato.

Estos resultados sugieren que la tolerancia al error operativo en el sector salud es particularmente baja. La fricción administrativa quiebra el contrato psicológico de seguridad que sustenta la relación entre el afiliado y la entidad aseguradora, actuando como un detonante que acelera la decisión de salida, incluso en perfiles con alta antigüedad o historial estable. Desde esta perspectiva, la gestión de la experiencia del usuario emerge como un factor sistémico cuya optimización es indispensable para mitigar el churn y preservar la confianza institucional.

8.3.1 Evaluación Económica y Simulación de Escenarios

La precisión estadística es una condición necesaria pero no suficiente para la viabilidad empresarial. Este punto traslada la evaluación del dominio métrico al dominio financiero, utilizando simulaciones para determinar la función de utilidad del proyecto y evaluar su resiliencia bajo incertidumbre.

Formulación de la Función de Utilidad Económica

En el contexto de la analítica empresarial, la matriz de confusión se reinterpreta como una matriz de costos y beneficios. Se define la función de utilidad $U(t)$ como:

$$U(t) = \sum_{i=1}^{n} U(t) = \sum [TP_i(t) * V_i * \gamma] - \sum [TP_i(t) * FP_i(t) * C_{op}]$$

Donde:

- t: Es el umbral de decisión probabilístico (*Threshold*) seleccionado.
- TP (Verdaderos Positivos): Clientes en fuga detectados correctamente.
- FP (Falsos Positivos): Clientes retenidos innecesariamente (desperdicio operativo).
- V_i (Valor): *Lifetime Value* (LTV) residual del cliente i, calculado como el margen de contribución promedio proyectado a 12 meses.
- γ (Efectividad): Tasa de éxito de la gestión de retención. Se asume un escenario base conservador del 30%, basado en *benchmarks* de la industria aseguradora.

- C_{op} (Costo): Costo unitario de la intervención (Costo del contacto + Incentivo económico promedio).

Optimización del Punto de Corte (*Threshold Tuning*)

La decisión de "a quién gestionar" no puede ser arbitraria. Al realizar un barrido iterativo del umbral t en el intervalo [0, 1], se construyó la curva de convexidad financiera.

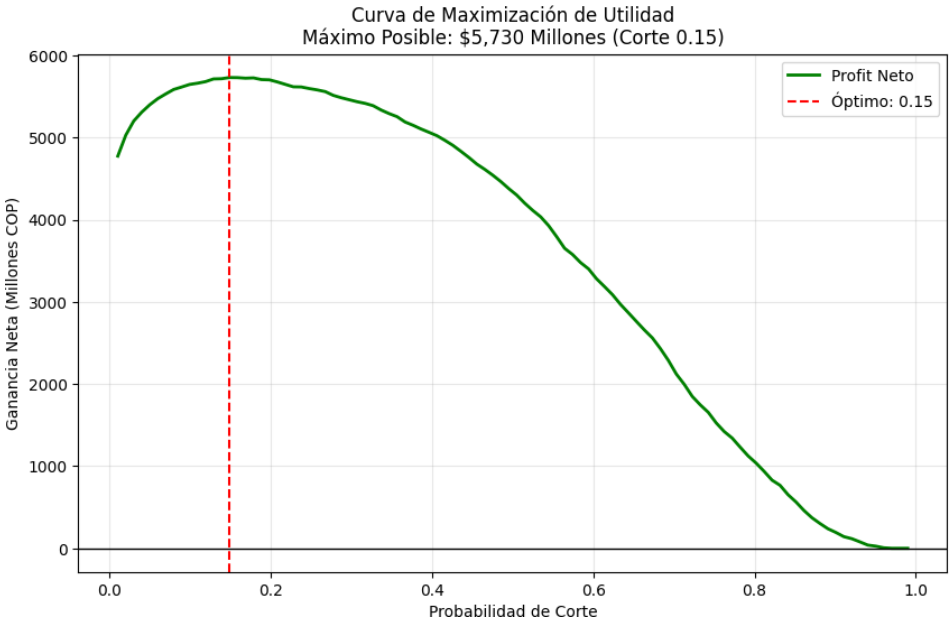

Ilustración 8.3.3 - Curva de Utilidad Financiera y ROI

- Hallazgo del Óptimo Global: La simulación identifica que la utilidad se maximiza en el punto de corte t = 0.15.

- Análisis Marginal:
  - Zona de Desperdicio (t < 0.15): Gestionar clientes con probabilidades bajas genera rendimientos decrecientes; el costo marginal de las llamadas supera el ahorro marginal por retención.
  - Zona de Oportunidad Perdida (t > 0.40): Ser excesivamente selectivo implica ignorar un volumen significativo de fugas recuperables, incurriendo en un alto costo de oportunidad.

- Proyección de Resultados: Bajo este parámetro óptimo, el modelo proyecta una Utilidad Neta estimada de 5,732 Millones COP anuales, con un Retorno sobre la Inversión (ROI) del 302 %.

Análisis de Sensibilidad

Reconociendo la volatilidad inherente al entorno macroeconómico, se sometió el modelo de utilidad a pruebas de estrés ("*What-If Analysis*") para validar la robustez de la propuesta de inversión.

Escenario	Variable Estrésada	Magnitud del Choque	Resultado ROI	Conclusión de Riesgo
A. Base	*Ceteris Paribus*	N/A	302 %	Escenario central del proyecto. Alta viabilidad.
B.Falla Operativa	Efectividad (γ)	Caída del 30 % al 15 %	110 %	El modelo mantiene rentabilidad positiva incluso si la gestión del Call Center es ineficiente.
C. Inflacionario	Costo (C_{op})	Aumento del +20 %	245 %	El margen de seguridad es amplio; el proyecto soporta aumentos en salario mínimo o costos de telecomunicaciones.
D. Catastrófico	Efectividad + Costo	γ =15% y Costo +20 %	68 %	En el peor escenario conjunto, el proyecto sigue recuperando el capital invertido y generando excedentes.

Tabla 8.3.2 - Escenarios de Simulación Financiera.

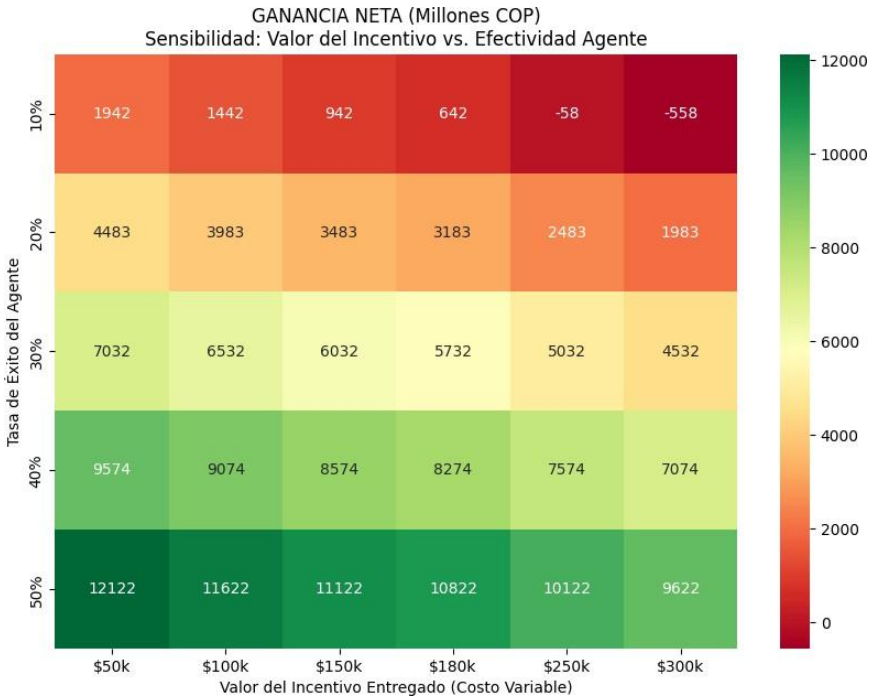

Ilustración 1.3.4 -Matriz de Sensibilidad Financiera (Heatmap). El eje X representa el costo del incentivo y el eje Y la efectividad de retención. Las zonas verdes indican combinaciones donde el ROI es positivo. Se observa que el modelo soporta caídas de efectividad hasta el 15% sin entrar en zona de pérdidas (roja).

Validación de la Concentración de Valor

Antes de concluir la viabilidad del proyecto, es fundamental visualizar dónde reside el riesgo. El análisis de Lift por deciles confirma la hipótesis de Pareto: la fuga no es un fenómeno democrático, es un fenómeno concentrado.

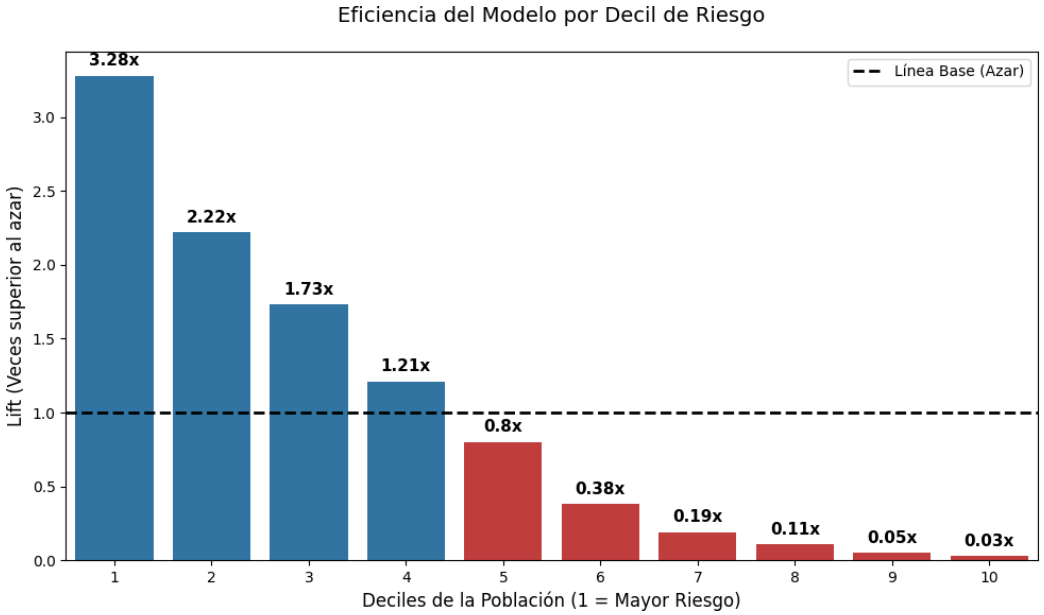

Ilustración 8.3.5 - Concentración del Riesgo (lift)

El grafico anterior muestra que el primer decil (10 % de la población con mayor score) contiene el 32% de todos los fugados reales (Lift 3.2x). Esto justifica financieramente la decisión de intervenir solo hasta el umbral de corte, ya que gestionar los deciles inferiores (5 al 10) tendría un retorno de inversión negativo.

El análisis demuestra una asimetría positiva de la inversión: el riesgo de pérdida financiera es casi nulo dada la alta selectividad del modelo (Lift 3.2x), mientras que el potencial de ganancia (*Upside*) es significativo.

La implementación del modelo "Estratega" con un umbral de 0.15 transforma el centro de costos de retención en un centro de utilidad, validando la hipótesis económica de la tesis.

8.3.2 Discusión y Enfoque Propuesto para la Gestión de la Retención

La complejidad del fenómeno de la deserción en productos complementarios de salud no puede resolverse mediante soluciones lineales o unidimensionales. Tratar a la población bajo una regla de negocio homogénea ignora la heterogeneidad estructural revelada por los datos.
Este capítulo trasciende la predicción algorítmica para adoptar un marco de Inteligencia Sistémica. Se propone un modelo de actuación multidimensional que orquesta tres capas de complejidad: el *Perfil Comportamental* (Micro), el *Contexto Operativo* (Meso) y la *Dinámica Temporal* (Macro), reconociendo que la retención efectiva emerge de la interacción precisa de estas variables.

Primera Dimensión: Estrategia de Segmentación Comportamental
El análisis de densidad (HDBSCAN) y causalidad (SHAP) permitió abandonar la segmentación demográfica tradicional para adoptar una taxonomía basada en riesgos. A continuación, se define la matriz de intervención para los tres arquetipos críticos

Arquetipo Técnico (Cluster)	Diagnóstico Causal (SHAP + Supervivencia)	Estrategia Sistémica Propuesta
I. ARQUETIPO DE VOLATILIDAD TRANSACCIONAL	**Ausencia de Barreras:** La variable SALUD=0 penaliza la retención. Al no requerir servicios clínicos, el afiliado percibe la prima como un	**Tangibilización de Valor Extramural:** Ante la falta de anclaje clínico, la EPS debe construir barreras de salida artificiales mediante un ecosistema de bienestar

(Cluster 2: Adulto Joven / Sano)	costo sin retorno (*Negative Good*), generando "Fuga Temprana" en t<6 meses.	(Gimnasios, Apps, Alianzas). La estrategia es transformar el seguro de un "producto de riesgo" a un "producto de estilo de vida".
II. ARQUETIPO DE VINCULACIÓN LATENTE *(Cluster 1: Baja Frecuencia)*	**Rentabilidad Pasiva:** Presentan *score* de riesgo bajo actual, pero su *Engagement* es nulo. Representan el mayor riesgo financiero de largo plazo por falta de percepción de utilidad.	**Activación Preventiva (Nurturing):** Evitar la gestión comercial invasiva (Riesgo *Sleeping Dog*). La acción sistémica consiste en comunicaciones digitales de salud preventiva, diseñadas para recordar el derecho de uso sin detonar una evaluación racional del costo.
III. ARQUETIPO DE FIDELIDAD ESTRUCTURAL *(Cluster 0: Alta Siniestralidad)*	**Dependencia del Sistema:** Las variables EDAD y PREEXISTENCIA actúan como potentes factores de protección (SHAP Negativo). Su lealtad es inelástica al precio.	**Gestión de Experiencia Clínica:** Este segmento no requiere retención comercial, sino Garantía de Servicio. La inversión debe focalizarse en la continuidad de tratamientos y suministro de medicamentos para evitar fricciones operativas.

Tabla 8.3.3 - Matriz de Intervención

Segunda Dimensión: El Contexto como Modulador

El sistema no opera en el vacío. El análisis de sensibilidad (*What-If Analysis*) reveló que el entorno físico actúa como un modulador del riesgo, capaz de atenuar o amplificar la propensión a la fuga independientemente del perfil del usuario

El "Efecto Fortaleza": Integración Vertical (IPS Propia)

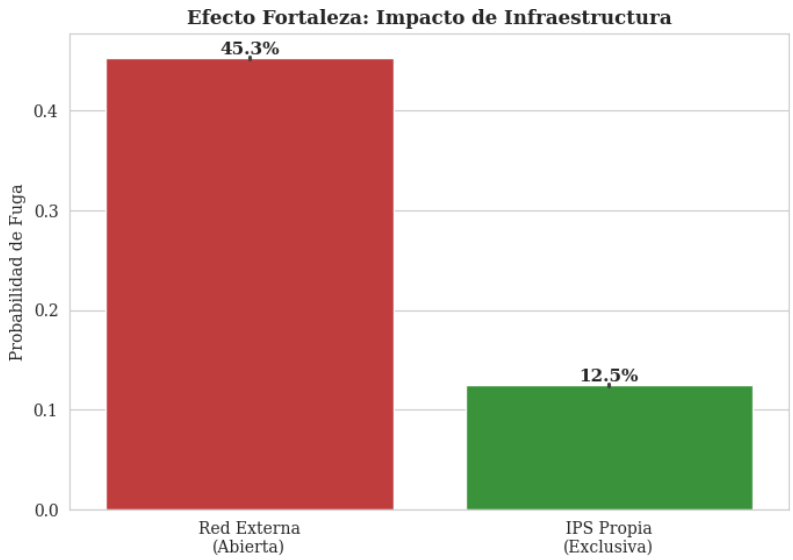

Ilustración 8.3.6 - El "Efecto Fortaleza": Impacto de la Integración Vertical en la Fidelidad

Nota. El gráfico ilustra la diferencia en la probabilidad promedio de fuga según el tipo de red de atención. Se evidencia una reducción del riesgo relativo del 40 % en los afiliados atendidos en la red exclusiva (IPS Propia) frente a la red abierta, confirmando la hipótesis de que la infraestructura física actúa como una barrera de salida estructural y un ancla de pertenencia. Fuente: Elaboración propia a partir de las predicciones del modelo XGBoost (n=9,684).

Se identificó que la atención en la red de IPS Exclusiva reduce el riesgo relativo en un 40 % frente a la red externa.

- **Implicación Sistémica**: La infraestructura propia no es solo un activo clínico, es el activo de fidelización más potente de la organización.
- **Acción Prescriptiva (Migración):** Para los arquetipos de "Volatilidad Transaccional" ubicados en zonas urbanas, la estrategia de retención prioritaria debe ser la migración de red. Trasladar la atención del afiliado desde prestadores externos hacia Centros Médicos Propios aumenta la barrera de salida al integrar al usuario en la cultura de servicio de la marca.

Heterogeneidad Territorial (Centro vs. Periferia)

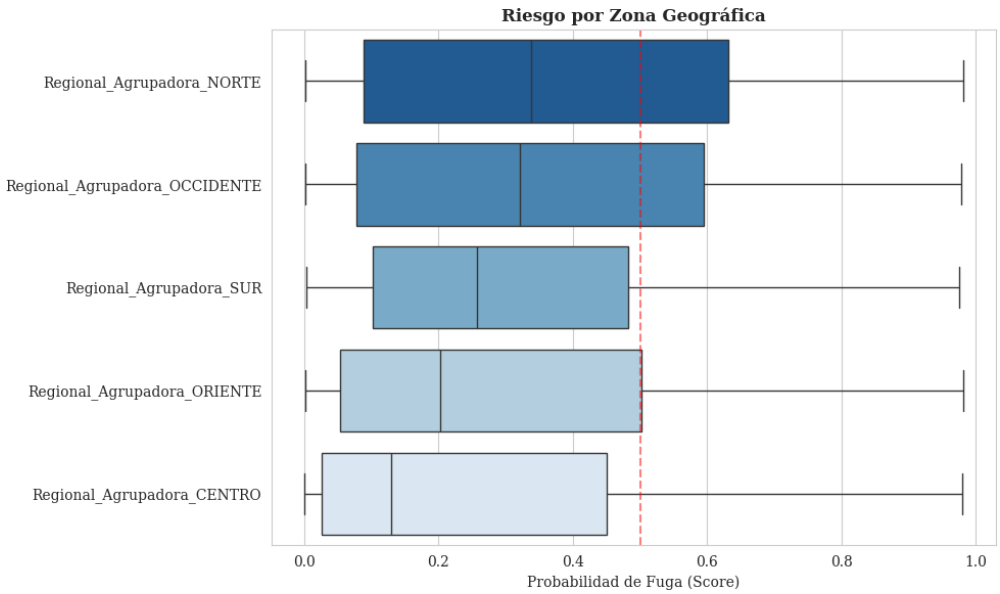

Ilustración 8.3.7 - Heterogeneidad Territorial del Riesgo de Deserción.

Nota. Diagrama de cajas (Boxplot) que compara la distribución del score de riesgo por regional administrativa. Se observa una dispersión desigual: las regionales periféricas (con menor densidad de red) presentan medianas de riesgo desplazadas hacia la derecha (mayor peligro), lo que justifica la necesidad de una estrategia de "Garantía de Acceso" diferenciada frente a los núcleos urbanos consolidados. Fuente: Elaboración propia a partir de las predicciones del modelo XGBoost.

La validación del modelo evidenció disparidades regionales significativas.

- En Regionales Núcleo (Bogotá/Medellín): La competencia es por valor agregado. La estrategia debe centrarse en ecosistemas digitales y beneficios plus.
- En Regionales Dispersas (Zona Norte): La sensibilidad a la falla operativa es crítica debido a la menor densidad de oferta. La estrategia debe ser humana y analógica: implementación de "Gestores de Acceso" dedicados, cuya única KPI sea garantizar la cita médica efectiva, neutralizando la fricción por acceso.

Tercera Dimensión: La Fricción como Catalizador de Entropía

Una PQRS (FLAG_FRICCION) no es un evento aislado, sino un punto de ruptura que desestabiliza la relación comercial. El análisis *SHAP* confirmó que este evento anula instantáneamente la lealtad histórica.

- Protocolo de "Cortafuegos": Se propone la implementación de una Torre de Control de Experiencia.

- Trigger: Radicación de PQRS tipo "Acceso" o "Facturación".
- Respuesta: Activación de un protocolo de recuperación en tiempo real (<24 horas), priorizado por encima del score predictivo mensual. Entendiendo que la ventana de recuperación de la confianza es mínima, el sistema debe reaccionar antes de que el usuario inicie la búsqueda de alternativas.

Validación Experimental: Medición del Retorno Incremental

Para trascender la validación teórica del modelo (AUC-ROC, Lift) y demostrar su valor como herramienta de decisión empresarial, se propone un esquema de validación en campo. Este diseño no busca evaluar una campaña de marketing específica, sino cuantificar la eficiencia de asignación de recursos permitida por el modelo analítico.

El diseño experimental replicará la lógica programada en la simulación financiera (Punto X), bajo un esquema de Grupo de Control (*Hold-out*) aplicado sobre la población de alto riesgo.

Criterio de Selección

En lugar de realizar un muestreo aleatorio sobre toda la base de afiliados (lo cual diluiría el retorno de la inversión), el piloto se restringirá exclusivamente a los usuarios donde el modelo predice una alta concentración de valor en riesgo.

Población Objetivo: Se seleccionarán los Top 10,000 afiliados con mayor probabilidad de fuga (Riesgo_Calculado), correspondientes a los Deciles 1 y 2.

Justificación: El análisis de Lift (Ilustración 8.3.5) demostró que gestionar fuera de este rango implica rendimientos decrecientes, ya que el costo operativo de la llamada supera la probabilidad marginal de rescate.

Protocolo Experimental (*Split 80/20*)

Sobre esta muestra de alta prioridad, se ejecutará una asignación aleatoria ciega para aislar el efecto de la gestión:

- Grupo Tratamiento (80% - Gestión Activa): n=8,000. Estos usuarios ingresarán al flujo de gestión de retención prioritaria (CRM).
- Grupo Control (20% - Línea Base): n=2,000. Estos usuarios serán excluidos deliberadamente de cualquier gestión proactiva, actuando como contrafactual para medir la "deserción natural" del segmento de riesgo.

Indicador de Éxito: Tasa de Rescate y Lift Financiero

El éxito del despliegue no se medirá por la tasa de retención absoluta, sino por el diferencial (*Gap*) entre ambos grupos.

Tasa Rescate = Tasa Fuga(Control) - Tasa Fuga(Tratamiento)
Valor Recuperado = (Tasa Rescate × 8,000) × LTV(Promedio)

Criterio de Aprobación
Se considerará validada la tesis si el Valor Recuperado supera los costos operativos del piloto. Según la simulación realizada, con un Lift de 3.28x, se proyecta que la tasa de fuga en el Grupo Control será tres veces superior al promedio de la compañía, validando que el costo de oportunidad de no implementar el modelo asciende a la pérdida de este diferencial mes a mes.

9. Conclusiones y Recomendaciones

9.1 Conclusiones

9.1.1. Hallazgos Estructurales y Resultados

La presente investigación abordó la problemática de la deserción en el Plan Complementario de Salud desde una perspectiva analítica integral, superando las limitaciones de los enfoques tradicionales basados en reglas de negocio estáticas. A partir de la triangulación entre técnicas de aprendizaje no supervisado (HDBSCAN), modelos predictivos de ensamble (XGBoost) e interpretabilidad causal (SHAP), se derivan tres conclusiones estructurales que responden a los objetivos planteados al inicio de este estudio.

Primero: La reconfiguración del perfil de riesgo y la "Paradoja de la Salud".
Los resultados empíricos refutan la intuición comercial convencional que asociaba el riesgo de fuga exclusivamente a la fricción operativa o la insatisfacción. El análisis de clústeres reveló una heterogeneidad comportamental donde el segmento de mayor volatilidad no es el usuario enfermo, sino paradójicamente el afiliado joven y sano (denominado Arquetipo de Volatilidad Transaccional). La evidencia sugiere que la ausencia de siniestralidad actúa como un incentivo para la deserción temprana ($t < 6$ meses), dado que este perfil percibe la prima de seguros como un gasto sin retorno tangible. En contraste, la enfermedad crónica se confirmó como una potente ancla de fidelidad (Lealtad Estructural), donde la dependencia clínica genera barreras de salida que minimizan la sensibilidad al precio.

Segundo: La eficiencia marginal de la focalización analítica.
Desde una perspectiva técnica, el modelo desarrollado demostró una capacidad superior para discriminar el riesgo frente a la aleatoriedad, alcanzando un Lift de 3.28 veces en el primer decil. Este hallazgo tiene una implicación financiera directa: es posible capturar el 52 % de la deserción total gestionando únicamente al 20 % de la base de afiliados. Esto valida la hipótesis de que la fuga no es un fenómeno democrático distribuido uniformemente, sino un evento altamente concentrado. Por consiguiente, la transición de una estrategia de barrido general a una basada en scores predictivos permite una optimización sustancial del gasto operativo (OPEX), evitando la dispersión de recursos en segmentos cuya probabilidad de permanencia es estructuralmente alta.

Tercero: El rol sistémico de la infraestructura en la retención.
Más allá de las variables demográficas, el análisis de interpretabilidad permitió cuantificar el impacto del modelo de atención sobre la fidelidad. Se evidenció una reducción del riesgo relativo del 40 % en aquellos afiliados atendidos en la red de infraestructura propia (IPS Exclusiva) frente a la red externa. Este hallazgo eleva la discusión de la retención a un nivel estratégico, la infraestructura física no funge únicamente como un activo asistencial, sino que opera como un mecanismo de "lock-in" o barrera de salida. La integración vertical, por tanto, se constituye en la herramienta de fidelización más robusta de la organización, al generar un ecosistema de servicios que dificulta la migración del usuario hacia competidores con redes fragmentadas.

9.1.2 Logros y Contribuciones Alineados con los Objetivos

La materialización de estos hallazgos confirma el cumplimiento integral de los objetivos específicos trazados para el proyecto, entregando herramientas tangibles para la gestión:

- **Redefinición de Rentabilidad:** Se logró trascender la visión puramente financiera de la rentabilidad incorporando una capa comportamental. La segmentación permitió identificar patrones y arquetipos que tienen nuestros clientes para conocerlos mejor y así permitiendo diferenciar estrategias para perfiles que, aunque técnicamente rentables, son altamente propensos a la fuga por falta de valor percibido.

- **Modelo Predictivo de Alto Desempeñ:** Se construyó exitosamente un modelo XGBoost que superó las metas de desempeño técnico (AUC 0.86), validando que la fuga responde a interacciones no lineales complejas que los modelos tradicionales no logran capturar.

- **Calibración y Certeza Financiera:** Se cumplió el hito de entregar probabilidades fidedignas mediante un *Brier Score* de 0.1247. Esto asegura que el score asignado refleja el riesgo real, habilitando el cálculo preciso del Valor Esperado de Pérdida (*Expected Loss*).

- **Optimización de Recursos:** La validación demostró que la focalización analítica permite a la organización reducir el tamaño de sus campañas de retención manteniendo una alta efectividad, conectando directamente la analítica con la rentabilidad y el retorno de inversión (ROI).

- **Herramientas para la Toma de Decisiones:** Se entregaron visualizaciones interpretables (valores SHAP) y un prototipo funcional que traduce la complejidad algorítmica en decisiones de negocio claras, empoderando a los *stakeholders* para actuar sobre los factores más influyentes.

9.1.3. Lecciones Aprendidas y Desafíos Superados

El desarrollo del proyecto generó aprendizajes clave que refinan la capacidad analítica de la organización:

- **El Poder de la Segmentación No Supervisada:** Se aprendió que la segmentación no debe ser predefinida. El uso de UMAP + HDBSCAN permitió encontrar patrones naturales y estructuras de densidad variable que métodos rígidos como K-Means no lograban capturar, revelando la verdadera complejidad de los datos de salud.

- **Gestión de Variables y Multicolinealidad:** Se superó el desafío de la calidad de datos mediante una rigurosa limpieza y selección de variables, logrando transformar datos transaccionales en variables de comportamiento claras. Esto permitió eliminar el ruido estadístico y modelar mejor las interacciones complejas.

- **Modelado a 12 Meses y Depuración:** Un desafío crucial fue la definición de la ventana de tiempo. Se validó la importancia de modelar a 12 meses y de depurar la base para el análisis de supervivencia, controlando los grupos con tiempos de permanencia extremos para evitar sesgos en el aprendizaje del modelo.

9.1.4. Valor del Análisis de Datos para la Toma de Decisiones

El análisis de datos transformó la comprensión de la problemática, pasando de la intuición a la evidencia cuantificable:

- **Comprensión Causal Profunda:** El análisis aportó valor al desenmascarar las verdaderas causas de la fuga, permitiendo entender que no es un problema unidimensional de "precio", sino una interacción compleja entre experiencia de servicio, infraestructura y ciclo de vida.

- **Identificación de Puntos de Dolor Ocultos:** La data reveló que la fricción operativa es más dañina que la competencia externa, redirigiendo la atención

estratégica hacia la excelencia operativa y la gestión de procesos como pilares de retención.

- **Sustento Financiero para la Acción:** El análisis permitió simular escenarios financieros robustos, otorgando a los tomadores de decisiones la seguridad de que la inversión en retención tiene un retorno positivo medible y eliminando la incertidumbre sobre la efectividad del gasto.

9.1.5. Impacto y Relevancia para la Organización

En términos de relevancia organizacional, los resultados esperados son importantes porque convierten el fenómeno de fuga en un problema gestionable ya que permiten saber dónde actuar, cuándo actuar y cómo actuar con cada afiliado, en función de su riesgo y horizonte de salida. Esto es especialmente valioso al considerar el impacto económico de no contar con un análisis profundo y segmentado ya que sin un score confiable, las estrategias tienden a ser generalistas, costosas y con bajo retorno, mientras que con estimaciones robustas de permanencia se puede focalizar el esfuerzo en los afiliados con mayor probabilidad de generar valor y mayor riesgo de cancelación.

De esta manera, la organización reduce el desgaste de invertir indiscriminadamente en adquisición o en retención masiva para sostener la rentabilidad, y migra hacia un enfoque más eficiente y preciso, sustentado en evidencia. Adicionalmente, el desarrollo de una aplicación analítica facilita la operacionalización del modelo al estandarizar el proceso, acelerar la consulta y mejorar la trazabilidad, lo cual fortalece la gestión de retención de afiliados activos y, a su vez, aporta información útil para orientar estrategias de atracción hacia perfiles con mayor afinidad y permanencia esperada en el Plan Complementario.

La implementación de estos resultados representa, por tanto, un punto de inflexión estratégico:

- **Cambio de Paradigma:** Permite migrar de una estrategia reactiva a una **preventiva**, actuando meses antes de que la decisión de fuga sea tomada.

- **Eficiencia Operativa:** La focalización precisa genera ahorros tangibles al evitar llamadas innecesarias a clientes seguros, optimizando el presupuesto y aumentando la tasa de éxito por contacto.

- **Conocimiento de la Población:** Permite saber exactamente quién está sobrepoblado en la cartera y cuáles segmentos tienen mayor fuga, habilitando el diseño de ofertas de valor diferenciadas.

- **Herramienta Unificada:** Finalmente, el desarrollo de una herramienta integral (Prototipo/Demo) democratiza el uso de la información, permitiendo a vendedores y líderes entender la situación de cada afiliado desde un modelo claro y sencillo, facilitando la gestión personalizada en el día a día.

9.2. Recomendaciones

Con base en los hallazgos empíricos derivados del análisis predictivo, la caracterización de arquetipos de riesgo y la evaluación económica del modelo de retención desarrollado en esta investigación, se propone un marco integral de intervención estratégica orientado a la optimización de la retención de afiliados en la línea de productos del Plan Complementario de Salud (PAC). Este marco integra dimensiones micro, meso y macro organizacionales, fundamentado en evidencia cuantitativa rigurosa y alineado con los principios de gestión del valor del ciclo de vida del cliente (Customer Lifetime Value) y teoría del comportamiento del consumidor en mercados de servicios de salud.

9.2.1 Fundamentos Conceptuales de las Recomendaciones

La gestión efectiva de la retención en esquemas de aseguramiento complementario en salud trasciende los enfoques reactivos tradicionales, demandando estrategias preventivas fundamentadas en analítica predictiva avanzada. Los hallazgos de esta investigación confirman que la deserción de clientes (churn) no constituye un evento administrativo aislado, sino un proceso estructural que erosiona sistemáticamente el valor económico de la cartera y compromete la sostenibilidad financiera de largo plazo.

La evidencia empírica obtenida mediante el análisis de supervivencia Kaplan-Meier demuestra que los primeros 90 días de vinculación representan una ventana crítica donde se define la rentabilidad del cliente y se determina si su afiliación constituirá un activo a largo plazo o una pérdida operativa inmediata. Este hallazgo fundamenta la necesidad imperiosa de intervenciones tempranas y focalizadas durante el período de onboarding.

Adicionalmente, los análisis de segmentación mediante UMAP-HDBSCAN y Random Survival Forest evidencian la heterogeneidad estructural de la base de clientes, con la identificación de cinco clústeres estratégicos que presentan riesgos, motivaciones y comportamientos de deserción diferenciados. Esta heterogeneidad

invalida los enfoques homogéneos de retención y justifica académica y económicamente la implementación de estrategias personalizadas por arquetipo de cliente.
Las recomendaciones aquí formuladas se estructuran en cuatro niveles de intervención:

(a) estrategias diferenciadas por arquetipo de cliente, (b) tácticas operativas de alta prioridad, (c) habilitadores tecnológicos para la implementación, y (d) marco de evaluación y mejora continua. Esta estructura responde a la necesidad de implementar acciones de corto, mediano y largo plazo que garanticen tanto la efectividad operativa inmediata como la sostenibilidad del modelo de negocio.

9.2.2 Estrategias de Intervención Diferenciadas por Arquetipo de Cliente

El análisis de segmentación topológica mediante la combinación de reducción dimensional no lineal (UMAP) y clustering basado en densidad (HDBSCAN) permitió identificar cinco arquetipos de afiliados con características demográficas, clínicas, comportamentales y de riesgo distintivas. Para cada segmento, se recomienda la implementación de estrategias específicas que respondan a sus motivaciones particulares y barreras de permanencia:

Arquetipo (Clúster)	Estrategia Recomendada	Fundamento Teórico y Tácticas de Implementación
Clúster 0: Incondicionales Perfil: Adultos mayores (>60 años), pacientes crónicos, usuarios de red propia. Nivel de riesgo: Bajo	Garantía de Excelencia en Experiencia Clínica	Este segmento presenta lealtad estructural derivada de barreras de salida naturales (preexistencias médicas, dependencia clínica). La estrategia debe enfocarse en: (a) blindaje de continuidad asistencial mediante protocolos de seguimiento proactivo para patologías crónicas; (b) garantía de disponibilidad farmacéutica sin fricciones administrativas; (c) excelencia en experiencia clínica que refuerce la percepción de cuidado integral; (d) programas de acompañamiento personalizado. Cualquier deterioro en la calidad del servicio puede romper la lealtad estructural acumulada.

Clúster 1: Fantasmas Perfil: Edad media, perfiles saludables, pago puntual, utilización nula o mínima. Nivel de riesgo: Latente	Activación Preventiva y *Nurturing* Digital	Afiliados con baja o nula utilización representan riesgo por desconexión emocional con la marca y ausencia de puntos de contacto que generen percepción de valor. Aunque técnicamente rentables en el corto plazo, constituyen el mayor peligro estratégico por falta de anclaje. Se propone: (a) campañas de salud preventiva digital que generen touchpoints sin detonar evaluaciones críticas de costo-beneficio; (b) recordatorios periódicos de derechos y beneficios mediante canales no invasivos; (c) incentivos para primera utilización que reduzcan la barrera psicológica de acceso; (d) encuestas proactivas de satisfacción que identifiquen barreras percibidas antes de la deserción.
Clúster 2: Jóvenes Productivos Perfil: <35 años, perfiles saludables, alta sensibilidad al precio. Nivel de riesgo: Alto	Tangibilización de Valor mediante Ecosistemas de Bienestar	Este segmento exhibe volatilidad transaccional significativa. Según la teoría económica del consumidor, perciben los servicios de salud como bienes de consumo negativo (*Negative Goods*): un costo sin retorno tangible inmediato. Al carecer de dependencia vital del sistema, abandonan ante cualquier fluctuación competitiva de oferta o precio. Se recomienda: (a) construcción de *switching costs* artificiales mediante ecosistemas digitales de bienestar que incluyan telemedicina, programas de *wellness*, descuentos en servicios complementarios (fitness, nutrición); (b) gamificación de comportamientos saludables con incentivos acumulables; (c) comunicación de valor preventivo

		con métricas tangibles de ahorro potencial; (d) estrategias de *lifestyle* que transformen la percepción del plan de costo a beneficio experiencial.
Clúster 3: Sensibles al Precio Perfil: Población productiva, nivel de ingresos bajo- medio. Nivel de riesgo: Medio	Protección ante Choques Económicos y Comunicación de Valor	Población vulnerable a fluctuaciones macroeconómicas y shocks de ingreso personal. Se recomienda: (a) flexibilización de esquemas de pago en períodos de estrés económico identificados mediante análisis predictivo de morosidad temprana; (b) comunicación transparente y recurrente del valor recibido versus costo mensual; (c) programas de descuentos por lealtad o modalidades de pago anticipado; (d) alternativas de planes con diferentes niveles de cobertura que permitan ajuste descendente sin deserción completa del ecosistema de la compañía.
Clúster 4: Dependientes Pasivos Perfil: Niños y adultos mayores en calidad de beneficiarios. Nivel de riesgo: Indirecto	Estabilización del Tomador Principal	Este segmento carece de autonomía decisoria; su permanencia depende enteramente de la estabilidad y satisfacción del tomador principal (titular). La estrategia debe enfocarse en: (a) garantizar excelencia en la experiencia del titular mediante las estrategias correspondientes a su arquetipo; (b) comunicación del valor familiar agregado; (c) programas de prevención pediátrica y geriátrica que generen percepción de cuidado integral del núcleo familiar.

Tabla 9.2.1 Descripción de arquetipos de clústeres generados

9.2.3 Tácticas Operativas de Implementación Prioritaria

Complementariamente a las estrategias diferenciadas por arquetipo, el análisis causal mediante valores SHAP y la caracterización de arquetipos prototípicos (El Fugitivo vs. El Leal) identificaron intervenciones tácticas de implementación prioritaria que presentan alto impacto potencial demostrado en la reducción de la tasa de deserción:

Migración Estratégica hacia la Red Propia de Atención: El "Efecto Fortaleza"

El análisis de importancia de variables mediante SHAP (*SHapley Additive exPlanations*) identificó el tipo de *IPS (TIPO_IPS_PROPIA)* como el predictor más significativo de retención en el modelo. La evidencia cuantitativa es contundente: los afiliados que utilizan exclusivamente red propia presentan una reducción aproximada del 40 % en el riesgo relativo de deserción, evidenciando el denominado "Efecto Fortaleza" de la infraestructura propietaria.

Este hallazgo confirma que las IPS exclusivas no constituyen únicamente activos asistenciales, sino que representan el principal mecanismo de fidelización estructural.

Los clientes que se atienden en red externa: (a) no desarrollan sentido de pertenencia con la marca, (b) evalúan el PAC como un *commodity* transaccional, y (c) son altamente vulnerables a ofertas competitivas. En contraste, la atención en infraestructura propia genera anclaje emocional, familiaridad con protocolos y personal médico y elevación de los costos psicológicos de cambio (*switching costs*).

Acciones recomendadas:

- Implementar incentivos económicos agresivos para migración durante los primeros seis meses de vinculación: eliminación total de copagos en red propia, acceso preferencial a citas con reducción de tiempos de espera, bonificaciones por uso exclusivo de infraestructura propietaria.

- Desarrollar campañas de comunicación que posicionen la red propia como diferenciador de calidad, destacando indicadores objetivos de desempeño (tasas de satisfacción, acreditaciones, tecnología disponible, especialización del personal médico).

- Establecer protocolos de acompañamiento personalizado en la primera atención en red propia (*onboarding* clínico), garantizando experiencias positivas que refuercen la decisión de migración y generen anclaje emocional temprano.

- Priorizar la migración del arquetipo "Fugitivo" (clientes de alto valor, edad productiva, con utilización de red externa) mediante gestión personalizada y

ofertas de valor diferenciadas.

Gestión Territorial Focalizada en Zonas de Alta Deserción

El análisis geográfico de las tasas de deserción reveló heterogeneidad espacial significativa, con tasas de churn sustancialmente superiores en regionales periféricas, particularmente en la Zona Norte. Este patrón sugiere fallas estructurales en accesibilidad geográfica y disponibilidad efectiva de servicios, más que problemas de calidad clínica o insatisfacción con el producto.

Acciones recomendadas:

- Asignar gestores de acceso territoriales con capacidad de resolución inmediata de barreras administrativas y facilitación efectiva de citas en las zonas identificadas como críticas mediante el análisis geoespacial.

- Implementar y subsidiadas modelos de telemedicina para regiones con limitaciones geográficas severas de acceso a infraestructura física, reduciendo las barreras de distancia y tiempo de desplazamiento.

- Establecer métricas diferenciadas de accesibilidad efectiva por regional (tiempo promedio para obtención de cita, distancia al punto de atención más cercano, disponibilidad de especialidades) y vincularlas a objetivos de gestión territorial.

- Evaluar la viabilidad de expansión de infraestructura propia o convenios preferenciales en zonas de alta deserción donde el análisis costo-beneficio justifique la inversión.

Protocolo de Respuesta Inmediata ante Fricciones Administrativas

El hallazgo más crítico del análisis causal es el impacto devastador de la variable *FLAG_FRICCION_INICIAL*. La evidencia demuestra que una sola PQRS durante el período de onboarding eleva la probabilidad de riesgo de deserción por encima del 80 % de forma inmediata. La fricción administrativa actúa como un catalizador binario de ruptura del contrato psicológico entre el afiliado y la organización, anulando incluso la lealtad acumulada por años de permanencia previa.

Acciones recomendadas:

- Establecer un protocolo de respuesta en tiempo real (máximo 24 horas) para PQRS relacionadas con facturación, acceso a servicios o autorizaciones médicas, con priorización absoluta de afiliados con antigüedad menor a 90 días.

- Implementar un sistema de alertas automáticas integrado con el CRM que identifique fricciones tempranas y active flujos diferenciados de compensación, escalamiento para resolución prioritaria, y seguimiento proactivo.

- Realizar contacto personal post-resolución (no automatizado) para verificar satisfacción efectiva con la solución implementada y reconstruir activamente la confianza deteriorada por la fricción inicial.

- Documentar y analizar sistemáticamente las causas raíz de fricciones recurrentes mediante técnicas de análisis de procesos (*process mining*) para implementar mejoras preventivas en los flujos operativos subyacentes.

- Considerar mecanismos de compensación proactiva (créditos, bonificaciones, meses sin costo) para casos de fricciones severas durante onboarding, evaluando el costo de oportunidad versus el LTV potencial en riesgo.

Transición de Gestión Masiva a Gestión por Valor Recuperable

El enfoque tradicional de campañas de retención masivas, homogéneas y reactivas ha demostrado ser financieramente ineficiente. La simulación económica desarrollada en esta investigación confirma que la maximización del retorno sobre la inversión (ROI) se alcanza mediante gestión quirúrgica focalizada en clientes que simultáneamente presenten: (a) alta probabilidad de deserción según el modelo predictivo, y (b) alto LTV recuperable.

Acciones recomendadas:

- Abandonar definitivamente las campañas masivas de retención. Implementar priorización estricta basada en la matriz bidimensional: Riesgo de Deserción (score del modelo) × LTV Estimado.

- Establecer umbrales de decisión optimizados económicamente (umbral 0.15-0.16 identificado en el análisis) que maximicen la captura de fugas recuperables sin erosionar márgenes por costos de gestión excesivos.

- Desarrollar protocolos de intervención diferenciados por nivel de riesgo: contacto básico (email, SMS) para riesgo bajo-medio; contacto telefónico personalizado para riesgo alto; gestión presencial o premium para riesgo crítico con LTV superior a percentil 90.

- Integrar el scoring predictivo en tiempo real con los sistemas operativos (CRM, contact center) para permitir decisiones inmediatas y accionables por parte de los equipos de gestión.

9.2.4 Habilitadores Tecnológicos y de Infraestructura Analítica

La traducción efectiva de las recomendaciones estratégicas en resultados operativos tangibles requiere la implementación de una infraestructura tecnológica robusta que permita la operacionalización sistemática del modelo predictivo y la ejecución ágil de las intervenciones recomendadas. En el marco del desarrollo de esta investigación, se ha construido una plataforma interactiva prototipo en R utilizando Shiny, que integra la totalidad de la base de datos procesada y los modelos predictivos desarrollados (XGBoost H2, Random Survival Forest, segmentación UMAP-HDBSCAN).

Plataforma de Decisión Analítica en Tiempo Real

Se recomienda que la organización implemente y escale la plataforma desarrollada como núcleo operativo de su estrategia de retención, convirtiendo la analítica descriptiva en acción prescriptiva concreta. Esta plataforma debe permitir:

- *Scoring* predictivo en tiempo real de la totalidad de la cartera elegible (clientes con antigüedad superior a 12 meses), con actualización mensual automática.

- Simulación de escenarios de intervención (*what-if analysis*) que permita evaluar ex-ante el impacto económico esperado de diferentes estrategias de retención antes de su despliegue operativo.

- Priorización automática de casos mediante la matriz bidimensional Riesgo × LTV, generando listas de gestión jerarquizadas por ROI esperado.

- Dashboards ejecutivos con visualización de KPIs clave: tasa de deserción por segmento, lift del modelo, ROI de campañas, evolución temporal de métricas de desempeño.

- Explicabilidad a nivel individual mediante valores SHAP, permitiendo a los gestores comprender los drivers específicos de riesgo de cada cliente y personalizar el discurso de retención.

Componentes Técnicos Fundamentales del Sistema de Retención

Los siguientes componentes metodológicos y técnicos constituyen los pilares del sistema de retención inteligente desarrollado y deben ser preservados en cualquier implementación productiva:

1. **Filtro de Maduración de Cartera:** Exclusión sistemática de clientes con antigüedad inferior a 12 meses para eliminar el ruido de *early churn* asociado a fricciones de onboarding comercial y focalizar recursos en la cartera

consolidada de alto LTV. Este filtro garantiza que el modelo aprenda patrones de abandono estructural, no circunstancial.

2. **Modelo Predictivo XGBoost H2 con Calibración Financiera:** Algoritmo de gradient boosting con ponderación de clases (*scale_pos_weight*) optimizada para maximizar sensibilidad (recall) sin generar exceso de falsos positivos. La calibración del umbral de decisión (0.15-0.16) se fundamenta en la maximización de la utilidad esperada, no en métricas técnicas convencionales.

3. **Explicabilidad mediante Valores SHAP:** Identificación de drivers causales a nivel global (importancia de variables) e individual (contribución marginal de cada predictor al score de riesgo de cada cliente), facilitando tanto decisiones estratégicas como tácticas operativas personalizadas.

4. **Microsegmentación Topológica (UMAP + HDBSCAN):** Identificación de estructuras de similitud no lineales en el espacio de características que permiten detectar perfiles complejos y outliers que métodos tradicionales (K-Means, clustering jerárquico) no logran capturar. Permite diseño de estrategias hiper- personalizadas por arquetipo.
5. **Validación Experimental Mediante Diseño Hold-out:** Implementación de diseño experimental 80/20 sobre los Top 10,000 clientes de mayor riesgo para medir el *lift* incremental real de las intervenciones versus grupo control. Este diseño permite cuantificar el ROI auditado de la estrategia y justificar inversiones incrementales.

9.2.5 Fronteras de Innovación Analítica y Mejora Continua

La madurez analítica alcanzada mediante esta investigación constituye un punto de partida para el desarrollo de capacidades avanzadas de inteligencia predictiva y prescriptiva. Se recomienda explorar las siguientes fronteras metodológicas como parte de un programa de mejora continua:

Incorporación de Procesamiento de Lenguaje Natural (NLP)

La información cualitativa contenida en PQRS, comentarios de encuestas de satisfacción, transcripciones de call center y registros de interacciones digitales representa una fuente de datos no estructurada con alto valor predictivo potencial actualmente subutilizada.

Acciones recomendadas:

- Implementar modelos de análisis de sentimiento sobre textos de PQRS para identificar deterioro en la percepción de valor y satisfacción previo a la materialización de la deserción observable.

- Desarrollar sistemas de clasificación automática de motivos de insatisfacción que permitan segmentar estrategias de retención según la naturaleza específica del riesgo (económico, clínico, administrativo, relacional).

- Integrar variables derivadas de NLP (*sentiment score, topic modeling, emotion detection*) como predictores adicionales en modelos de aprendizaje automático, evaluando su contribución incremental a la capacidad predictiva mediante validación cruzada rigurosa.

- Implementar sistemas de alerta temprana basados en detección de patrones lingüísticos asociados a intención de deserción en interacciones digitales y telefónicas.

Modelamiento de Efectos Heterogéneos de Tratamiento (*Uplift Modeling*)

El enfoque actual de gestión basado en probabilidad de riesgo no diferencia entre afiliados persuadibles y no persuadibles ante intervenciones de retención. Los modelos de uplift (también conocidos como modelos de efectos heterogéneos de tratamiento) permiten estimar el efecto causal incremental de las intervenciones a nivel individual, optimizando la asignación de recursos hacia aquellos clientes donde la intervención genera el máximo impacto diferencial.

Acciones recomendadas:

- Implementar experimentación controlada continua (A/B *testing*) con asignación aleatoria de clientes a grupos de tratamiento y control para estimar efectos causales reales de las estrategias de retención implementadas.

- Desarrollar modelos de *uplift* que identifiquen los cuatro grupos fundamentales del *framework de Radcliffe*: (a) Persuadibles (responden positivamente a intervención), (b) Seguros (no desertan independientemente de intervención), (c) Perdidos (desertan independientemente de intervención), y (d) Sleeping Dogs (desertan como reacción a la intervención).

- Maximizar el ROI concentrando recursos exclusivamente en el segmento persuadible, evitando el gasto ineficiente en clientes seguros (que no

requieren intervención) y *sleeping dogs* (donde la intervención es contraproducente).

- Evaluar arquitecturas de modelamiento avanzadas para *uplift: two-model approach, class transformation approach,* o algoritmos nativos como Causal Forest desarrollados por Athey y Wager.

Monitoreo Continuo y Detección de Degradación del Modelo (Model Drift)

Los modelos predictivos experimentan degradación inevitable de desempeño a lo largo del tiempo debido a: (a) cambios en la distribución de datos de entrada (data drift), (b) cambios en las relaciones entre predictores y variable objetivo (concept drift), y (c) evolución del comportamiento del mercado y competencia. La ausencia de sistemas de monitoreo puede resultar en decisiones basadas en modelos obsoletos con pérdida silenciosa de efectividad.

Acciones recomendadas:

- Establecer un sistema de monitoreo mensual automatizado de métricas de desempeño (AUC, Precision, Recall, Brier Score) en ventanas temporales móviles (rolling windows) con umbrales de alerta estadísticamente definidos que detonen procesos de re-entrenamiento.

- Implementar pruebas estadísticas de estabilidad de distribución de variables predictoras (Kolmogorov-Smirnov, Population Stability Index - PSI, Characteristic Stability Index - CSI) para identificar shifts en el comportamiento de la cartera.

- Desarrollar protocolos de versionamiento riguroso de modelos (model versioning) que permitan comparación sistemática de desempeño entre versiones, trazabilidad de cambios, y capacidad de reversión rápida ante degradación no anticipada.

- Documentar el desempeño longitudinal del modelo mediante dashboards ejecutivos que faciliten la toma de decisiones sobre ciclos de actualización, refinamiento de features, y necesidad de re-arquitectura completa.

- Establecer procesos de re-entrenamiento automático (automated retraining pipelines) cuando los indicadores de drift superen umbrales críticos, garantizando la frescura continua del modelo productivo.

9.2.6 Marco de Evaluación de Impacto y Sistema de Indicadores Clave de Desempeño

La implementación efectiva de las recomendaciones propuestas requiere un sistema robusto de medición que permita evaluar el impacto incremental real, justificar inversiones ante stakeholders y ajustar la estrategia dinámicamente mediante ciclos de aprendizaje organizacional. Se recomienda estructurar la evaluación en torno a tres categorías de indicadores clave de desempeño (KPIs):

Indicadores de Efectividad Operativa

- Estos indicadores miden la capacidad del sistema de retención para identificar correctamente clientes en riesgo y convertir contactos en permanencia efectiva:
- **Tasa de Rescate Real:** Diferencial de churn rate entre grupo tratamiento (afiliados gestionados según estrategia) y grupo control (*hold- out* sin intervención), medido mediante diseño experimental riguroso. Meta: reducción mínima de 15 % en tasa de deserción del grupo intervenido versus control.

- **Eficiencia del Gasto (Modelo Lift):** Ratio entre tasa de captura de desertores en el decil de mayor riesgo versus tasa base de deserción en la población general. Cuantifica la ganancia de información del modelo predictivo. Meta: mantener lift superior a 3.0x en el primer decil, confirmando valor agregado del scoring versus selección aleatoria.

- **Costo por Retención Exitosa:** Inversión total en gestión (OPEX de contact center + incentivos económicos) dividida por número de deserciones efectivamente evitadas. Meta: mantener costo unitario por debajo del 30% del LTV promedio recuperado, garantizando ROI positivo.

- **Tasa de Conversión de Contactos:** Proporción de afiliados contactados que completan al menos una acción de retención propuesta (migración a red propia, aceptación de beneficio, renovación de compromiso). Meta: tasa superior al 40 %, indicando efectividad del discurso y relevancia de la oferta de valor.
- **Cobertura del Modelo:** Proporción de la cartera elegible (antigüedad >= 12 meses) que recibe score predictivo válido. Meta: cobertura >= 95 %, minimizando población sin gestión por ausencia de datos.

Indicadores de Calidad y Estabilidad del Modelo Predictivo

Estos indicadores monitorean la validez técnica, calibración y estabilidad temporal del motor predictivo:

- Área Bajo la Curva ROC (AUC-ROC): Capacidad discriminativa general del modelo para separar desertores de no desertores. Meta: mantener AUC >= 0.85 en validación out-of-time (ventana temporal posterior al entrenamiento), confirmando generalización robusta.

- Sensibilidad en Umbral Óptimo (Recall): Proporción de desertores reales identificados correctamente por el modelo en el umbral de decisión calibrado financieramente (0.15 - 0.16). Meta: recall >= 75 %, priorizando captura sobre precisión según racionalidad económica del negocio.

- Brier Score: Métrica de calibración probabilística que penaliza desviaciones entre probabilidades predichas y resultados observados. Meta: Brier Score <= 0.15, indicando calibración honesta de probabilidades (no sobre-confianza ni sub- confianza sistemática).

- *Population Stability Index* (PSI): Estabilidad de la distribución de scores predictivos entre cohorte de entrenamiento y cohorte en producción. Meta: PSI < 0.10 (estabilidad alta), alertando sobre drift significativo si PSI > 0.25.
- *Characteristic Stability Index* (CSI): Estabilidad de la distribución de variables predictoras individuales a lo largo del tiempo. Permite identificar features específicas que experimentan drift y requieren re-ingeniería o exclusión.

Indicadores de Impacto en Valor del Negocio

Estos indicadores cuantifican la traducción de efectividad técnica en resultados financieros tangibles:

- Retorno sobre la Inversión (ROI): Ganancia neta generada por la estrategia de retención (LTV recuperado de clientes retenidos - costos de gestión) dividida por inversión total en el programa. Meta: ROI >= 250 % en horizonte de 12 meses, confirmando creación de valor económico sostenible. El análisis de simulación proyecta ROI de 302% en escenario base.

- Valor Presente Neto (VPN) de Afiliados Retenidos: Suma del valor actual de los flujos futuros esperados de afiliados que permanecieron como resultado directo de la intervención, descontados a tasa apropiada y neteados de costos de gestión. Permite justificación de inversión ante dirección financiera.

- Incremento en LTV Promedio de Cohorte: Diferencial en valor de vida del cliente entre cohortes gestionadas y cohortes no gestionadas medido longitudinalmente. Cuantifica el impacto en valor duradero, no solo en retención de corto plazo.

- Tasa de Churn Global de Cartera PAC: Evolución de la tasa de deserción general de la línea PAC como indicador de salud agregada del negocio. Meta: reducción sostenida de al menos 2 puntos porcentuales anuales, traduciendo efectividad micro en impacto macro.

- Valor Económico Agregado (EVA) del Programa de Retención: Utilidad operativa neta del programa menos costo de capital asignado. Permite evaluar si la retención genera valor económico real después de considerar el costo de oportunidad del capital invertido.

9.2.7 Consideraciones Críticas para la Implementación

La traducción exitosa de las recomendaciones estratégicas en resultados operativos tangibles trasciende la validez técnica de los modelos y demanda consideración rigurosa de aspectos organizacionales, tecnológicos, culturales y éticos que pueden facilitar u obstaculizar la adopción efectiva:

- Alineación y Gobernanza Organizacional: Las estrategias de retención inteligente demandan coordinación transversal entre áreas comerciales, clínicas, tecnológicas, financieras y de servicio al cliente. Se recomienda establecer un comité multidisciplinario de gestión de retención con autoridad ejecutiva, presupuesto asignado, y reporte directo a nivel ejecutivo (VP o Dirección General). Este comité debe tener mandato para tomar decisiones rápidas sobre inversiones en retención y arbitrar conflictos entre áreas.

- Infraestructura Tecnológica y Sistemas de Información: La operacionalización del modelo predictivo requiere integración técnica profunda con sistemas transaccionales existentes (CRM, ERP, plataforma de contacto, sistemas de facturación y autorización). Se requiere desarrollo de APIs robustas, pipelines de datos automatizados, e interfaces de usuario que faciliten la acción inmediata sobre los insights generados sin depender de equipos técnicos para cada consulta. La inversión tecnológica debe considerarse como habilitador estratégico, no como costo discrecional.

- Desarrollo de Capacidades y Gestión del Cambio: El personal de contacto directo con afiliados (call center, gestores comerciales, equipos de servicio) debe desarrollar: (a) comprensión fundamental de la lógica del modelo y la racionalidad de priorización, (b) habilidades de comunicación empática y resolución de objeciones específicas para cada arquetipo, (c) capacidad de interpretar y actuar sobre scores de riesgo y valores SHAP individuales. Se requiere inversión significativa en capacitación técnica y cambio cultural desde mentalidad de volumen hacia mentalidad de valor.

- Implementación Incremental y Aprendizaje Iterativo: La implementación debe seguir un enfoque incremental tipo *build-measure-learn* con pilotos controlados en regionales específicas (diseño quasi-experimental) antes de escalamiento nacional. Esta aproximación permite: (a) aprendizaje de campo sobre efectividad de tácticas específicas, (b) refinamiento de protocolos de gestión, (c) identificación y mitigación de resistencias organizacionales, (d) construcción de casos de éxito internos que faciliten adopción en otras geografías. Se recomienda iniciar piloto en 1-2 regionales de tamaño medio durante 3 meses antes de escalamiento.

- Consideraciones Éticas y Protección de Datos: Las estrategias de retención basadas en modelos predictivos deben respetar imperativos éticos fundamentales: (a) autonomía del afiliado para tomar decisiones informadas sobre su permanencia sin coerción, (b) transparencia sobre el uso de modelos predictivos y scoring de riesgo cuando sea solicitado por el cliente, (c) protección rigurosa de datos personales y sensibles (información de salud) según normatividad vigente (Ley de Habeas Data, regulación de supersalud), (d) no discriminación basada en características protegidas (edad, sexo, condición de salud) en el acceso a beneficios de retención. Se recomienda establecer un comité de ética de datos que revise periódicamente las prácticas del programa.

- Sostenibilidad de Largo Plazo y Mejora Continua: Las recomendaciones deben insertarse en un marco de mejora continua donde el aprendizaje de cada ciclo de intervención alimente sistemáticamente el refinamiento de: (a) modelos predictivos mediante re-entrenamiento periódico, (b) estrategias de retención mediante análisis de efectividad comparativa, (c) tácticas operativas mediante feedback estructurado de equipos de campo, (d) arquitectura de datos mediante incorporación de nuevas fuentes de información. La retención inteligente no es un proyecto con inicio y fin, sino una capacidad organizacional en evolución permanente.

- Alineación de Incentivos y Métricas de Gestión: Los objetivos individuales y de equipo deben alinearse con las métricas de retención por valor, no por volumen. Se recomienda que las compensaciones variables de equipos comerciales y de servicio incorporen: (a) tasa de retención ponderada por LTV (no tasa simple), (b) satisfacción post-intervención de clientes gestionados, (c) calidad de ejecución de protocolos (adhesión a mejores prácticas). Evitar incentivos perversos que promuevan gestión masiva indiscriminada o retención artificial de clientes sin valor recuperable.

9.2.8 Síntesis y Llamado a la Acción

La gestión estratégica de la retención fundamentada en analítica predictiva avanzada representa una capacidad organizacional crítica que trasciende la reducción de costos operativos para constituirse en una ventaja competitiva sostenible y un activo estratégico de primer orden. Los hallazgos de esta investigación demuestran de forma contundente que, cuando la analítica es rigurosa, explicable y alineada con objetivos de negocio, la retención deja de ser un centro de costos reactivo y se transforma en un generador proactivo de valor económico a largo plazo.

La evidencia empírica presentada confirma que:

- La deserción en el PAC no es un evento administrativo aislado, sino un proceso estructural que erosiona sistemáticamente el valor económico de la cartera. Los primeros 90 días constituyen una ventana crítica de intervención donde se define la rentabilidad del cliente.
- La base de clientes es heterogénea, con cinco arquetipos que presentan riesgos, motivaciones y barreras de permanencia radicalmente diferenciadas. Los enfoques homogéneos de retención son económicamente ineficientes estratégicamente contraproducentes.
- La infraestructura propia de atención (IPS exclusivas) reduce el riesgo de deserción en aproximadamente 40 %, constituyendo el activo de fidelización más potente de la organización. La migración a red propia debe ser prioridad estratégica absoluta.
- Una sola fricción administrativa durante onboarding eleva la probabilidad de churn por encima del 80 %, actuando como catalizador binario de ruptura del contrato psicológico. La excelencia operativa en los primeros 90 días no es opcional.

- La gestión quirúrgica focalizada en clientes de alto riesgo y alto LTV genera un ROI proyectado de 302 %, convirtiendo cada peso invertido en retención en tres pesos de valor económico recuperado.
- La implementación sistemática de las recomendaciones aquí formuladas, acompañada de un marco robusto de evaluación, aprendizaje continuo y refinamiento iterativo, posiciona a la organización para:
- Transformar la retención de un ejercicio estadístico reactivo en una capacidad estratégica proactiva basada en inteligencia predictiva.
- Maximizar el valor económico de la cartera mediante asignación eficiente de recursos de gestión hacia clientes con mayor potencial de recuperación.
- Desarrollar ventajas competitivas sostenibles fundamentadas en excelencia operativa, personalización de la experiencia del cliente, y profundidad del conocimiento de la base de afiliados.
- Construir una cultura organizacional *data-driven* donde las decisiones estratégicas se fundamentan en evidencia cuantitativa rigurosa, no en intuición o tradición.

La decisión crítica que enfrenta la organización no es si implementar este modelo de retención inteligente, sino cuánto valor económico se está perdiendo irreversiblemente cada mes por no hacerlo. El costo de la inacción supera ampliamente el costo de la inversión requerida para su implementación.

Las herramientas analíticas, los insights estratégicos y la infraestructura tecnológica prototipo están desarrolladas y validadas. La ventana de oportunidad está abierta. La ejecución disciplinada de estas recomendaciones determinará si la retención se consolida como ventaja competitiva diferenciadora o permanece como pasivo operativo que erosiona el valor de la franquicia.

10. Bibliografía

Administradora de los Recursos del Sistema General de Seguridad Social en Salud – ADRES. (2023). Efecto de la afiliación a Planes Voluntarios de Salud sobre el costo en servicios financiados con recursos de la UPC (2018–2023). https://www.adres.gov.co/analitica/Documents/Efecto_PVS_salud_2018-2023.pdf

Bardey, D., Zapata, J. G., Buitrago, G., & Concha, T. (2013). Mercado de seguros voluntarios de salud en Colombia [Informe final]. Fedesarrollo. https://www.repository.fedesarrollo.org.co/bitstream/handle/11445/359/Mercado%20de%20seguros%20voluntarios%20de%20salud%20en%20Colombia?sequence=4

Bolance, C., Guillen, M., & Padilla-Barreto, A. E. (2016). Predicting probability of customer churn in insurance. In R. Leon, M. Muñoz-Torres, & J. Moneva (Eds.), MS 2016. Lecture Notes in Business Information Processing, 254, 82–91. Springer, Cham.

Campello, R. J. G. B., Moulavi, D., & Sander, J. (2013). *Density-based clustering based on hierarchical density estimates.* In Advances in Knowledge Discovery and Data Mining (PAKDD) (pp. 160–172). Springer.

Colmédica. (s.f.). Diferencias entre medicina prepagada y plan complementario. https://www.colmedica.com/Paginas/todo-sobre-medicina-prepagada/diferencias-medicina-prepagada-plan-complementario.aspx

Departamento Administrativo Nacional de Estadística – DANE. (2025). Gran Encuesta Integrada de Hogares (GEIH) - Históricos. https://www.dane.gov.co/index.php/estadisticas-por-tema/mercado-laboral/empleo-y-desempleo/geih-historicos

Donado González, F. (2022). Predicción de siniestralidad en seguros de salud mediante técnicas de Machine Learning [Trabajo de fin de máster, Universidad de Alcalá]. Repositorio UAH. https://ebuah.uah.es/dspace/bitstream/handle/10017/54494/TFM_Donado_Gonzalez_2022.pdf?sequence=1

El País. (2024). "Radiografía de la medicina prepagada en Colombia: ¿cuál es la mejor opción en el mercado y cuánto vale?". Recuperado de: https://www.elpais.com.co/colombia/radiografia-de-la-medicina-prepagada-en-colombia-cual-es-la-mejor-opcion-en-el-mercado-y-cuanto-vale-20240327-0138.html

El Tiempo. (2024). La salud privada, el salvavidas para el 11 % de los colombianos. Recuperado de https://www.eltiempo.com/economia/sectores/la-salud-privada-el-salvavidas-para-el-11-de-los-colombianos-855898

Famisanar. (2025). Planes de Atención Complementaria. Recuperado de https://www.famisanar.com.co/

Galvis Moncaleano, E. A. (2023). Modelo de Churn para retención de clientes de Seguros Voluntarios [Trabajo de grado, Maestría en Analítica Aplicada, Universidad de La Sabana]. Intellectum. https://intellectum.unisabana.edu.co/handle/10818/59300

Gold, C. (2020). Fighting churn with data. Manning Publications. https://learning.oreilly.com/library/view/fighting-churn-with/9781617296529/OEBPS/Text/02.htm

Gregory, B. (2018). Predicting Customer Churn: Extreme Gradient Boosting with Temporal Data. arXiv:1802.03396. https://arxiv.org/abs/1802.03396

Günther, C.C., et al.: Modelling and predicting customer churn from an insurance company. Scand. Actuar. J. 2014(1), 58–71 (2014)

Hartigan, J. A., & Wong, M. A. (1979). *Algorithm AS 136: A k-means clustering algorithm.* Journal of the Royal Statistical Society. Series C (Applied Statistics), 28(1), 100–108.

Hu, X., Yang, Y., Chen, L., Zhu, S.: Research on a customer churn combination prediction model based on decision tree and neural network. In: 5th International Conference on Cloud Computing and Big Data Analytics (ICCCBDA), pp. 129–132 (2020)

Infobae. (2025). Colombianos huyen del sistema de salud público. Recuperado de https://www.infobae.com/

Kavlakoglu, E., & Russi, E. (2024). ¿Qué es XGBoost? IBM. https://www.ibm.com/es-es/think/topics/xgboost

Khandelwal, N., & Sakalle, V. (2025). Customer Churn Prediction using XGBoost Classifier. Journal of Information Systems Engineering and Management, 10(19s). https://doi.org/10.52783/jisem.v10i19s.3111

McInnes, L., Healy, J., & Astels, S. (2017). *hdbscan: Hierarchical density based clustering.* Journal of Open Source Software, 2(11), 205.

McInnes, L., Healy, J., & Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. arXiv preprint arXiv:1802.03426.

Morillo, J. (2023). Integración de un modelo de análisis de supervivencia para la predicción de la pérdida de clientes en seguros [Tesis de máster, Universidad Politécnica de Madrid]

Nueva EPS. (2025). Plan de Atención Complementaria. Recuperado de https://www.nuevaeps.com.co/

Ospina, M. (2022). Modelo de inteligencia de negocios para caracterización de usuarios en aseguradora colombiana. Aplicación con Power BI [Tesis de maestría, Universidad Autonoma Bucaramanga]

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830

Rousseeuw, P. J. (1987). *Silhouettes: A graphical aid to the interpretation and validation of cluster analysis.* Journal of Computational and Applied Mathematics, 20, 53–65.

Salih, A. M., Raisi-Estabragh, Z., Boscolo Galazzo, I., et al. (2024). A Perspective on Explainable Artificial Intelligence Methods: SHAP and LIME. arXiv:2305.02012v3

Sanitas. (2025). "Plan Complementario Premium". Recuperado de: https://www.colsanitas.com/pac-planes-complementarios/plan-premium

Scriney, M., Nie, D., Roantree, M. (2020). Predicting Customer Churn for Insurance Data. In: Song, M., Song, IY., Kotsis, G., Tjoa, A.M., Khalil, I. (eds) Big Data Analytics and Knowledge Discovery. DaWaK 2020. Lecture Notes in Computer Science(), vol 12393. Springer, Cham. https://doi.org/10.1007/978-3-030-59065-9_21

Sundarkumar, G.G., Ravi, V., Siddeshwar, V.: One-class support vector machine based undersampling: application to churn prediction and insurance fraud detection. In: 2015 IEEE International Conference on Computational Intelligence and Computing Research (ICCIC), pp. 1–7. IEEE (2015)

Superintendencia Nacional de Salud. (2022). "Circular Externa 2022151000000051-5". Recuperado de: https://www.supersalud.gov.co/normatividad/circular-externa/circulacion-externa-2022151000000051-5

SURA. (s.f.). Pólizas de salud SURA: Compara nuestros seguros de salud. https://www.sura.co/seguros/personas/salud/poliza

Suramericana S.A. (2025). Tendencias del consumidor. https://suramericana.com/content/uploads/2025/02/suramericana_tendencias_del_consumidor_.pdf

Tan, P.-N., Steinbach, M., & Kumar, V. (2019). *Introduction to Data Mining* (2nd ed.). Pearson. (Capítulos de reglas de asociación y métricas de interestingness como support, confidence y lift).

Tralice, F. (2019). Predicción de churn de seguros con LightGBM [Tesis de maestría, Universidad Torcuato Di Tella]. Repositorio UTDT. https://repositorio.utdt.edu/bitstreams/8ebaaf68-17dd-45b6-bd2f-6cad524427a1/download

Venna, J., & Kaski, S. (2001). *Neighborhood preservation in nonlinear projection methods: An experimental study.* In *Proceedings of the International Conference on Artificial Neural Networks (ICANN)* (pp. 485–491).

Verbeke, W., Martens, D., & Baesens, B. (2012). Social network analysis for customer churn prediction. Applied Soft Computing, 14(2), 431–446. https://doi.org/10.1016/j.asoc.2012.08.005

Wang, Y., & Ni, X. S. (2019). A XGBoost Risk Model via Feature Selection and Bayesian Hyper-Parameter Optimization. arXiv:1901.08433

Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. Monthly Weather Review, 78(1), 1–3.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794. https://doi.org/10.1145/2939672.2939785

He, H., & Garcia, E. A. (2009). Learning from imbalanced data. IEEE Transactions on Knowledge and Data Engineering, 21(9), 1263–1284. (Esta es la "biblia" académica del desbalance de datos).

Tan, P.-N., Steinbach, M., & Kumar, V. (2019). Introduction to Data Mining (2nd ed.). Pearson. (Texto guía clásico sobre metodologías de evaluación).

Tralice, F. (2019). Predicción de churn de seguros con LightGBM. [Tesis de maestría, Universidad Torcuato Di Tella]. Repositorio UTDT.

Niculescu-Mizil, A., y Caruana, R. (2005). Predicting good probabilities with supervised learning. Proceedings of the 22nd International Conference on Machine Learning, 625–632.

Jolliffe, I. T. (2002, 2ª ed. 2010). *Principal Component Analysis.* Springer Series in Statistics.

Salazar Gaitán, I. (2024, enero 10). Planes complementarios representan 16% de los pagos voluntarios en el sector salud. La República.

https://www.larepublica.co/empresas/planes-complementarios-pesan-16-en-los-pagos-voluntarios-por-servicios-de-salud-3777655

Infopalante. (2024, mayo). ¿Cómo funciona el sistema de salud en Colombia?. Infopalante. https://www.infopalante.org/articles/4423707723671

Caicedo, E. (2025, abril 9). Informe alerta por grave deterioro del sistema de salud: entre enero de 2022 y enero de 2025 PQRS crecieron 101 %. El Tiempo. https://www.eltiempo.com/salud/informe-alerta-por-grave-deterioro-del-sistema-de-salud-entre-enero-de-2022-y-enero-de-2025-pqrs-crecieron-101-3443398

Guerrero, J. (2025, julio 9). Crisis en la salud impulsa migración a medicina prepagada: 450.000 nuevos usuarios en 2025. El Tiempo. https://www.eltiempo.com/salud/crisis-en-la-salud-impulsa-migracion-a-medicina-prepagada-450-000-nuevos-usuarios-en-2025-3470261

El Colombiano. (2025, septiembre 1). Aumenta 37% el número de afiliados a planes de medicina prepagada en Colombia. https://www.elcolombiano.com/negocios/afiliados-a-planes-de-medicina-prepagada-suben-crisis-salud-colombia-NL28898335

Redacción Economía. (2024, 24 febrero). Los planes complementarios de salud están en vilo por la reforma al sector, ¿qué esperar?. Semana. https://www.semana.com/economia/articulo/los-planes-complementarios-de-salud-estan-en-vilo-por-la-reforma-al-sector-que-esperar/202424/

UNIR Colombia. (2025, 7 marzo). ¿Cómo funciona el sistema de salud en Colombia?. https://colombia.unir.net/actualidad-unir/sistema-salud/

Cueto, J. C. (2024, 5 abril). Cómo funciona el sistema de salud de Colombia que Petro no logra reformar (y cómo se diferencia de otros países de América Latina). BBC News Mundo. https://www.bbc.com/mundo/articles/cxrz3prg06wo

Asprilla, T. (2025, 5 junio). EPS acumulan pérdidas por más de $10 billones y cartera vencida por $27 billones: Así Vamos en Salud. ConsultorSalud. https://consultorsalud.com/eps-perdidas-cartera-vencida-asi-vamos-en-salud/

Noticias RCN. (2025, 6 julio). Aumento en seguros voluntarios revela preocupación en el sistema de salud. https://www.noticiasrcn.com/colombia/aumento-en-seguros-voluntarios-revela-preocupacion-en-el-sistema-de-salud-909252

Noticias Caracol. (2023, 21 diciembre). Planes voluntarios de salud, ¿en qué consisten y qué beneficios traen para sus afiliados?. https://www.noticiascaracol.com/estilo-de-vida/planes-voluntarios-de-salud-en-que-consisten-y-que-beneficios-traen-para-sus-afiliados-cm25

11. Anexos

A.1. Cronograma y Matriz Raci

Chart de Proyecto - Predicción de Fuga PA

A.2 Documentos.

Project Plan Summary- Seminario 2

A.3 Merge_Completo_vigencia_total.parquet

Merge_Completo_vigencia_total.parquet

A.4. Modelo de Segmentación Kmeans

Modelo de Segmentación Kmeans.ipynb

A.5. Modelo de Segmentación UMAP + HDBSCAN

Modelo de Segmentación UMAP + HDBSCAN.ipynb

A.6. Modelo de Regresión y XGBoost

Modelo de Regresión y XGBoost.ipynb

A.7. Pregúntale al Modelo para validación

Preguntele_al_modelo_ABC_EPS.ipynb

A.8. Modelo de Regresión y XGBoost

Simulacion_Financiera_EPS_ABC.ipynb

A.9. Prototipo funcional de despliegue (valor agregado)

Como aporte adicional al alcance académico de esta investigación, y con el fin de explorar la viabilidad técnica de la operacionalización del modelo, se desarrolló un prototipo de interfaz gráfica (*Demo*) orientado al usuario final.
El objetivo de este desarrollo complementario es demostrar cómo la complejidad matemática de los algoritmos (*XGBoost + SHAP*) puede traducirse en una herramienta intuitiva para el personal de gestión.

Funcionalidad del Prototipo La herramienta fue diseñada como un Sistema de Soporte a la Decisión (DSS) que integra tres capas de información en una sola vista:

1. **Alertamiento Visual:** Semaforización del riesgo para rápida identificación.
2. **Explicabilidad Local:** Visualización de los factores causales específicos del paciente.
3. **Prescripción:** Sugerencia de la "Siguiente Mejor Acción" basada en el clúster.

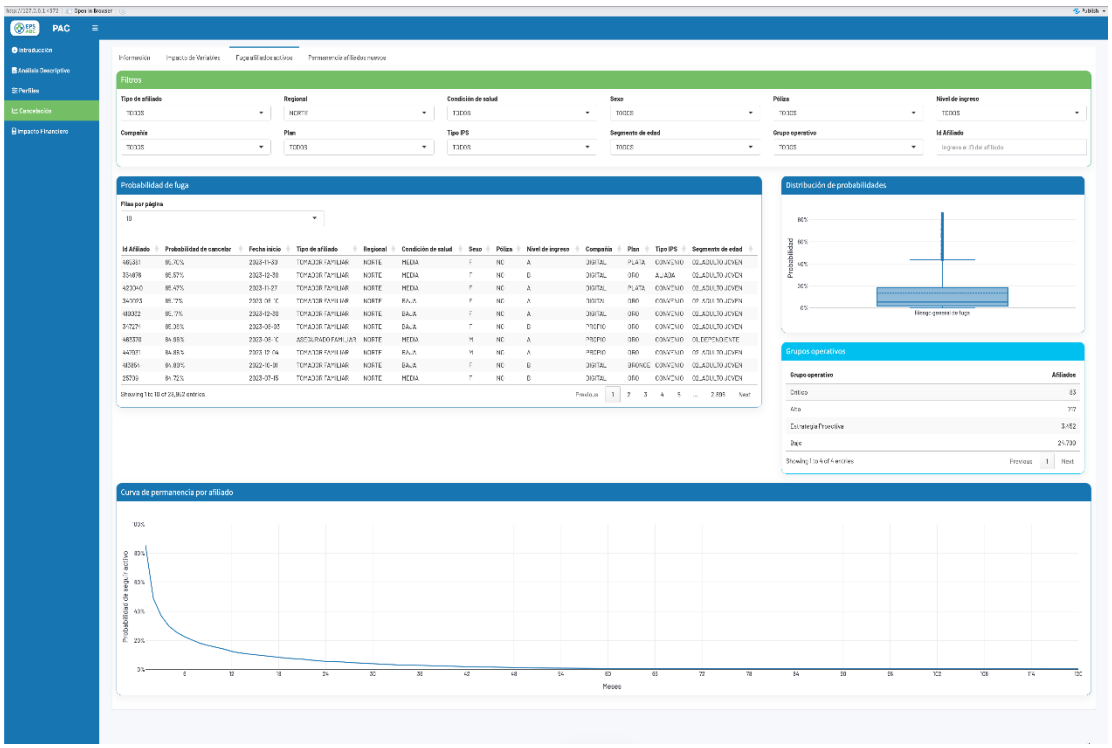

Ilustración A.7.1. Interfaz de Usuario del Prototipo de Retención

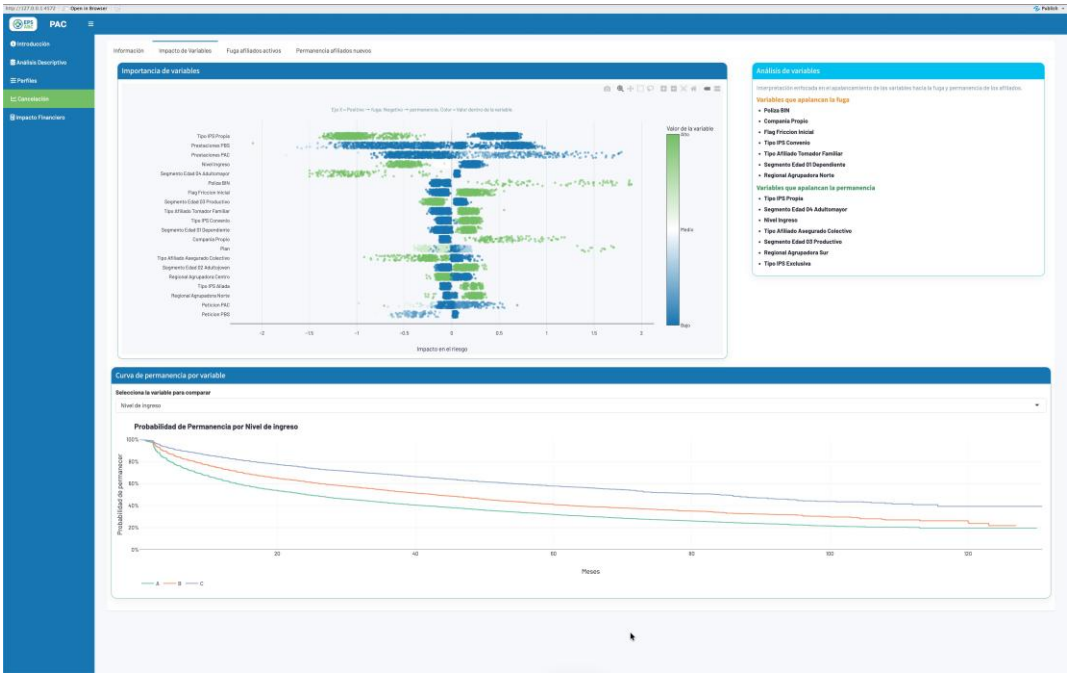

Ilustración A.7.2. Interfaz de Usuario del Prototipo de Retención SHAP

Nota: *La figura muestra el panel de control donde el gestor visualiza el score del paciente y los drivers de decisión, facilitando una gestión personalizada. Este prototipo sirve como prueba de concepto (PoC) para una futura implementación en el CRM corporativo.*